与人类的自适应协作：面向多智能体 LLM 的元认知策略优化与持续学习

Adaptive Collaboration with Humans: Metacognitive Policy Optimization for Multi-Agent LLMs with Continual Learning

Wei Yang*、Defu Cao*、Jiacheng Pang、Muyan Weng、Yan Liu

南加州大学（University of Southern California）

{wyang930, defucao, pangj, muyanwen, yanliu.cs}@usc.edu

ICLR 2026 · arXiv:2603.07972v1 [cs.AI] · 原文 30 页 · * 共同第一作者

> 中文阅读版说明：本文件依据 ICLR 2026 论文逐节翻译，保留原有章节顺序、公式、表格数值与图注位置。图 1—12 保留原图并附中文图注；表 1—13 以中文重排，数值照录原文。模型名、方法名（HILA、DLPO、GRPO、EVAL、CREATE、DEFER）与参考文献条目保持英文。附录 A—D 一并译出；提示词模板属于操作性文本，保留英文原文。

摘要

单个大语言模型（LLM）的规模扩展已带来显著进展，但下一个前沿在于通过多智能体系统（MAS）扩展协作。然而，纯自主的 MAS 仍是“封闭世界”系统，受限于预训练模型的静态知识边界。这一局限使它们在需要训练数据之外知识的任务上十分脆弱，面对新挑战时常导致集体失败。为解决这一问题，我们提出人在回路多智能体协作（Human-In-the-Loop Multi-Agent Collaboration, HILA）框架，一种面向人—智能体协作的原则性范式。HILA 训练智能体学习一种元认知策略，用以决定何时自主解决问题、何时求助人类专家。为落实该策略，我们引入双环策略优化（Dual-Loop Policy Optimization, DLPO），把即时决策与长期能力成长解耦。内环使用带成本感知奖励的组相对策略优化（Group Relative Policy Optimization, GRPO）来优化求助决策；外环实现持续学习，把专家反馈转化为高质量监督信号，增强智能体的推理能力。在困难的数学与问题求解基准上的实验表明，配备 DLPO 的 HILA 持续优于先进 MAS，为协作式、可持续改进的智能体系统奠定了原则性基础。代码见 https://github.com/USC-Melady/HILA.git。

1 引言

单个大语言模型（LLM）的规模扩展已取得显著进展，但下一个前沿在于通过多智能体系统（MAS）扩展协作（Hong et al., 2023; Chen et al., 2023b; Jiang et al., 2023; Ning et al., 2023; Han et al., 2025; Wang et al., 2025a; Chen et al., 2025b）。通过协调多个智能体来解决任何单一模型都无法企及的问题，这一范式催生了从结构化辩论到动态工作流优化的一系列创新（Zhang et al., 2024a; Qiao et al., 2024; Han et al., 2025）。然而这些系统面临固有天花板：无论交互协议多么精巧，纯自主智能体本质上仍是封闭世界。其知识边界受预训练语料限制（Wang et al., 2023b; Srivatsa et al., 2024; Du et al., 2023; Liu et al., 2024）。它们可以重组已有信息，却无法生成新知识或适应未见情境。当任务需要实时信息、领域专长或训练中缺失的推理模式时，这便造成脆弱性（Zhang et al., 2024d; Chen et al., 2025a）。此类情况下，仅靠内部协作无法弥合差距，往往导致集体失败。要打

破这一天花板、实现开放式智能，需要新范式。我们认为，最有原则的路径是整合外部人类专长，把封闭系统转变为具备持续学习与成长能力的自适应框架（Sun et al., 2025; Zou et al.）。

在封闭世界范式内，研究主要沿两个方向展开。第一，强调通过日益复杂的交互协议优化自主协作。基于结构化辩论（Chan et al., 2023; Liu et al., 2024）、拓扑控制（Ong et al., 2024; Chen et al., 2024b）与工作流图优化（Zhang et al., 2024b; Li et al., 2025a）的框架，在精炼与重组智能体内部知识方面取得了显著改进。然而这些方法大多进行集体内省（Zhang et al., 2024e; Chen et al., 2024a），最大化利用已有信息，却不超出聚合知识边界。它们是强大的整合器，却不是能获得真正新能力的真正学习者。认识到这一内在局限，第二条研究路线试图纳入人类专长（Takerngsaksiri et al., 2025; Mozannar et al., 2025）。许多人机回环系统（Liu et al., 2023; Pandya et al., 2024）主要把人当作子任务上的被动神谕或监督者。这留下两个关键问题未解：何时求助专家，往往被简化为低置信度阈值等启发式，而非学习得到的策略（Kenton et al., 2024; Li et al., 2024b）；以及如何从人类输入中学习，通常被当作一次性修补，而非长期能力成长的催化剂（Mu et al., 2024; Wang et al., 2025b）。重要的是，人类干预有潜力在多个层面发挥作用：既提供针对特定推理错误的局部纠正，也提供重塑整个协作过程的更广泛调整（Triem & Ding, 2024; Grondin et al., 2025）。

这一分析表明，关键挑战不在于智能体能否与人类交互，而在于它们能否智能地、有策略地交互。解决这一点需要元认知策略——一种对自身能力与同伴能力进行推理、以指导协作的高层策略。这样的策略必须解决两个交织的问题：**何时提问**，要求超越启发式，对不确定性建模，并权衡失败风险与干预成本；**如何成长**，要求建立把专家反馈转化为持久能力提升、而非一次性修补的机制。统一这些要素的范式，对于构建开放、持续演化的智能体系统至关重要。

为应对这些挑战，我们提出人在回路多智能体协作（HILA），一个面向自适应人—智能体协作的原则性框架。HILA 的核心思想不只是把人放进回路，而是赋予智能体一种元认知策略，决定何时需要外部专长、以及应如何使用外部专长。HILA 通过三个协同组件落实这一思想：（i）自主运行（Autonomous Operation），智能体首先用当前能力尝试解决问题；（ii）元认知评估（Metacognitive Assessment），评估自身置信度与任务难度，以识别潜在知识边界；（iii）策略性求助（Strategic Deferral），把外部专长作为有针对性的干预，而非被动兜底。为优化这种元认知行为，我们进一步提出双环策略优化（DLPO），一个把短期干预决策与长期能力提升分离的训练框架。其内环应用带成本感知奖励的 GRPO 在线改进求助行为；外环把求助事件中的专家反馈转化为监督训练信号，持续增强模型底层推理能力。

本文主要贡献如下：

- 我们提出人在回路多智能体协作（HILA）框架，一种人—智能体协作范式，赋予智能体元认知策略，以决定何时策略性地求助人类专家。
- 我们引入双环策略优化（DLPO），一种把短期求助决策与长期能力成长分离的训练方法。内环采用带成本感知奖励的 GRPO，外环利用专家反馈作为持续学习的监督信号。
- 在数学推理与通用问题求解基准上的大量实验表明，配备 DLPO 的 HILA 优于自主多智能体系统，为持续改进的智能体协作奠定了稳健基础。

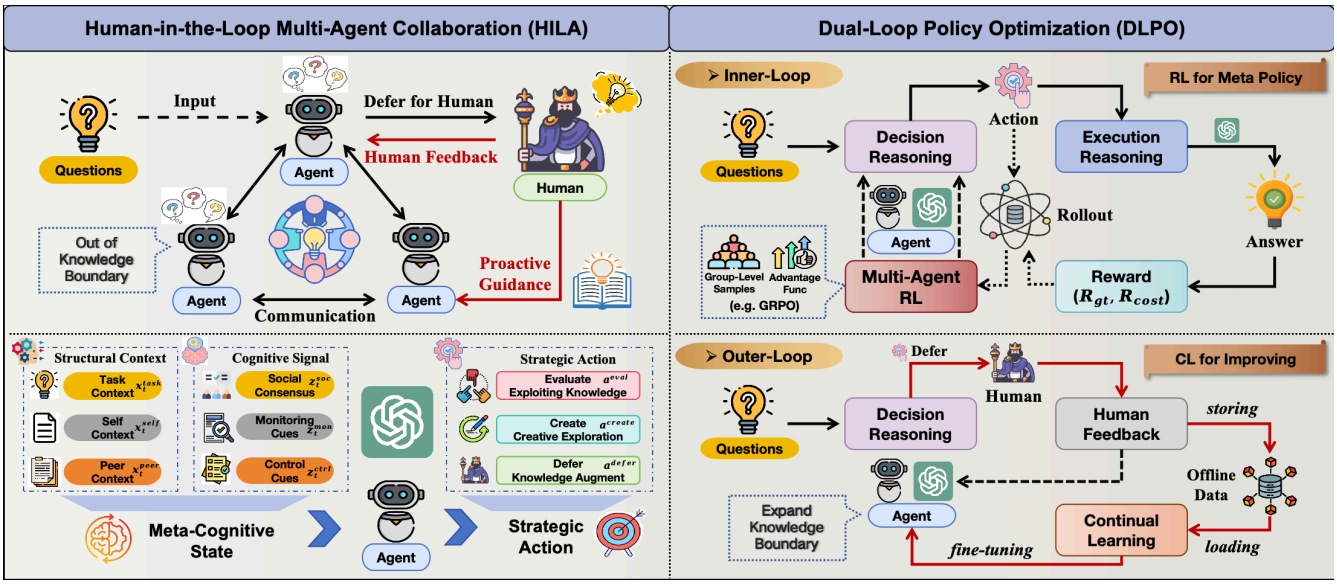


图 1：HILA 框架及其双环策略优化（DLPO）训练范式概览。左：HILA 通过元认知状态与策略动作（EVAL、CREATE、DEFER）协调多智能体协作，同时支持主动的人类指导与被动的专家反馈。右：DLPO 在内环 RL 中用成本感知奖励优化元策略，并在外环持续学习循环中把 DEFER 触发的人类反馈存为离线监督，从而扩展模型的知识边界。

2 相关工作

单打独斗的大语言模型（LLM）受上下文长度、顺序生成与技能覆盖限制，制约了其解决复杂推理任务的能力（Gabriel et al., 2024; Ping et al., 2025b; Li et al., 2025b; Ye et al., 2024; Xia et al., 2025a）。为缓解这些问题，多智能体系统（MAS）得到广泛探索：多个 LLM 被组织为协作结构，进行集体问题求解（Hong et al., 2023; Yang et al., 2025a; Jiang et al., 2023; Qiao et al., 2024; Yang & Thomason, 2025）。早期工作依赖基于提示词的范式，分配预定义角色或工作流，实现辩论、批评或企业式流水线（Du et al., 2023; Chan et al., 2023; Yang et al., 2025b; Chang et al., 2025）。这些设计虽然有效，却缺乏适应性，因为交互协议固定，无法通过经验演化。较新的工作转向结构化协调与自适应通信。预定义方案在链、树或图上进行辩论或同行评审（Liu et al., 2024; Qian et al., 2024）；自适应方法则通过路由、剪枝或工作流搜索动态重构交互（Yang et al., 2026; Chen et al., 2026; Yue et al., 2025; Ping et al., 2025a）。

一条互补的研究路线引入人在回路协作。人被定位为监督者、神谕或评估者，提供纠正或领域知识以增强智能体表现（Takerngsaksiri et al., 2025; Mozannar et al., 2025; Liu et al., 2023; Pandya et al., 2024）。密切相关的 Siedler & Gemp (2025) 研究 MARL 中由 LLM 中介的指导：LLM 作为自然语言控制器，解释并传递干预，以塑造智能体的学习轨迹并加速训练。然而这类系统往往依赖启发式（如置信度阈值）触发求助（Kenton et al., 2024; Li et al., 2024b），反馈通常被当作一次性修补，而非持续能力成长的信号（Mu et al., 2024; Wang et al., 2025b）。近期讨论强调，人类参与可发生在多个层面，从纠正局部推理错误到重塑全局协作动态（Triem & Ding, 2024; Grondin et al., 2025）。这些方向共同推进了 MAS 领域，但要从封闭世界重组走向开放、自适应协作，仍有挑战。相关工作的详细综述见附录 A。

3 方法

我们的方法构建一个面向与人类专家自适应协作的多智能体系统。图 1 给出 HILA 及其双环策略优化概览，突出多智能体协作如何与人类耦合。核心是一种元认知策略，使智能体能够对自身能力与同伴能力进行推理，从而决定何时自主行动、何时求助外部专长。我们把这一协作过程形式化为元认知马尔可夫决策过程（Metacognitive Markov Decision Process），作为框架基础。随后通过结构化认知状态空间与功能性动作空间来具体化框架。最后，我们引入双环策略优化算法，把改进元认知策略的强化学习与整合专家反馈为持久能力成长的持续学习结合起来。

3.1 预备知识：元认知马尔可夫决策过程

我们把人与智能体的协作建模为元认知马尔可夫决策过程（Meta-MDP），对自主问题求解或求助人类专家等高层认知策略上的决策进行形式化。这一抽象为定义协作框架中的状态、动作、转移与奖励提供了原则性基础。完整形式化与详细设计见附录 B。

3.2 人—智能体协作框架

在 Meta-MDP 基础上，我们引入一个通过三个组件落实人—智能体交互的框架：（i）结构化认知状态空间，编码问题上下文与元认知评估；（ii）功能性动作空间，表示高层协作策略；（iii）交互协议，规定跨轮次的协调。这些要素让智能体在推理任务的同时，以有原则的方式调节决策边界。

3.2.1 结构化认知状态空间

元认知策略不应仅凭狭窄的局部回答做决策，因为有效协调依赖对当前推理语境的更广阔视野。在我们的设置中，策略应考虑三类主要信息。第一，任务上下文，包括原始问题与相关交互历史，它定义决策环境与当前目标。第二，智能体自身的自我上下文，即最新解答与局部推理状态，反映其当前信念与置信度。第三，来自其他智能体的同伴上下文，因为它们的回答提供了关于一致、分歧与替代解路径的补充证据。三者共同为“保持当前轨迹、生成新解，还是寻求更强外部援助”提供更丰富的依据。

为进一步支持超越原始任务/自我/同伴上下文的元策略决策，我们可选地用一小组结构化认知信号增强 s_t，这些信号实现元认知的“监控—控制”视角以及标准社会信息线索。在不确定条件下，控制器受益于三类互补证据：关于集体状态的社会证据（Cannon-Bowers et al., 1993; Jost et al., 2013）、关于当前解答可靠性的自我监控证据（Nelson & Narens, 1994; Dunlosky & Metcalfe, 2008），以及关于进一步内部思考是否可能有帮助、是否需要升级的认知控制证据（Risko & Gilbert, 2016）。我们通过可观察交互轨迹上的轻量摘要来落实这些来源：社会共识线索 z_t^{soc}（趋同 vs. 冲突）、元认知监控线索 z_t^{mon}（局部可靠性）与认知控制线索 z_t^{ctrl}（进展 vs. 升级）。所有线索均用简单的解析与规则启发式计算，形成显式的、面向决策的抽象，不引入额外学习模块。

形式上，我们把策略状态表示为

$$s_t = \mathrm{concat}\left(x_t^{task},\, x_t^{self},\, x_t^{peer},\, z_t^{soc},\, z_t^{mon},\, z_t^{ctrl}\right),$$

其中 x_t^{task}、x_t^{self}、x_t^{peer} 分别表示任务、自我与同伴上下文，z_t^{soc}、z_t^{mon}、z_t^{ctrl} 是可选的结构化认知线索，刻画社会共识、元认知监控与元认知控制证据。实践中，这些线索通过可观察交互轨迹上的轻量解析与规则启发

式计算，而非引入额外学习模块或外部监督。该设计为元策略提供当前协作状态的显式、面向决策的抽象，同时保持结构化组件的轻量与辅助性。

3.2.2 策略动作空间

Meta-MDP 中的动作空间 $\mathcal{A}$ 不由底层文本生成定义，而由一组离散的高层认知策略定义。这些动作使智能体能够管理问题求解过程，在利用已有集体知识、探索新解与策略性求助外部专长之间取得平衡。形式上，动作空间定义为

$$\mathcal{A} = \{a_{eval},\ a_{create},\ a_{defer}\}.$$

评估（a_{eval}）：利用集体知识。 该动作代表趋同与综合的认知立场。选择 a_{eval} 时，智能体承诺利用多智能体组内已有知识。操作上，它必须从同伴在当前轮已提出的解答中选择并认可一个。该动作让智能体利用集体智慧，强化高质量、共识性的解答。

创造（a_{create}）：创造性探索与假设生成。 该动作体现发散与探索的认知立场。选择 a_{create} 时，智能体认为当前解答池不足，承诺从头生成新的解答序列（“Choice”“Reason”）。该动作对于打破认知固着、纠正组内共享错误、引入新的可能更优推理路径至关重要。

求助（a_{defer}）：风险缓解与知识增强。 该动作代表最高层次的元认知意识——识别系统自身能力极限的能力。选择 a_{defer} 表示智能体判断问题的不确定性或难度超出集体当前可靠求解能力。操作上，这会触发调用外部人类专家，其高质量示范随后作为本轮输出。该动作既是关键情境下保证任务成功的机制，也是通过持续学习向系统引入新知识的通道。

3.2.3 协作交互模型

本框架的一个定义性特征，是通过结构化多轮协议把人类专长整合进集体推理。每一轮 t，所有 N 个智能体接收共享认知状态 s_t。每个智能体 i 独立采样元认知动作 $a_{i,t} \sim \pi_\theta(a|s_t)$ 并并行执行。输出 $y_{i,t}$ 取决于所选动作：自主行动时，智能体应用其内部生成过程 $g_\theta(s_t)$；求助时，采用专家给出的权威解答 $y_{human,t}$：

$$y_{i,t} = \begin{cases} g_\theta(s_t), & \text{若 } a_{i,t} \in \{a_{eval}, a_{create}\}, \\ y_{human,t}, & \text{若 } a_{i,t} = a_{defer}. \end{cases}$$

集合 $\{y_{1,t}, \ldots, y_{N,t}\}$ 随后构成下一状态 s_{t+1}，确保更新反映最可靠的信号——无论来自自主综合还是人类示范。

从学习角度看，求助动作具有双重作用。它既是风险缓解，在不确定下覆盖有缺陷的解答以保证进展；也是知识增强，把专家示范作为高质量样本注入持续学习（第 3.3 节）。因此，人类协作者不仅是兜底神谕，更是系统改进的驱动者。

3.3 带持续学习的自适应策略优化

要掌握上述元认知挑战，需要一种优化策略，在两条竞争路径间取得平衡：高风险但可能高回报的自主问题求解，以及低风险但受限的求助专家。这一权衡天然适合强化学习（RL），目标是学习策略 π_θ，最大化协作过程的期望效用。为此，我们提出双环策略优化（DLPO）框架，把用于策略优化的强化学习目标与用于持续知识获取的监督目标结合起来。

3.3.1 内环：元认知策略的强化学习

内环在策略动作上优化智能体的高层策略 $\pi_\theta(a|s_t)$。关键挑战是提供能反映自主成功、潜在失败与专家干预成本之间权衡的学习信号。该问题很适合组相对策略优化（GRPO），它对比每个状态下各动作的相对优势。

奖励设计。 我们使用奖励函数 $R(s_t, a_t)$，把任务正确性与轻量的动作相关成本结合起来。令 $\widehat{y}(a_t)$ 表示在状态 s_t 执行动作 a_t 后得到的输出，$R_{gt}(\widehat{y})$ 表示由所得答案诱导的任务奖励（例如二值正确性信号）。定义

$$R(s_t, a_t) = \begin{cases} R_{gt}(\widehat{y}(a_t)), & a_t = \text{EVAL}, \\ R_{gt}(\widehat{y}(a_t)) - C_{create}, & a_t = \text{CREATE}, \\ R_{gt}(\widehat{y}_{human}(a_t)) - C_{defer}, & a_t = \text{DEFER}, \end{cases}$$

其中 C_{create} 与 C_{defer} 是小的可调惩罚，分别反映内部重生成与外部专家干预的额外成本，且 $C_{defer} > C_{create} \geq 0$。这样，正确性仍是主要训练信号，而成本项鼓励策略在多个选择导致相近好结果时偏好低成本动作。

GRPO 目标。 给定奖励向量 $R_t = [R(s_t, a_1), ..., R(s_t, a_K)]$，通过对奖励中心化计算优势：

$$A(s_t, a_k) = R(s_t, a_k) - \frac{1}{K} \sum_{j=1}^{K} R(s_t, a_j).$$

策略梯度目标为：

$$\mathcal{L}_{PG}(\theta) = -\mathbb{E}_{s_t, a_t \sim \pi_\theta} \left[A(s_t, a_t) \log \pi_\theta(a_t|s_t) \right].$$

两个正则项保证稳定性：KL 惩罚约束偏离参考策略 π_{ref}，熵奖励促进探索。最终内环损失为：

$$\mathcal{L}_{Inner} = \mathcal{L}_{PG} + \beta_{kl}\mathcal{L}_{KL} - \beta_{ent}\mathcal{L}_{Entropy}.$$

3.3.2 外环：从专家反馈中持续学习

内环优化智能体如何使用当前能力，而真正自适应的系统还必须扩展能力。仅靠强化学习无法克服基座 LLM 的知识天花板，因为它改进决策策略，却不引入根本性的新技能。为打破这一天花板，我们引入一个从专家示范中持续学习的外环优化。

该环由 DEFER 动作激活，表示智能体已识别出知识缺口。求助时，智能体从专家处获得高质量示范 $y_{human} = (t_1, ..., t_L)$，并将其转换为监督微调（SFT）样本。训练目标是在给定状态 s_t 的条件下最大化该序列的似然，即最小化交叉熵损失：

$$\mathcal{L}_{SFT}(\theta) = -\sum_{i=1}^{L} \log \pi_\theta(t_i \mid s_t, t_{1:i-1}).$$

在这一设计中，内环 RL 决定何时求助，外环教它从专家输入中学什么。二者共同建立“学徒—导师”动态：智能体策略性地调用人类指导，并系统性地将其吸收为持久能力成长。

3.3.3 最终双环策略优化目标

内外环联合优化，以训练一个既策略娴熟又能持续改进的单一智能体。最终训练目标是内环强化学习信号与外环条件监督信号的原则性组合。总损失 $\mathcal{L}_{total}$ 在一批经验上计算：

$$\mathcal{L}_{total}(\theta) = \mathbb{E}_{(s_t, a_t)} \left[\mathcal{L}_{Inner}(\theta) + \lambda_{sft} \cdot \mathbb{I}(a_t = a_{defer}) \cdot \mathcal{L}_{SFT}(\theta) \right],$$

其中 $\mathcal{L}_{Inner}(\theta)$ 是完整 GRPO 目标，λ_{sft} 是平衡两种学习信号的超参数，$\mathbb{I}(\cdot)$ 是指示函数，确保 SFT 损失仅在采取 DEFER 动作时应用。

4 实验

实验设置。 我们在广泛的基准套件上评估方法，包括通用语言理解（MMLU）、程序合成（HumanEval）与定量数学（GSM8K、AIME、AMC）。遵循相关工作（Liu et al., 2023; Pandya et al., 2024），我们用 GPT-4o-mini 作为人类专家的代理，利用其强推理能力模拟人类干预。详细实验与训练设置见附录 C.1。

总体表现。 表 1 显示，配备 DLPO 的 HILA 框架在所有比较方法中取得最佳总体表现，在所有报告的基准上持续超过强自主多智能体基线。这些基线——包括辩论式（如 LLM-Debate）、基于拓扑（如 DyLAN）与图优化（如 GPTSwarm、AFLOW）方法——仍局限于“封闭世界”协作，其表现受智能体内部知识封顶，在需要非显然推理路径的问题上往往退化。相反，HILA 通过让智能体策略性地获取外部专长，引入“开放世界”动态，直接应对这一天花板。在 Llama3-8B 骨干上，HILA 在每个基准上都相对最强的自主基线取得实质性增益，绝对提升从 3.7 到 15.4 分不等。增益在 AMC、AIME 等竞赛式数学基准上尤其明显，这些任务常因错误前提引发级联失败。通过学习在高不确定性下求助的元认知策略，HILA 避开这些陷阱并有效利用更优指导。这些结果表明，性能增益不仅来自更复杂的交互，更来自外部知识的原则性整合，以及智能体学习到的“何时调用外部知识”的能力。

表 1：使用 LLaMA3-8B 骨干的基线与所提方法比较。 所有数值为百分比（表中省略百分号）。括号内为相对 Vanilla 基线（第一行）的绝对差。下划线数字表示各基准上表现最好的基线。“SA”表示单智能体，“MA”表示多智能体设置。

模型	类型	GSM8K	AMC	AIME	HumanEval	MMLU
Vanilla	SA	72.76 (+0.00)	8.03 (+0.00)	2.96 (+0.00)	47.56 (+0.00)	57.99 (+0.00)
CoT	SA	74.22 (+1.46)	11.65 (+3.62)	3.70 (+0.74)	51.42 (+3.86)	61.57 (+3.58)
SC	SA	80.79 (+8.03)	12.45 (+4.42)	4.07 (+1.11)	57.52 (+9.96)	68.30 (+10.31)
PHP	MA	80.01 (+7.25)	15.66 (+7.63)	4.44 (+1.48)	56.50 (+8.94)	68.46 (+10.47)
Debate	MA	83.52 (+10.76)	19.28 (+11.25)	5.56 (+2.60)	57.72 (+10.16)	67.59 (+9.60)
G-Debate	MA	83.98 (+11.22)	20.48 (+12.45)	5.19 (+2.23)	57.93 (+10.37)	69.89 (+11.90)
DyLAN	MA	82.03 (+9.27)	19.68 (+11.65)	3.70 (+0.74)	61.59 (+14.03)	66.85 (+8.86)
G-Swarm	MA	84.89 (+12.13)	15.66 (+7.63)	5.78 (+2.82)	59.55 (+11.99)	69.67 (+11.68)
A-Prune	MA	84.38 (+11.62)	16.47 (+8.44)	4.81 (+1.85)	57.11 (+9.55)	69.09 (+11.10)
AFlow	MA	83.75 (+10.99)	12.05 (+4.02)	4.44 (+1.48)	62.20 (+14.64)	69.31 (+11.32)
HILA	MA	**89.86 (+17.10)**	**35.83 (+24.47)**	**9.37 (+6.41)**	**72.15 (+24.59)**	**73.62 (+15.63)**

跨骨干泛化。 我们进一步在四个异构 LLM 骨干上评估 HILA，覆盖 Qwen 与 LLaMA 两个家族及多种模型规模。如表 2 所示，HILA 在所有骨干的 GSM8K 上均取得最佳表现，超过单智能体提示基线以及强自主多智能体方法。这表明 HILA 的有效性并不绑定特定模型家族或参数规模，而是能稳健迁移到差异很大的预训练骨干上。此外，增益在更小或更弱的模型上尤其明显，说明当基座模型能力较弱时，HILA 能更有效地弥补有限的

内在推理能力。综合来看，这些结果表明所提框架既对骨干选择具有通用性，也能随模型强度扩展，同时保持自适应协作与策略性人类干预带来的一致收益。

表 2：四个 LLM 骨干上各基线在 GSM8K 的表现。 所有数值为百分比（省略百分号）。括号内为相对各骨干 Vanilla 行的绝对差（百分点）。HILA 指配备 DLPO 的所提方法。

模型	Qwen2.5-7B	Qwen2.5-3B	LLaMA3-8B	LLaMA3-3B
Vanilla	90.71 (+0.00)	83.25 (+0.00)	72.76 (+0.00)	45.26 (+0.00)
CoT	91.13 (+0.42)	84.36 (+1.11)	74.22 (+1.46)	52.49 (+7.23)
SC	91.79 (+1.08)	87.54 (+4.29)	80.79 (+8.03)	58.68 (+13.42)
PHP	91.35 (+0.64)	86.83 (+3.58)	80.01 (+7.25)	66.21 (+20.95)
LLM-Debate	92.47 (+1.76)	87.41 (+4.16)	83.52 (+10.76)	76.32 (+31.06)
DyLAN	92.64 (+1.93)	87.85 (+4.60)	82.03 (+9.27)	76.17 (+30.91)
GPTSwarm	92.83 (+2.12)	86.45 (+3.20)	84.89 (+12.13)	71.85 (+26.59)
AgentPrune	91.76 (+1.05)	86.20 (+2.95)	84.38 (+11.62)	68.71 (+23.45)
AFlow	92.37 (+1.66)	86.78 (+3.53)	83.75 (+10.99)	70.89 (+25.63)
HILA	**94.72 (+4.01)**	**91.17 (+7.92)**	**89.86 (+17.10)**	**83.85 (+38.59)**

不只是更好的干预决策。 为进一步分析 HILA 性能的来源，我们分离策略学习与能力成长的贡献。表 3 在逐步增强的训练机制下比较三个 HILA 变体。从尚未优化的策略到 GRPO，整体变化仅温和，主要收益体现在更可靠的策略控制，而非普遍更高的任务准确率。相反，引入完整 DLPO 目标后，各基准出现明显的第二阶段提升，说明增益不能仅由更好的动作选择解释。这一模式表明：强化学习主要改进“系统何时选择求助”，而外环监督负责把这些求助事件转化为推理能力的持久提升。

表 3：HILA 在逐步增强训练机制下的表现。 Init Policy 表示未优化系统，GRPO 仅应用内环策略优化，DLPO 增加来自专家示范的外环更新。结果表明完整双环目标带来最强总体表现。

模型	GSM8K	AMC	MMLU
HILA（初始策略）	88.15	33.33	68.30
HILA + GRPO	88.38	32.50	70.47
HILA + DLPO	89.86	35.83	73.62

表 4 进一步验证这一解释：用 DLPO 训练后更新的骨干评估标准推理流水线。在单智能体提示与自主多智能体基线上，把原骨干替换为 DLPO 更新后的骨干，均能持续提升表现，说明收益可迁移到 HILA 交互协议之外。值得注意的是，即使下游方法在推理时不使用策略性求助，增益仍然出现。这表明训练中收集的专家示范不仅帮助 HILA 做出更好的局部决策，也提升了底层 LLM 的一般推理能力。综合来看，这些结果表明 HILA 的增益来自两个互补来源：更好的干预元认知策略，以及强化骨干模型本身的持续学习。

表 4：DLPO 更新后骨干的可迁移性。 Base 表示原始 LLaMA3-8B 骨干，DLPO 表示经过 DLPO 训练后的同一骨干。对每个推理框架，测试时协议保持不变，仅替换骨干。所有数值为百分比。

模型	GSM8K	AMC	MMLU
Vanilla（Base）	72.76	8.03	57.99

模型	GSM8K	AMC	MMLU
Vanilla（DLPO）	82.11	10.84	61.58
DyLAN（Base）	82.03	19.68	66.85
DyLAN（DLPO）	88.32	25.30	68.72
Debate（Base）	83.52	19.28	67.59
Debate（DLPO）	88.93	21.69	69.57

训练各阶段的策略分布。 为更好理解训练如何改变 HILA 的协作行为，我们考察三种策略动作（EVAL、CREATE、DEFER）在不同训练阶段的分布。表 5 显示出清晰且可解释的趋势。从尚未优化的策略开始，HILA 把相当比例的决定分配给 DEFER，表明在学会校准的元认知策略之前，系统对干预算依赖很大。应用 GRPO 后，DEFER 占比在各数据集上持续下降，EVAL 与 CREATE 略微更频繁。这一趋势表明，内环策略优化学到了更具成本意识的干预策略。由于求助带有显式惩罚，智能体对调用外部专长更加挑剔，并更好地利用自主替代方案。

完整 DLPO 训练后，效果更加明显。与初始化阶段和仅 GRPO 相比，DEFER 在所有基准上大幅下降，EVAL 显著上升。这一转变表明，智能体不仅在启发式地回避昂贵的求助，而是在多智能体系统内部变得更有能力解决问题。由于 DLPO 把内环策略优化与专家示范的持续学习结合起来，求助率下降进一步说明这些示范提升了模型的底层推理能力。随着骨干变强，系统更少依赖外部帮助，更常利用或改进内部可用解答。这些结果表明：GRPO 改进“何时提问”，而 DLPO 进一步改进“是否还需要提问”。

表 5：各训练阶段策略动作的分布。 随着训练推进，DEFER 比例持续下降，EVAL 变得更主导，表明元认知控制改善、对外部干预的依赖降低。

模型	GSM8K EVAL	GSM8K CREATE	GSM8K DEFER	AMC EVAL	AMC CREATE	AMC DEFER	MMLU EVAL	MMLU CREATE	MMLU DEFER
HILA（初始策略）	36%	35%	29%	36%	40%	24%	47%	34%	19%
HILA + GRPO	38%	36%	26%	40%	40%	20%	48%	37%	15%
HILA + DLPO	55%	28%	17%	64%	24%	12%	74%	21%	5%

人类代理能力的影响。 我们进一步用三种不同能力的语言模型——gpt-3.5-turbo、gpt-4o-mini 与 gpt-4o——实例化人类代理，研究外部专家强度如何影响 HILA 的有效性。如图 2 与表 6 所示，更强的代理在所有基准上都带来更好的总体表现。这一排序在 GSM8K、AMC 与 MMLU 上稳定：gpt-3.5-turbo 最弱，gpt-4o-mini 明显提升，gpt-4o 最佳。该趋势与 DEFER 在 HILA 中的角色一致：它正是为了在自主多智能体系统达到极限时引入

更高质量推理。因此，结果表明 HILA 不仅依赖“学会何时求助”，也依赖“向谁求助”。策略性干预与专家质量互补：更强的元认知策略能识别何时需要外部帮助，而最终收益仍取决于所返回指导的信息量与可靠性。

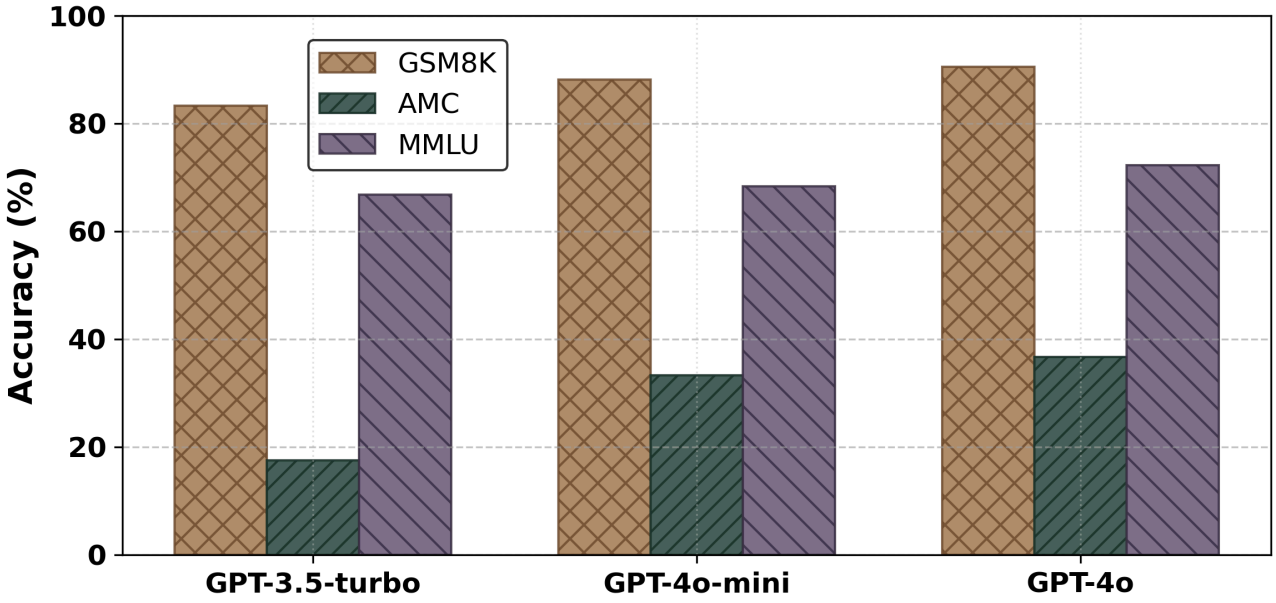


图 2：人类代理能力对 HILA 的影响。使用更强的语言模型作为外部专家，在 GSM8K、AMC 与 MMLU 上持续提升表现。

表 6：人类代理能力对 HILA 的影响。 使用更强的语言模型作为外部专家，在 GSM8K、AMC 与 MMLU 上持续提升表现，说明外部指导质量是策略性求助有效性的重要因素。

模型	GSM8K	AMC	MMLU
HILA + gpt-4o-mini	88.15	33.33	68.30
HILA + gpt-3.5-turbo	83.33	17.50	66.84
HILA + gpt-4o	89.76	36.67	72.28

集体探索的价值。 为考察集体规模如何影响有效性与成本，我们在 AMC 与 MMLU 上评估不同自主智能体数量的 HILA，如图 3(a) 所示，完整结果见附录 C.2 表 7 与表 8。在两个基准上，增加智能体数量总体提升准确率，最明显的增益出现在从极小集体增加到中等规模时。这一趋势支持 HILA 的核心直觉：更大的智能体池带来更丰富的集体探索，使系统生成更广泛的候选推理轨迹，提高识别并传播强解的概率。然而增益并非线性。随着集体继续扩大，改进变小且更不稳定，表明一旦解空间已充分多样化，收益递减。相反，计算成本随智能体数量急剧上升，因为更广泛的参与使输入与输出 token 都大幅增加。这些结果凸显一个实际权衡：更大的集体可通过更广探索增强推理，但必须与上升的推理成本平衡，因此智能体数量是 HILA 中的重要平衡选择。

迭代协作的最优深度。 为评估迭代改进的作用，我们改变协作轮数并在 AMC 与 MMLU 上评估 HILA，如图 3(b) 所示，完整结果见附录 C.2 表 9 与表 10。在两个基准上，效果都呈现清晰的非单调模式。从较浅交互深度增加到中等深度，准确率持续提升，表明多轮协作帮助系统改进中间解答、吸收同伴反馈并纠正先前错误。这支持“迭代交互通过让智能体逐步修订并巩固候选解来增强推理”的直觉，而非依赖单轮交换。然而收益不会无限持续。表现在中等等深度达到峰值，随后随着交互进一步延长而略有下降，尽管 token 使用仍在上升。这

表明额外轮次起初创造了有用的纠错机会，但过度交互导致收益递减，并可能开始强化次优轨迹。这些结果表明迭代协作有价值但并非无界，轮数选择应平衡改进收益与上升的计算成本。

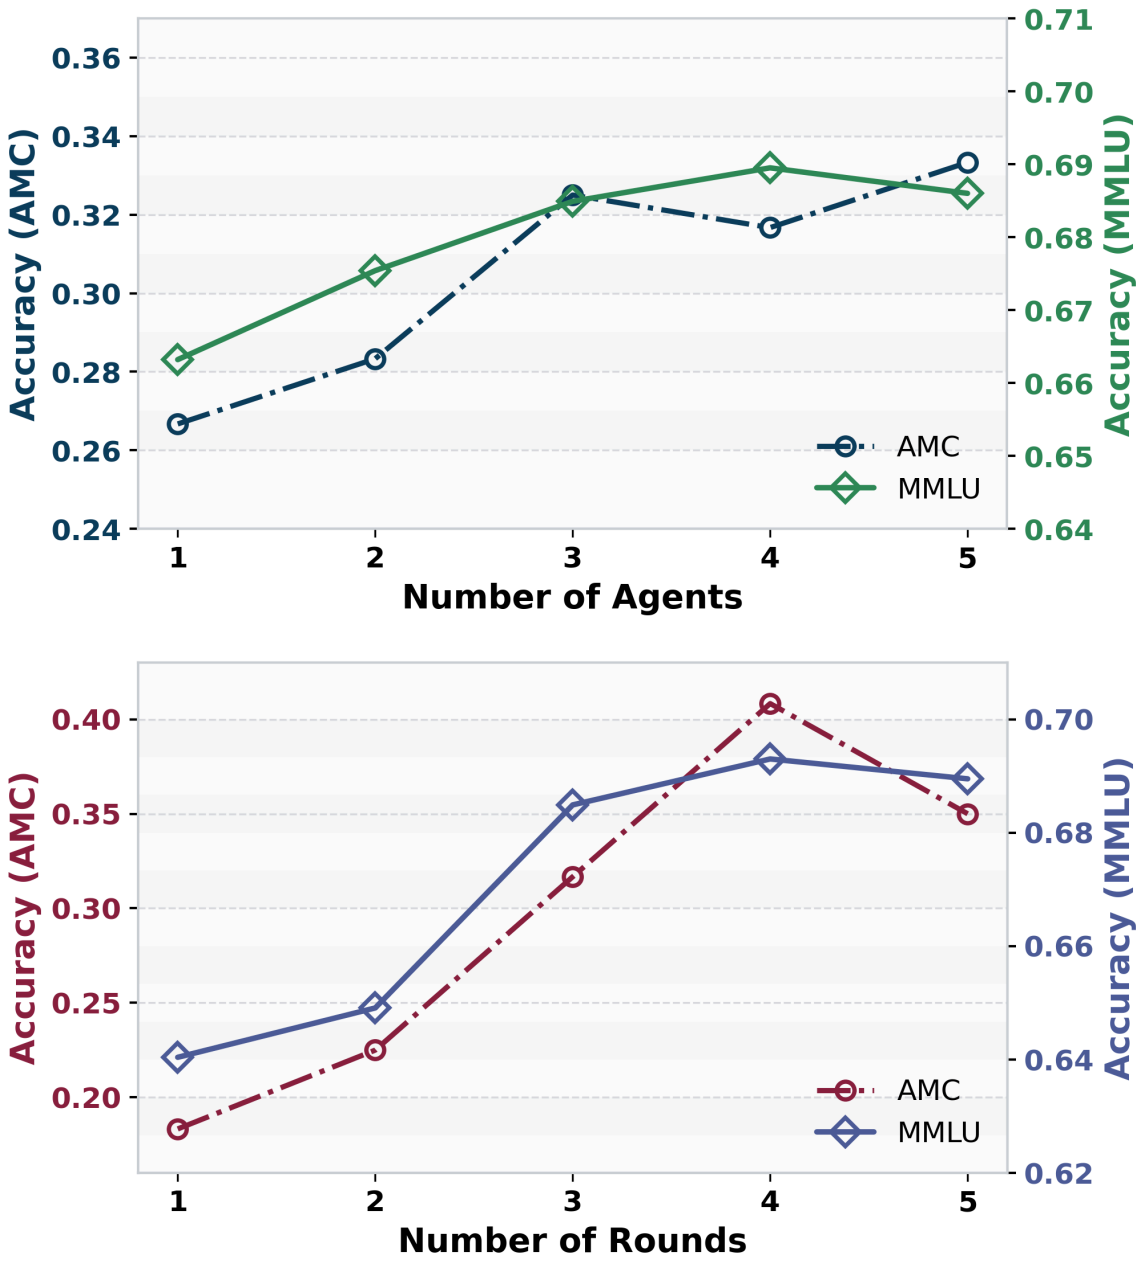


图 3：协作配置规模化的效果。(a) 增加智能体数量对 AMC 与 GSM8K 准确率的影响；(b) 改变交互轮数对表现的影响。结果凸显“更多智能体带来更广探索”与“更多轮次带来更深改进”之间的权衡。

5 结论

本文提出 HILA，一个为多智能体系统配备元认知策略的框架，用于决定何时自主行动、何时求助外部专长。通过双环策略优化——把基于 GRPO 的干预控制与专家示范的持续学习结合起来——HILA 同时实现自适应决策与长期能力提升。在多样且困难的推理基准上的大量实验表明，HILA 持续优于强自主与多智能体基线。未来工作将研究更动态的协作机制，并进一步增强多智能体系统的演化能力。

致谢

本工作部分得到美国国防部 Cooperative Agreement Number W911NF-24-2-0133 的支持。本文观点与结论属于作者，不应被解释为美国陆军研究办公室或美国政府的官方政策（无论明示或暗示）。美国政府有权为政府目的复制与分发重印本，不受本文版权标注限制。

参考文献

Sahar Abdelnabi, Amr Gomaa, Sarath Sivaprasad, Lea Sch¨onherr, and Mario Fritz. Cooperation, competition, and maliciousness: Llm-stakeholders interactive negotiation. Advances in Neural Information Processing Systems, 37:83548–83599, 2024. Shayan Meshkat Alsadat and Zhe Xu. Multi-agent reinforcement learning in non-cooperative stochastic games using large language models. IEEE Control Systems Letters, 2024. Janis A Cannon-Bowers, Eduardo Salas, and Sharolyn Converse. Shared mental models in expert team decision making. 1993.

Defu Cao, Michael Gee, Jinbo Liu, Hengxuan Wang, Wei Yang, Rui Wang, and Yan Liu. Con-versational time series foundation models: Towards explainable and effective forecasting. arXiv preprint arXiv:2512.16022, 2025.

Chi-Min Chan, Weize Chen, Yusheng Su, Jianxuan Yu, Wei Xue, Shanghang Zhang, Jie Fu, and Zhiyuan Liu. Chateval: Towards better llm-based evaluators through multi-agent debate. arXiv preprint arXiv:2308.07201, 2023.

Ching Chang, Yidan Shi, Defu Cao, Wei Yang, Jeehyun Hwang, Haixin Wang, Jiacheng Pang, Wei Wang, Yan Liu, Wen-Chih Peng, et al. A survey of reasoning and agentic systems in time series with large language models. arXiv preprint arXiv:2509.11575, 2025.

Guangyao Chen, Siwei Dong, Yu Shu, Ge Zhang, Jaward Sesay, B¨orje F Karlsson, Jie Fu, and Yemin Shi. Autoagents: A framework for automatic agent generation. arXiv preprint arXiv:2309.17288, 2023a.

Jiaju Chen, Yuxuan Lu, Xiaojie Wang, Huimin Zeng, Jing Huang, Jiri Gesi, Ying Xu, Bingsheng Yao, and Dakuo Wang. Multi-agent-as-judge: Aligning llm-agent-based automated evaluation with multi-dimensional human evaluation. arXiv preprint arXiv:2507.21028, 2025a.

Junzhe Chen, Xuming Hu, Shuodi Liu, Shiyu Huang, Wei-Wei Tu, Zhaofeng He, and Lijie Wen. Llmarena: Assessing capabilities of large language models in dynamic multi-agent environments. arXiv preprint arXiv:2402.16499, 2024a.

Shuhao Chen, Weisen Jiang, Baijiong Lin, James Kwok, and Yu Zhang. Routerdc: Query-based router by dual contrastive learning for assembling large language models. Advances in Neural Information Processing Systems, 37:66305–66328, 2024b.

Weize Chen, Yusheng Su, Jingwei Zuo, Cheng Yang, Chenfei Yuan, Chen Qian, Chi-Min Chan, Yujia Qin, Yaxi Lu, Ruobing Xie, et al. Agentverse: Facilitating multi-agent collaboration and exploring emergent behaviors in agents. arXiv preprint arXiv:2308.10848, 2(4):6, 2023b.

Yiqun Chen, Qi Liu, Yi Zhang, Weiwei Sun, Xinyu Ma, Wei Yang, Daiting Shi, Jiaxin Mao, and Dawei Yin. Tourrank: Utilizing large language models for documents ranking with a tournament-inspired strategy. In Proceedings of the ACM on Web Conference 2025, pp. 1638–1652, 2025b.

Yiqun Chen, Jinyuan Feng, Wei Yang, Meizhi Zhong, Zhengliang Shi, Rui Li, Xiaochi Wei, Yan Gao, Yi Wu, Yao Hu, et al. Self-compression of chain-of-thought via multi-agent reinforcement learning. arXiv preprint arXiv:2601.21919, 2026.

Yilun Du, Shuang Li, Antonio Torralba, Joshua B Tenenbaum, and Igor Mordatch. Improving fac-tuality and reasoning in language models through multiagent debate. In Forty-first International Conference on Machine Learning, 2023. John Dunlosky and Janet Metcalfe. Metacognition.

Sage Publications, 2008.

Xueyang Feng, Zhi-Yuan Chen, Yujia Qin, Yankai Lin, Xu Chen, Zhiyuan Liu, and Ji-Rong Wen. Large language model-based human-agent collaboration for complex task solving. arXiv preprint arXiv:2402.12914, 2024. Adrian Garret Gabriel, Alaa Alameer Ahmad, and Shankar Kumar Jeyakumar. Advancing agentic systems: Dynamic task decomposition, tool integration and evaluation using novel metrics and dataset. arXiv preprint arXiv:2410.22457, 2024.

Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, et al. The llama 3 herd of models. arXiv preprint arXiv:2407.21783, 2024.

Suzie Grondin, Arthur Charpentier, and Philipp Ratz. Beyond human intervention: Algorithmic collusion through multi-agent learning strategies. arXiv preprint arXiv:2501.16935, 2025.

Ai Han, Junxing Hu, Pu Wei, Zhiqian Zhang, Yuhang Guo, Jiawei Lu, and Zicheng Zhang. Joyagents-r1: Joint evolution dynamics for versatile multi-llm agents with reinforcement learning. arXiv preprint arXiv:2506.19846, 2025.

Sirui Hong, Mingchen Zhuge, Jonathan Chen, Xiawu Zheng, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, et al. Metagpt: Meta programming for a multi-agent collaborative framework. In The Twelfth International Conference on Learning Representations, 2023.

Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. arXiv preprint arXiv:2408.08435, 2024.

Ziqi Jia, Junjie Li, Xiaoyang Qu, and Jianzong Wang. Enhancing multi-agent systems via reinforce-ment learning with llm-based planner and graph-based policy. arXiv preprint arXiv:2503.10049, 2025.

Dongfu Jiang, Xiang Ren, and Bill Yuchen Lin. Llm-blender: Ensembling large language models with pairwise ranking and generative fusion. arXiv preprint arXiv:2306.02561, 2023.

Zhouyang Jiang, Bin Zhang, Airong Wei, and Zhiwei Xu. Qllm: Do we really need a mixing network for credit assignment in multi-agent reinforcement learning? arXiv preprint arXiv:2504.12961, 2025. John T Jost, Arie W Kruglanski, and Thomas O Nelson. Social metacognition: An expansionist review.

In Metacognition, pp. 137–154.

Psychology Press, 2013.

Zachary Kenton, Noah Siegel, J´anos Kram´ar, Jonah Brown-Cohen, Samuel Albanie, Jannis Bulian, Rishabh Agarwal, David Lindner, Yunhao Tang, Noah Goodman, et al. On scalable oversight with weak llms judging strong llms. Advances in Neural Information Processing Systems, 37: 75229–75276, 2024.

Boyi Li, Zhonghan Zhao, Der-Horng Lee, and Gaoang Wang. Adaptive graph pruning for multi-agent communication. arXiv preprint arXiv:2506.02951, 2025a.

Dapeng Li, Hang Dong, Lu Wang, Bo Qiao, Si Qin, Qingwei Lin, Dongmei Zhang, Qi Zhang, Zhiwei Xu, Bin Zhang, et al. Verco: Learning coordinated verbal communication for multi-agent reinforcement learning. arXiv preprint arXiv:2404.17780, 2024a.

Huao Li, Hossein Nourkhiz Mahjoub, Behdad Chalaki, Vaishnav Tadiparthi, Kwonjoon Lee, Ehsan Moradi Pari, Charles Lewis, and Katia Sycara. Language grounded multi-agent reinforcement learning with human-interpretable communication. Advances in Neural Information Processing Systems, 37:87908–87933, 2024b.

Jiate Li, Defu Cao, Li Li, Wei Yang, Yuehan Qin, Chenxiao Yu, Tiannuo Yang, Ryan A Rossi, Yan Liu, Xiyang Hu, et al. ” someone hid it”: Query-agnostic black-box attacks on llm-based retrieval. arXiv preprint arXiv:2602.00364, 2026.

Shixuan Li, Wei Yang, Peiyu Zhang, Xiongye Xiao, Defu Cao, Yuehan Qin, Xiaole Zhang, Yue Zhao, and Paul Bogdan. Climatellm: Efficient weather forecasting via frequency-aware large language models. arXiv preprint arXiv:2502.11059, 2025b. Yuxi Li. Reinforcement learning applications. arXiv preprint arXiv:1908.06973, 2019.

Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Shuming Shi, and Zhaopeng Tu. Encouraging divergent thinking in large language models through multi-agent debate. arXiv preprint arXiv:2305.19118, 2023.

Muhan Lin, Shuyang Shi, Yue Guo, Vaishnav Tadiparthi, Behdad Chalaki, Ehsan Moradi Pari, Si-mon Stepputtis, Woojun Kim, Joseph Campbell, and Katia Sycara. Speaking the language of teamwork: Llm-guided credit assignment in multi-agent reinforcement learning. arXiv preprint arXiv:2502.03723, 2025.

Jijia Liu, Chao Yu, Jiaxuan Gao, Yuqing Xie, Qingmin Liao, Yi Wu, and Yu Wang. Llm-powered hi-erarchical language agent for real-time human-ai coordination. arXiv preprint arXiv:2312.15224, 2023.

Tongxuan Liu, Xingyu Wang, Weizhe Huang, Wenjiang Xu, Yuting Zeng, Lei Jiang, Hailong Yang, and Jing Li. Groupdebate: Enhancing the efficiency of multi-agent debate using group discussion. arXiv preprint arXiv:2409.14051, 2024.

Jianqiao Lu, Wanjun Zhong, Wenyong Huang, Yufei Wang, Fei Mi, Baojun Wang, Weichao Wang, Lifeng Shang, and Qun Liu. Self: Language-driven self-evolution for large language model. 2023.

Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, et al. Self-refine: Iterative refinement with self-feedback. Advances in Neural Information Processing Systems, 36:46534–46594, 2023.

Hussein Mozannar, Gagan Bansal, Cheng Tan, Adam Fourney, Victor Dibia, Jingya Chen, Jack Ger-rits, Tyler Payne, Matheus Kunzler Maldaner, Madeleine Grunde-McLaughlin, et al. Magentic-ui: Towards human-in-the-loop agentic systems. arXiv preprint arXiv:2507.22358, 2025.

Chunjiang Mu, Hao Guo, Yang Chen, Chen Shen, Die Hu, Shuyue Hu, and Zhen Wang. Multi-agent, human–agent and beyond: a survey on cooperation in social dilemmas. Neurocomputing, 610:128514, 2024.

Gabriel Mukobi, Hannah Erlebach, Niklas Lauffer, Lewis Hammond, Alan Chan, and Jesse Clifton. Welfare diplomacy: Benchmarking language model cooperation. arXiv preprint arXiv:2310.08901, 2023. Thomas O Nelson and Louis Narens. Why investigate metacognition. Metacognition: Knowing about knowing, 13:1–25, 1994.

Xuefei Ning, Zinan Lin, Zixuan Zhou, Zifu Wang, Huazhong Yang, and Yu Wang. Skeleton-of-thought: Prompting llms for efficient parallel generation. arXiv preprint arXiv:2307.15337, 2023.

Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E Gonzalez, M Waleed Kadous, and Ion Stoica. Routellm: Learning to route llms with preference data. arXiv preprint arXiv:2406.18665, 2024.

Bo Pan, Jiaying Lu, Ke Wang, Li Zheng, Zhen Wen, Yingchaojie Feng, Minfeng Zhu, and Wei Chen. Agentcoord: Visually exploring coordination strategy for llm-based multi-agent collaboration. arXiv preprint arXiv:2404.11943, 2024.

Ravi Pandya, Michelle Zhao, Changliu Liu, Reid Simmons, and Henny Admoni. Multi-agent strategy explanations for human-robot collaboration. In 2024 IEEE International Conference on Robotics and Automation (ICRA), pp. 17351–17357. IEEE, 2024.

Chanwoo Park, Seungju Han, Xingzhi Guo, Asuman Ozdaglar, Kaiqing Zhang, and Joo-Kyung Kim. Maporl: Multi-agent post-co-training for collaborative large language models with reinforcement learning. arXiv preprint arXiv:2502.18439, 2025.

Feng Peiyuan, Yichen He, Guanhua Huang, Yuan Lin, Hanchong Zhang, Yuchen Zhang, and Hang Li. Agile: A novel reinforcement learning framework of llm agents. Advances in Neural Infor-mation Processing Systems, 37:5244–5284, 2024.

Heng Ping, Arijit Bhattacharjee, Peiyu Zhang, Shixuan Li, Wei Yang, Anzhe Cheng, Xiaole Zhang, Jesse Thomason, Ali Jannesari, Nesreen Ahmed, et al. Verimoa: A mixture-of-agents framework for spec-to-hdl generation. arXiv preprint arXiv:2510.27617, 2025a.

Heng Ping, Shixuan Li, Peiyu Zhang, Anzhe Cheng, Shukai Duan, Nikos Kanakaris, Xiongye Xiao, Wei Yang, Shahin Nazarian, Andrei Irimia, et al. Hdlcore: A training-free framework for mitigat-ing hallucinations in llm-generated hdl. arXiv preprint arXiv:2503.16528, 2025b.

Chen Qian, Zihao Xie, Yifei Wang, Wei Liu, Kunlun Zhu, Hanchen Xia, Yufan Dang, Zhuoyun Du, Weize Chen, Cheng Yang, et al. Scaling large language model-based multi-agent collaboration. arXiv preprint arXiv:2406.07155, 2024.

Shuofei Qiao, Ningyu Zhang, Runnan Fang, Yujie Luo, Wangchunshu Zhou, Yuchen Eleanor Jiang, Chengfei Lv, and Huajun Chen. Autoact: Automatic agent learning from scratch for qa via self-planning. arXiv preprint arXiv:2401.05268, 2024. Evan F Risko and Sam J Gilbert. Cognitive offloading. Trends in cognitive sciences, 20(9):676–688, 2016.

Yu Shang, Yu Li, Keyu Zhao, Likai Ma, Jiahe Liu, Fengli Xu, and Yong Li. Agentsquare: Automatic llm agent search in modular design space. arXiv preprint arXiv:2410.06153, 2024. Philipp D Siedler and Ian Gemp. Llm-mediated guidance of marl systems. arXiv preprint arXiv:2503.13553, 2025.

KV Srivatsa, Kaushal Kumar Maurya, and Ekaterina Kochmar. Harnessing the power of multiple minds: Lessons learned from llm routing. arXiv preprint arXiv:2405.00467, 2024.

Chuanneng Sun, Songjun Huang, and Dario Pompili. Llm-based multi-agent decision-making: Challenges and future directions. IEEE Robotics and Automation Letters, 2025. Mirac Suzgun and Adam Tauman Kalai. Meta-prompting: Enhancing language models with task-agnostic scaffolding. arXiv preprint arXiv:2401.12954, 2024.

Wannita Takerngsaksiri, Jirat Pasuksmit, Patanamon Thongtanunam, Chakkrit Tantithamthavorn, Ruixiong Zhang, Fan Jiang, Jing Li, Evan Cook, Kun Chen, and Ming Wu. Human-in-the-loop software development agents. In 2025 IEEE/ACM 47th International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP), pp. 342–352. IEEE, 2025. Yashar Talebirad and Amirhossein Nadiri. Multi-agent collaboration: Harnessing the power of intelligent llm agents. arXiv preprint arXiv:2306.03314, 2023. Qwen Team. Qwen2 technical report. arXiv preprint arXiv:2407.10671, 2024. Haley Triem and Ying Ding. “tipping the balance”: Human intervention in large language model multi-agent debate. Proceedings of the Association for Information Science and Technology, 61 (1):361–373, 2024.

Ziyu Wan, Yunxiang Li, Xiaoyu Wen, Yan Song, Hanjing Wang, Linyi Yang, Mark Schmidt, Jun Wang, Weinan Zhang, Shuyue Hu, et al. Rema: Learning to meta-think for llms with multi-agent reinforcement learning. arXiv preprint arXiv:2503.09501, 2025.

Shenzhi Wang, Chang Liu, Zilong Zheng, Siyuan Qi, Shuo Chen, Qisen Yang, Andrew Zhao, Chaofei Wang, Shiji Song, and Gao Huang. Avalon’s game of thoughts: Battle against decep-tion through recursive contemplation. arXiv preprint arXiv:2310.01320, 2023a.

Xuejiao Wang, Guoqing Zhi, Zhihao Tang, Hao Jin, Qianyue Zhang, and Nan Li. Self-aware in-telligent medical rescue unmanned team via large language model and multi-agent reinforcement learning. In Proceedings of the 2024 International Symposium on AI and Cybersecurity, pp. 119–124, 2024.

Zhenhailong Wang, Shaoguang Mao, Wenshan Wu, Tao Ge, Furu Wei, and Heng Ji. Unleashing the emergent cognitive synergy in large language models: A task-solving agent through multi-persona self-collaboration. arXiv preprint arXiv:2307.05300, 2023b.

Zihan Wang, Kangrui Wang, Qineng Wang, Pingyue Zhang, Linjie Li, Zhengyuan Yang, Xing Jin, Kefan Yu, Minh Nhat Nguyen, Licheng Liu, et al. Ragen: Understanding self-evolution in llm agents via multi-turn reinforcement learning. arXiv preprint arXiv:2504.20073, 2025a.

Ziyan Wang, Zhicheng Zhang, Fei Fang, and Yali Du. M3hf: Multi-agent reinforcement learning from multi-phase human feedback of mixed quality. arXiv preprint arXiv:2503.02077, 2025b.

Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, and Quoc V Le. Finetuned language models are zero-shot learners. arXiv preprint arXiv:2109.01652, 2021.

Yuan Wei, Xiaohan Shan, and Jianmin Li. Lero: Llm-driven evolutionary framework with hy-brid rewards and enhanced observation for multi-agent reinforcement learning. arXiv preprint arXiv:2503.21807, 2025.

Muyan Weng, Defu Cao, Wei Yang, Yashaswi Sharma, and Yan Liu. Temporalbench: A benchmark for evaluating llm-based agents on contextual and event-informed time series tasks. arXiv preprint arXiv:2602.13272, 2026.

Yu Xia, Rui Zhong, Hao Gu, Wei Yang, Chi Lu, Peng Jiang, and Kun Gai. Hierarchical tree search-based user lifelong behavior modeling on large language model. In Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 1758–1767, 2025a.

Yu Xia, Rui Zhong, Zeyu Song, Wei Yang, Junchen Wan, Qingpeng Cai, Chi Lu, and Peng Jiang. Trackrec: Iterative alternating feedback with chain-of-thought via preference alignment for rec-ommendation. arXiv preprint arXiv:2508.15388, 2025b.

Kai Xiong, Xiao Ding, Yixin Cao, Ting Liu, and Bing Qin. Examining inter-consistency of large lan-guage models collaboration: An in-depth analysis via debate. arXiv preprint arXiv:2305.11595, 2023.

Yanggang Xu, Weijie Hong, Jirong Zha, Geng Chen, Jianfeng Zheng, Chen-Chun Hsia, and Xin-lei Chen. Scalable uav multi-hop networking via multi-agent reinforcement learning with large language models. arXiv preprint arXiv:2505.08448, 2025. Wei Yang and Jesse Thomason. Learning to deliberate: Meta-policy collaboration for agentic llms with multi-agent reinforcement learning. arXiv preprint arXiv:2509.03817, 2025.

Wei Yang, Jiacheng Pang, Shixuan Li, Paul Bogdan, Stephen Tu, and Jesse Thomason. Maestro: Learning to collaborate via conditional listwise policy optimization for multi-agent llms. arXiv preprint arXiv:2511.06134, 2025a.

Wei Yang, Muyan Weng, Jiacheng Pang, Defu Cao, Heng Ping, Peiyu Zhang, Shixuan Li, Yue Zhao, Qiang Yang, Mengdi Wang, et al. Toward evolutionary intelligence: Llm-based agentic systems with multi-agent reinforcement learning. Available at SSRN 5819182, 2025b.

Wei Yang, Shixuan Li, Heng Ping, Peiyu Zhang, Paul Bogdan, and Jesse Thomason. Auditing multi-agent llm reasoning trees outperforms majority vote and llm-as-judge. arXiv preprint arXiv:2602.09341, 2026.

Wen Ye, Wei Yang, Defu Cao, Yizhou Zhang, Lumingyuan Tang, Jie Cai, and Yan Liu. Domain-oriented time series inference agents for reasoning and automated analysis. arXiv preprint arXiv:2410.04047, 2024.

Zhangyue Yin, Qiushi Sun, Cheng Chang, Qipeng Guo, Junqi Dai, Xuanjing Huang, and Xipeng Qiu. Exchange-of-thought: Enhancing large language model capabilities through cross-model communication. arXiv preprint arXiv:2312.01823, 2023.

Yanwei Yue, Guibin Zhang, Boyang Liu, Guancheng Wan, Kun Wang, Dawei Cheng, and Yiyan Qi. Masrouter: Learning to route llms for multi-agent systems. arXiv preprint arXiv:2502.11133, 2025.

Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah Goodman. Star: Bootstrapping reasoning with reasoning. Advances in Neural Information Processing Systems, 35:15476–15488, 2022.

Ceyao Zhang, Kaijie Yang, Siyi Hu, Zihao Wang, Guanghe Li, Yihang Sun, Cheng Zhang, Zhaowei Zhang, Anji Liu, Song-Chun Zhu, et al. Proagent: building proactive cooperative agents with large language models. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pp. 17591–17599, 2024a.

Guibin Zhang, Yanwei Yue, Zhixun Li, Sukwon Yun, Guancheng Wan, Kun Wang, Dawei Cheng, Jeffrey Xu Yu, and Tianlong Chen. Cut the crap: An economical communication pipeline for llm-based multi-agent systems. arXiv preprint arXiv:2410.02506, 2024b.

Jiayi Zhang, Jinyu Xiang, Zhaoyang Yu, Fengwei Teng, Xionghui Chen, Jiaqi Chen, Mingchen Zhuge, Xin Cheng, Sirui Hong, Jinlin Wang, et al. Aflow: Automating agentic workflow genera-tion. arXiv preprint arXiv:2410.10762, 2024c.

Jintian Zhang, Xin Xu, Ningyu Zhang, Ruibo Liu, Bryan Hooi, and Shumin Deng. Exploring collab-oration mechanisms for llm agents: A social psychology view. arXiv preprint arXiv:2310.02124, 2023.

Kaiqing Zhang, Zhuoran Yang, and Tamer Bas¸ar. Multi-agent reinforcement learning: A selective overview of theories and algorithms. Handbook of reinforcement learning and control, pp. 321– 384, 2021.

Xuan Zhang, Yang Deng, Zifeng Ren, See-Kiong Ng, and Tat-Seng Chua. Ask-before-plan: Proac-tive language agents for real-world planning. arXiv preprint arXiv:2406.12639, 2024d.

Yang Zhang, Shixin Yang, Chenjia Bai, Fei Wu, Xiu Li, Zhen Wang, and Xuelong Li. Towards efficient llm grounding for embodied multi-agent collaboration. arXiv preprint arXiv:2405.14314, 2024e.

Heng Zhou, Hejia Geng, Xiangyuan Xue, Li Kang, Yiran Qin, Zhiyong Wang, Zhenfei Yin, and Lei Bai. Reso: A reward-driven self-organizing llm-based multi-agent system for reasoning tasks. arXiv preprint arXiv:2503.02390, 2025.

Guobin Zhu, Rui Zhou, Wenkang Ji, and Shiyu Zhao. Lamarl: Llm-aided multi-agent reinforcement learning for cooperative policy generation. IEEE Robotics and Automation Letters, 2025.

Yuan Zhuang, Yi Shen, Zhili Zhang, Yuxiao Chen, and Fei Miao. Yolo-marl: You only llm once for multi-agent reinforcement learning. arXiv preprint arXiv:2410.03997, 2024.

Mingchen Zhuge, Wenyi Wang, Louis Kirsch, Francesco Faccio, Dmitrii Khizbullin, and J¨urgen Schmidhuber. Gptswarm: Language agents as optimizable graphs. In Forty-first International Conference on Machine Learning, 2024. Henry Peng Zou, Wei-Chieh Huang, Yaozu Wu, Yankai Chen, Chunyu Miao, Hoang Nguyen, Yue Zhou, Weizhi Zhang, Liancheng Fang, Langzhou He, et al. Llm-based human-agent collaboration and interaction systems: A survey. 16

附录

A 相关工作

A.1 多智能体 LLM 系统中的协作范式

早期研究表明，单个 LLM 智能体在上下文长度、顺序生成与技能广度上存在固有局限，制约其解决需要多样视角或并行推理的复杂任务（Gabriel et al., 2024; Liang et al., 2023; Xiong et al., 2023; Yin et al., 2023; Zhang et al., 2023）。为克服这些瓶颈，近期工作探索多智能体系统（MAS），在软件工程、规划与问题求解等领域编排多个 LLM 以实现集体智能（Hong et al., 2023; Chen et al., 2023b; Xia et al., 2025b; Ning et al., 2023; Li et al., 2026; Pan et al., 2024; Suzgun & Kalai, 2024; Chen et al., 2023a; Weng et al., 2026）。

多数现有框架依赖基于提示词的范式，预定义角色、通信协议或工作流结构。这些设计实现辩论、批评与企业式流水线，在协调效率上取得显著收益（Du et al., 2023; Chan et al., 2023; Cao et al., 2025; Mukobi et al., 2023;

Wang et al., 2023a; Abdelnabi et al., 2024; Han et al., 2025）。然而由于它们是手工构造的、不能通过经验适应，这类系统本质上仍是封闭世界：只能重组已有知识，无法获得真正的新能力（Wang et al., 2023b; Liu et al., 2024; Chen et al., 2024b）。

在固定提示词之外，还出现了两个方向。预结构化协调采用固定的辩论或同行评审拓扑，如链、树或图，以精炼推理（Du et al., 2023; Liu et al., 2024; Qian et al., 2024）。相反，自组织方法通过搜索、剪枝、路由或演化机制动态调整交互图（Hu et al., 2024; Shang et al., 2024; Zhang et al., 2024b; Zhuge et al., 2024; Zhang et al., 2024c; Yue et al., 2025）。这些进展凸显"谁在何时通信"的重要性，但它们主要优化内部协调，未解决从外部专长中学习的问题。

相反，我们的工作引入一个集中式、迭代式协作框架，明确把人类专长作为开放世界资源纳入。我们不把人反馈当作被动神谕或一次性纠正（Takerngsaksiri et al., 2025; Mozannar et al., 2025; Liu et al., 2023; Pandya et al., 2024），而是赋予智能体元认知策略，同时管辖求助时机与把人类指导吸收为持久改进。该方法与先前的辩论、路由与工作流搜索系统有根本区别，后者往往缺乏推理与决策结果之间的原则性信用分配（Chan et al., 2023; Talebirad & Nadiri, 2023; Wei et al., 2025）。通过把外部知识与学习到的元认知适应结合起来，我们的框架超越静态协作，为自适应、持续改进的多智能体智能开辟道路。

A.2 面向 LLM 的多智能体强化学习

越来越多工作试图超越静态提示工程，为多智能体 LLM 系统赋予自适应学习能力。早期努力依赖监督微调（SFT），通过模仿专家示范或精选轨迹注入协作模式（Lu et al., 2023; Madaan et al., 2023; Zelikman et al., 2022; Wei et al., 2021）。虽然对播种合作行为有效，SFT 受离线性质限制，无法适应新情境。强化学习（RL）因此成为自然补充，使智能体通过试错交互与奖励驱动适应来改进策略（Zhu et al., 2025; Zhuang et al., 2024）。实践中，SFT 常作为初始化，RL 在反馈下提供细粒度策略改进（Zhu et al., 2025; Li, 2019; Zhang et al., 2021）。

近期研究突出三个主要方向。第一，把语言编译为结构化控制器——如图、代码或计划——使 RL 能在符号抽象而非原始文本上优化执行策略（Zhuang et al., 2024; Jia et al., 2025; Zhu et al., 2025）。第二，通过基于 RL 的任务分解、通信路由与角色分配来适应在线协作，实现超越静态协议的动态协调（Zhou et al., 2025; Wang et al., 2024; Xu et al., 2025; Li et al., 2024a）。第三，若干研究探索在语言空间中直接用 GRPO 或 PPO 式更新学习推理策略，并在有益时整合工具或人类输入（Wan et al., 2025; Park et al., 2025; Han et al., 2025; Peiyuan et al., 2024; Feng et al., 2024）。这些方法强调信用分配与奖励塑造对高维语言动作空间中涌现行为对齐的重要性（Wei et al., 2025; Jiang et al., 2025; Alsadat & Xu, 2024; Lin et al., 2025）。

我们的工作与这一轨迹密切一致，但强调一个关键空白：多数现有 RL 方法聚焦优化智能体内或智能体间协调，而系统的知识边界保持固定。相反，我们引入双环视角：RL 负责学习元认知求助策略，求助事件触发的专家示范驱动持续学习。这一整合同时应对即时决策与长期能力成长，为真正自适应的多智能体系统提供原则性路径。

B 方法

B.1 预备知识：元认知马尔可夫决策过程

我们把人与智能体协作的动力学形式化为元认知马尔可夫决策过程（Meta-MDP），由元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$ 定义。Meta-MDP 为序贯决策提供原则性框架，其中动作对应高层认知策略。形式上，Meta-MDP 由元组 $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ 定义。在多智能体协作的每一轮 t，过程如下展开：状态 $s_t \in \mathcal{S}$ 是结构化认知状态表示，不仅封装外部问题上下文，也封装智能体对自身与同伴当前理解的内部评估（详见第 3.2 节）。基于这一丰富状态，智能体从离散动作空间 $\mathcal{A}$ 中选择元认知动作 a_t，其中包括自主解题或求助专家等功能性策略。系统随后按转移函数 $P(s_{t+1}|s_t, a_t)$ 转移到新状态 s_{t+1}，并给出奖励 $R(s_t, a_t)$，旨在激励任务成功与高效利用专家资源。总体目标是学习最优元认知策略 $\pi^*(a_t|s_t)$，最大化期望累积奖励，从而训练出能在自主问题求解与策略性依赖人类指导之间理性平衡的智能体。

C 实验

C.1 实验设置

基准与评估。 为评估框架，我们在一组广泛基准上实验，测试推理能力的不同方面。任务跨三个领域：通用知识与分析推理、程序合成、数学问题求解。

通用知识使用 MMLU 基准，包含 57 个学科领域，为多项选择格式，以准确率衡量。为控制评估成本，每个学科类别采样 10 个样例。程序合成采用 HumanEval，模型依据自然语言规格生成代码解。定量推理考虑四个以简洁数值答案为特点的数学数据集：GSM8K（小学算术应用题）、AIME（短答奥赛式题）与 AMC（竞赛题）。这些数据集的性能以求解率（Solve Rate）报告，定义为与各数据集规范化参考解的精确匹配。

所有评估在官方数据集上使用标准提示协议。我们排除外部工具与检索，确保改进来自协作框架而非辅助资源。单智能体设置中，推理确定性运行。涉及随机采样的多智能体实验设置随机种子、重复运行并报告平均结果。该设置隔离所提方法的贡献，便于与现有方法公平比较。

基线。 为确保公平全面比较，我们对照三类广泛基线，它们代表 LLM 协作推理的主导范式：

1. **单智能体求解器。** 依赖单一模型实例，无同伴交互，刻画仅靠提示词的性能上限。包括标准提示下的直接解码（Vanilla）、思维链（CoT）提示生成的推理轨迹，以及自洽性（SC）等多采样聚合方法；还包括自我反思策略（如 Reflection、RASC），模型在无外部帮助时内部修订输出。
2. **交互式多智能体审议。** 引入多个智能体之间的显式通信，智能体生成、批评并改进彼此提案。LLM-Debate 等方法实现结构化“辩论—回应”循环，成对或汇集式批评框架（如 PHP）模拟同行评审。这些基线评估：在没有外部专长时，仅靠系统化交互能否减少错误、提升推理稳健性。
3. **系统级协调框架。** 一些方法把协作视为计算图上的优化问题。自适应拓扑与路由方法（如 DyLAN、MasRouter）动态决定通信模式；工作流与搜索式系统（如 GPTSwarm、AFLOW）编排可复用推理模块；AgentPrune 等通信剪枝策略通过过滤冗余交互提升可扩展性。这些基线突出规模下的效率与协调。

对所有基线，我们控制骨干模型、提示设置与生成预算（智能体数量、轮数、输出数）。产生多个候选时，应用基线的规范归约方法（如多数投票）。不使用检索增强或外部工具。这一分类明确改进来自更强的单

智能体推理、更丰富的同伴验证，还是更有效的协调，为评估我们的方法提供清晰背景。

实现细节。 除另有说明，主实验采用三智能体协作设置、三轮交互。所有自主智能体由指令微调的开源骨干实例化：Qwen2.5-7B-Instruct、Qwen2.5-3B-Instruct（Team, 2024）、Llama-3.1-8B-Instruct 与 Llama-3.2-3B-Instruct（Grattafiori et al., 2024）。为在控制内存开销的同时高效后训练，我们采用 LoRA 参数高效微调，默认秩 16、缩放因子 $\alpha = 32$、dropout 0.05。实践中用 HuggingFace Transformers 框架实现系统，配合 8 位量化与键值缓存，降低内存消耗并加速多轮推理。自主智能体生成采用核采样，top-p = 0.95、温度 0.7、最大生成长度 1024 token。外部 GPT 人类代理使用较低温度 0.3，以便干预时产生更稳定可靠的回答。为降低评估随机性，多数主实验用三个独立随机种子重复并取平均。优化使用 Adam 与余弦学习率衰减。超参数搜索中，学习率从 $\{2\times10^{-5}, 5\times10^{-5}, 1\times10^{-4}, 2\times10^{-4}, 5\times10^{-4}\}$ 选择，训练 epoch 在 1—3 内变化。通过梯度累积控制有效批大小，批大小在 $\{8, 16, 32\}$ 中探索。GRPO 式内环优化使用裁剪系数 $\epsilon = 0.2$、KL 正则权重 $\beta_{kl} = 0.02$、奖励缩放固定为 1.0，默认启用优势归一化。这些设置旨在保持稳定的离线策略优化，同时保留对候选动作相对奖励差异的足够敏感度。

训练数据由真实与合成任务实例组成。GSM8K 直接使用原始训练划分。对其余基准，为更好模拟现实中智能体可能需要请求外部帮助的求助场景，我们用 GPT-5 构造合成训练数据，生成模拟协作推理中各类情境的任务对齐样本。所有任务合计约 10K 训练实例。数据生成与离线轨迹构造在 HILA 框架下进行。具体而言，对每个智能体状态，我们枚举所有有效策略动作并推演相应后果，形成分组候选，再转换为离线 GRPO 训练的对比样本。这种穷举枚举使我们能构建带显式相对偏好的动作组，而不只依赖在线执行中采样的单一动作。

除策略训练数据外，我们还为外环持续学习阶段构造监督数据。每当智能体选择寻求外部帮助，我们记录对应问题、专家提供的正确推理轨迹与最终答案，并把该配对作为 SFT 的真实监督实例。预处理后，离线数据集约含 8K 个 GRPO 训练分组样本与约 2K 个专家标注 SFT 样本。这一划分反映双环设计的预期角色：内环主要从动作级相对比较中训练，外环由较小但更高质量的专家示范驱动，直接扩展模型推理能力。

奖励塑造方面，总体奖励尺度固定为 1.0，并调节不同策略动作的惩罚。CREATE 惩罚在 $\{0.05, 0.1, 0.2\}$ 中搜索，DEFER 惩罚从 0.1 到 0.5、步长 0.1 变化。这些系数控制自主探索、依赖同伴解答与外部干预之间的权衡。我们在留出验证集上调节，以平衡推理准确率与调用额外计算或专家协助的成本。除明确研究某一超参数的消融外，所有实验使用相同实现流水线与调参协议。

人类专家的定义。 原则上，框架中的人类协作者指能够提供外部知识与纠正性干预的真实的人。然而，遵循用先进语言模型近似人类输入的既有研究（Liu et al., 2023; Pandya et al., 2024），我们也采用强 LLM 作为实际替代。对推理能力相对较弱的 LLaMA 系智能体，多数实验用 GPT-4o-mini 作为代理专家，以在成本与效果间保持良好平衡。相反，对推理能力明显更强的 Qwen 系智能体，需要更强的专家才能提供足够有信息量的指导，因此这些设置使用 GPT-4o 作为代理专家。

提示词模板。 框架依赖一小组任务特定与交互特定的提示词模板，以协调推理、协作与元认知控制。具体而言，我们使用基础提示在不同任务类型（如数学推理、多项选择问答、代码生成）下初始化任务求解；使用辩论提示把每个智能体暴露于自身先前回答与其他智能体回答，支持迭代多智能体精炼；使用元策略提示管辖 EVAL、CREATE、DEFER 之间的高层动作选择。为清晰起见，下面给出这些提示的规范形式，占位变量表示任务内容与动态构造的交互历史。

> 以下提示词模板为操作性文本，保留英文原文，变量名与格式不变。

提示词模板（英文原文）

```
Base Prompt (Multiple-Choice)
Answer the following multiple-choice question. Choose the single best option.
Solve the problem:
{{question}}
Think step by step, show your reasoning, and end your response with a single line that clearly
states the final answer.
Base Prompt (Math: Numeric / Symbolic)
Solve the following problem:
{{question}}
Think step by step, show your reasoning, and be careful with arithmetic. End your response
with a single line that clearly states the final answer. If the answer is a number, output only
the number on that final line.
20

Published as a conference paper at ICLR 2026
Base Prompt (Math with Forced Boxed Answer)
Solve the following problem:
{{question}}
Think step by step, show your reasoning, and be careful with arithmetic. Must give the final
answer in the form \boxed{...}.
Base Prompt (Code Generation with Unit Tests)
You are given a Python programming task. Write a correct and efficient solution that passes
all unit tests.
Rules:
• Output ONLY Python code.
• Do NOT include explanations, comments outside the given prompt, or additional
text.
• Keep the original function signature exactly as given.
• Do not write any test code. Do not use input() or print().
• You may use the Python standard library.
{{question}}
Base Prompt (Generic Fallback)
Solve the following problem:
{{question}}
Think step by step. End your response with a single line that clearly states the final answer.
If the answer is a number, output only the number on that final line.
Multi-agent Collaboration Prompt
You are in a multi-agent collaboration.
=== Original Prompt ===
{{base prompt}}
=== Your Previous Responses ===
{{self history block}}
=== Other Agents' Responses ===
{{others history block}}
Now compare the solutions, resolve disagreements, and provide an UPDATED final answer.
Keep reasoning concise but correct. Finish with a clear final answer line.
Meta-Policy Prompt
You are a meta-policy controller for a multi-agent system. Choose ONE action and output
ONLY the action line.
Valid actions (no extra text):
• DEFER
(ask a human expert)
• EVAL <idx>
(copy Agent idx; idx in 0..N-1)
• CREATE
(write a new solution yourself)
{{structured decision signals}}
=== Problem ===
{{base prompt}}
=== Your Latest Solution ===
{{self latest solution}}
21

Published as a conference paper at ICLR 2026
vention.
=== Other Agents' Latest Solutions ===
{{others latest solutions}}
Now output ONLY one action line.
```

C.2 实验结果

训练各阶段的准确率—求助耦合。 为进一步探究 DEFER 率下降反映的是真实能力提升（而非仅仅规避成本），我们联合分析各训练阶段的任务准确率与求助频率。图 4—6 揭示一致且可解释的模式：从初始化策略到 GRPO、再到完整 DLPO，系统总体向左上区域移动，即更高准确率、更低外部干预依赖。这种耦合尤其有信息量，因为它区分了两种性质不同的状态：（i）减少求助但牺牲正确性的“节俭”策略；（ii）既减少求助又提升准确率的更强策略。跨基准看，GRPO 往往带来温和的左移（更低 DEFER），符合学习成本感知干预策略的预期。相反，DLPO 在三个数据集上都带来更清晰的帕累托式改进，同时降低求助并提高准确率，这很难仅用成本意识解释。它与双环设计一致：内环改进“何时提问”，外环吸收专家示范，使系统越来越“不需要提问”。值得注意的是，这种耦合改进的幅度因任务而异：GSM8K 上准确率提升相对温和而求助大幅下降，说明 DLPO 主要减少较容易算术题上的不必要升级；AMC 上仅 GRPO 出现轻微权衡，而 DLPO 在进一步降低求助的同时恢复并提升准确率，表明持续学习有助于避免“过度剪枝”干预；MMLU 上两项指标单调改善，强有力说明学习到的策略既更具选择性也更有能力。总体而言，这些耦合轨迹为“HILA 的增益来自校准干预与能力成长”提供了额外的行为验证。

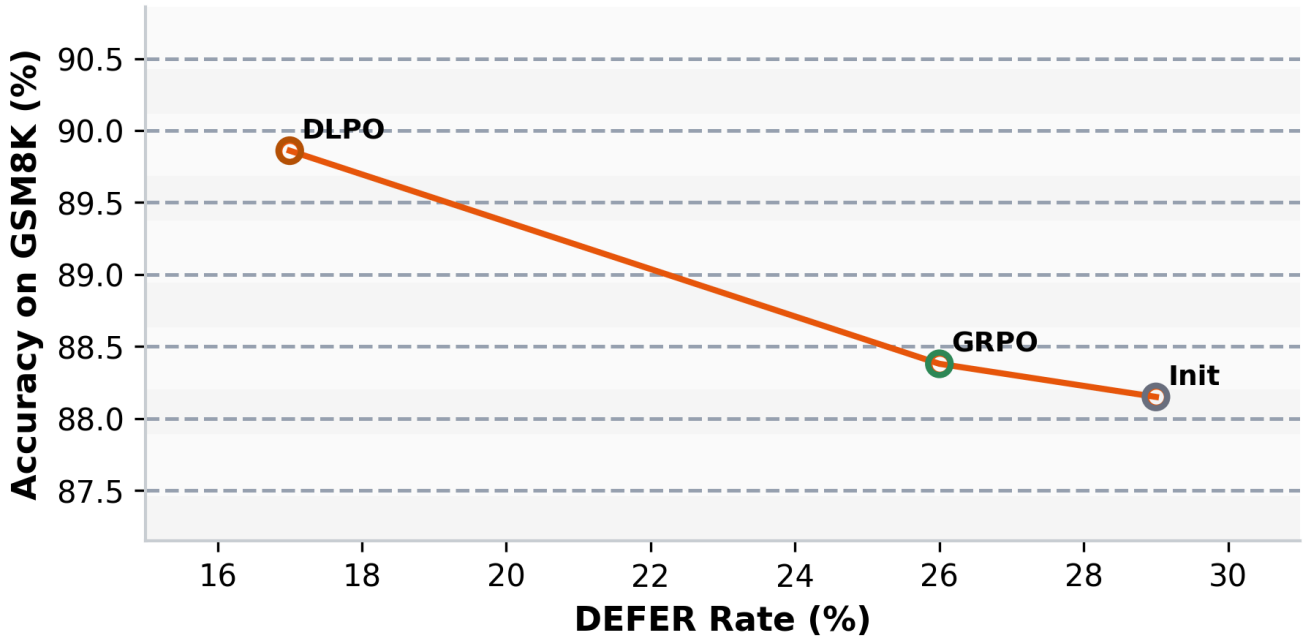


图 4：GSM8K 上各训练阶段（Init → GRPO → DLPO）的准确率与 DEFER 率。DLPO 实现联合改进：提高准确率的同时降低对外部干预的依赖。

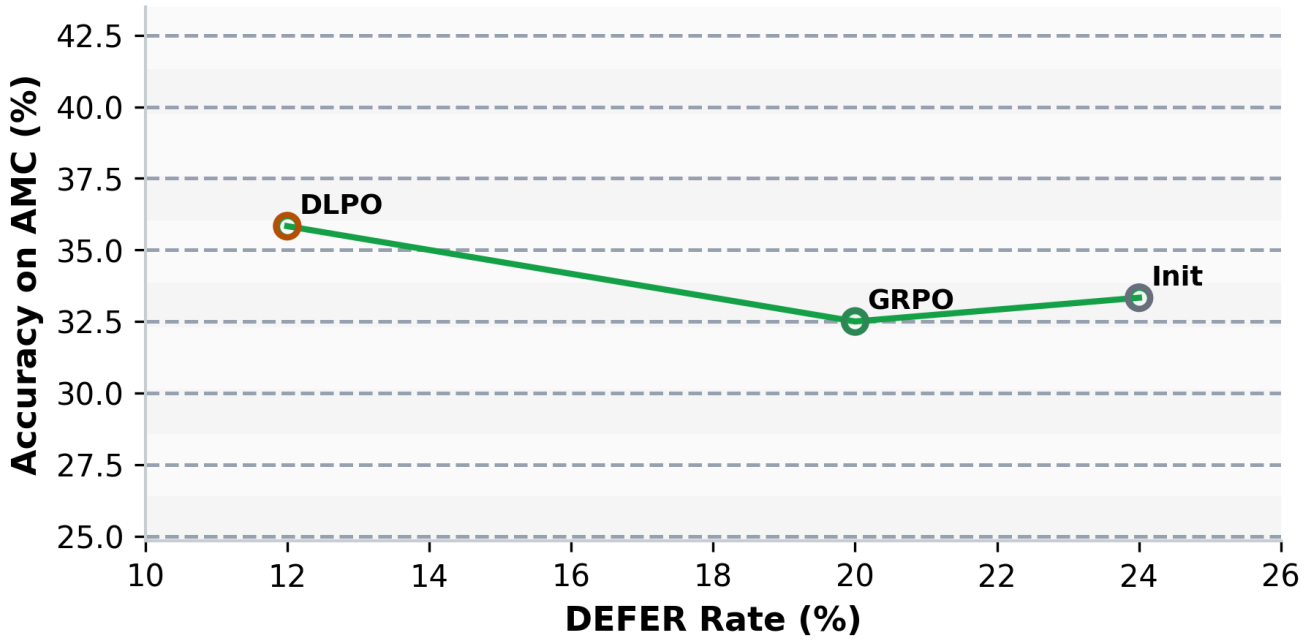


图 5：AMC 上各训练阶段的准确率与 DEFER 率。GRPO 在准确率小幅波动下降求助，DLPO 则同时提升准确率并进一步降低求助，表明持续学习缓解了过度保守的干预。

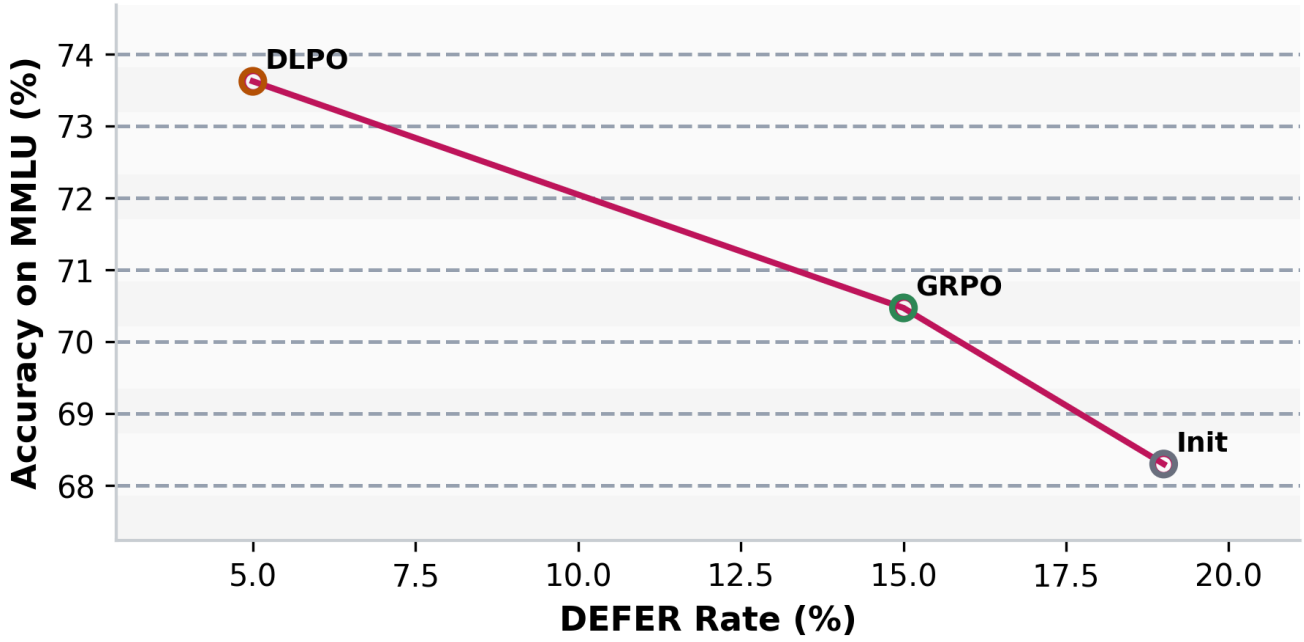


图 6：MMLU 上各训练阶段的准确率与 DEFER 率。准确率随求助率下降而单调上升，表明学习到的策略既更具选择性也更有能力。

人类代理能力的影响。 我们进一步用不同强度的语言模型替换人类代理，考察外部专家能力对 HILA 总体表现的影响。如图 2 与表 6 所示，结果呈现清晰一致的模式：更强的人类代理在所有评估基准上带来更好的最终表现。代理较弱时，干预带来的增益明显减少；更强代理则产生最佳总体结果。该趋势与 HILA 的设计一致：DEFER 旨在自主集体达到极限时提供更高质量的推理轨迹。这些结果表明，HILA 的有效性不仅取决于学会何时调用外部帮助，也取决于干预发生时所获指导的质量。换言之，策略性求助与专家质量互补：训练良好

的元认知策略能识别外部协助有价值的情境，但最终收益仍取决于该协助的信息量与可靠性。总体而言，该实验说明 HILA 在可获得更强外部指导时能有效受益，同时也凸显所选人类代理对最终系统表现的重要性。

求助成本作为协作的控制旋钮。 我们进一步考察求助成本 C_{defer} 如何调节 HILA 中自主推理与外部干预的平衡。图 7(a) 显示不同 C_{defer} 下 AMC 与 MMLU 的准确率趋势；图 7(b) 展示 AMC 上低成本 0.1 与高成本 0.5 时动作分布的变化。清晰的模式是：提高 C_{defer} 使策略远离 DEFER、转向自主动作，尤其是 EVAL。这证实学习到的策略会直接响应预期干预惩罚并相应调整行为。同时，准确率曲线揭示一个不容忽视的权衡：中等成本可在保持有竞争力表现的同时减少不必要的外部依赖；更大的成本更激进地抑制求助，但也可能损害最终准确率。该效应在更困难的基准上尤其明显——过度抑制干预会使系统在仍需要外部指导时无法获得它。这些结果支持“C_{defer} 是协作的有效控制旋钮”的观点：它调节 HILA 依赖外部专长的频率，同时暴露实践中必须调节的性能—成本权衡。

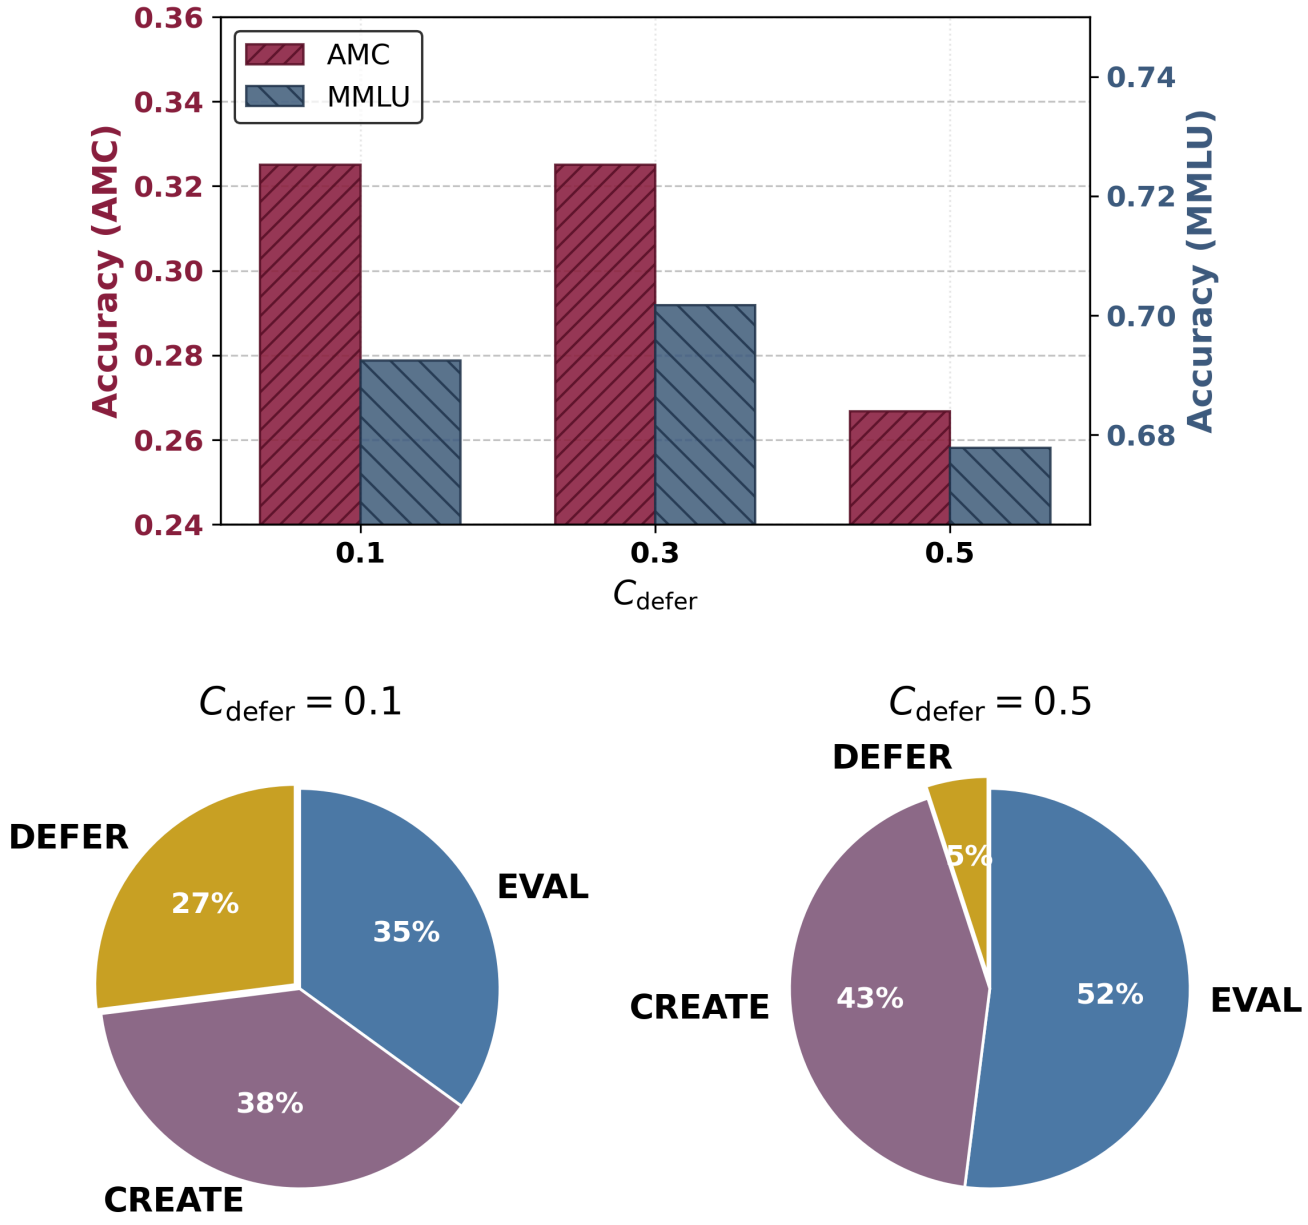


图 7：求助成本作为协作的控制旋钮。(a) 改变求助成本 C 对 AMC 与 MMLU 任务准确率的影响；(b) 提高成本如何使 AMC 上学习到的策略远离 DEFER、转向自主动作（尤其是 EVAL）。结果说明减少外部干预与保持最终表现之间的权衡。

集体探索的价值。 为考察集体规模对有效性与成本的影响，我们在 AMC 与 MMLU 上评估不同自主智能体数量的 HILA，如表 7 与表 8 所示。两个基准上趋势大体一致：增加智能体数量总体提升准确率，尤其是从极小集体增加到中等规模时。这一模式支持框架的核心前提：更大的智能体池带来更丰富的集体探索。更多智能体并行生成并改进候选解，系统可访问更广泛的推理轨迹，提高至少出现一个高质量解、并能通过元认知策略被选择或传播的概率。

同时，增益并非线性。准确率在智能体较少时提升最明显，随着集体扩大变得更不稳定，增量收益变小且相邻设置间偶有波动。这表明单纯扩大智能体数量存在收益递减：一旦解空间已充分多样化，额外智能体贡献的新信息逐渐减少。相反，计算成本随智能体数量急剧上升。参与智能体越多，输入与输出 token 增长越快，即使准确率仅小幅提升，总 token 用量也会大幅增加。综合来看，这些结果凸显实际权衡：更大的集体可通过更广探索增强推理，但收益必须与上升的推理成本平衡。这使智能体数量成为部署 HILA 时重要的效率—性能设计选择。

表 7：智能体数量对 AMC 表现与 token 成本的影响。 扩大集体通常提升准确率，但输入、输出与总 token 用量也急剧上升，呈现明显的性能—效率权衡。

智能体数	AMC	平均输入 token	平均输出 token	平均总 token
1	26.67	3146	1299	4445
2	28.33	10184	2564	12748
3	32.50	23285	4463	27748
4	31.67	42540	6349	48889
5	33.33	64097	7585	71682
6	32.50	92135	9501	101636
8	34.17	162142	12704	174846
10	35.83	238278	14928	253206

表 8：智能体数量对 MMLU 表现与 token 成本的影响。 更大的集体通常带来更好准确率，尤其在智能体较少时，但系统扩展时 token 消耗大幅增加。

智能体数	MMLU	平均输入 token	平均输出 token	平均总 token
1	66.32	2054	508	2562
2	67.54	5575	972	6547
3	68.49	11049	1525	12574
4	68.95	18302	2077	20379
5	68.60	27133	2609	29742
6	69.47	38317	3223	41540
8	69.12	65295	4333	69628
10	69.65	94827	5612	100439

迭代协作的最优深度。 为评估迭代改进的作用，我们改变协作轮数并在 AMC 与 MMLU 上评估 HILA，如表 9 与表 10 所示。两个基准上均呈现清晰的非单调模式。从较浅交互深度增加到中等深度，准确率持续提升，

表明多轮协作帮助系统改进中间解、吸收同伴反馈并从早期错误中恢复。这支持“迭代交互让智能体逐步修订并巩固候选解、而非依赖单轮交换”的直觉。

然而额外轮次的收益不会无限持续。表现在中等等深度达到峰值，随后在进一步延长交互时略有下降，即使 token 用量继续增加。这表明额外轮次起初提供有用的纠错与改进机会，但过度交互会导致收益递减，甚至可能开始强化次优轨迹。一种可能的解释是：重复交换增加了传播噪声或缺陷中间推理的机会，使集体更容易累积错误而非纠正错误。综合来看，这些结果表明迭代协作有价值但并非无界：轮数选择应平衡改进收益、上升的计算成本与过度迭代风险。

表 9：协作轮数对 AMC 表现与 token 成本的影响。 交互深度从 1 轮增至 4 轮时准确率大幅提升，但再增加一轮时下降，表明过度迭代带来收益递减。

轮数	AMC	平均输入 token	平均输出 token	平均总 token
1	18.33	455	2195	2650
2	22.50	13406	3480	16886
3	31.67	24129	4580	28709
4	40.83	33287	5203	38490
5	35.00	43984	6627	50611

表 10：协作轮数对 MMLU 表现与 token 成本的影响。 中等轮数提升准确率，继续增加交互深度只带来有限收益与略高成本。

轮数	MMLU	平均输入 token	平均输出 token	平均总 token
1	0.6404	5352	933	6285
2	0.6491	6385	1251	7636
3	0.6849	11049	1525	12574
4	0.6930	15318	1798	17116
5	0.6895	19689	2144	21833

C.2.1 真实人在回路

动机与评估范围。 主实验使用强 GPT 模型作为外部专家代理，提供受控、可扩展的人类干预近似。然而 HILA 的核心主张本质上关于人—智能体协作，而非仅模型—模型交互。为验证外部专家替换为真实人类参与者时框架仍然有效，我们用真实博士级专家开展了一项额外的人在回路研究。由于真实人工标注远比基于 API 的代理监督昂贵，我们聚焦三个代表性基准，共同覆盖算术推理、竞赛式数学问题求解与通用知识推理：GSM8K、AMC 与 MMLU。该选择在任务格式与难度上提供多样性，同时保持研究实际可行。相应地，我们以两种操作形式实例化真实人类参与：初始化时提供的主动指导，以及被动协助，如图 8 所示。

面向人类评估的平衡子集构造。 为确保人类评估子集忠实反映 HILA 遇到的协作状态范围，我们不简单均匀随机采样。对 GSM8K 与 MMLU，我们依据干预前智能体间的一致模式构造分层子集，使所选实例覆盖性质不同的集体推理状态。具体而言，每个样本归入以下类别之一：（i）所有智能体一致且正确；（ii）多数一致但错误；（iii）多数一致且正确；（iv）所有智能体不一致。然后在最终评估子集中近似平衡这些类别。这种

分层很重要，因为它让人类专家接触易与难的协作语境，包括共识失败与严重分歧，而非过度代表简单实例。对 AMC，由于基准本身较小，我们评估全集而非分层子集。

人类专家池与参与协议。 如图 9 所示，我们招募 20 名来自广泛技术学科的博士生，包括计算机科学、计算机工程、电气工程、数学、工业与系统工程、生物医学工程、地球科学与经济学，把他们视为领域通用专家标注者。为使真实人类参与兼容重复、可复现的评估，我们采用离线专家收集协议：每位人类专家预先回答所选问题，而非在实时推理中交互式查询。对每个问题，每位专家提供两个字段：human idea，包含简洁的解题直觉或高层计划；human reasoning，包含更完整的推理轨迹与最终答案。该设计让我们在同一系统下评估轻量人类提示与完整专家解答。形式上，若 x 表示输入问题、h 表示人类专家，则收集的标注可写为

$$E_h(x) = \left(e_h^{idea}(x),\, e_h^{reason}(x)\right),$$

其中 $e_h^{idea}(x)$ 与 $e_h^{reason}(x)$ 表示两个层级的专家指导。

人类参与的两种模式。 我们研究 HILA 下真实人类参与的两种不同模式。第一种模式中，人作为被动专家，即仅当智能体选择 DEFER 时才咨询人类；此时人类回答的作用与标准 HILA 循环中的外部专家信号完全相同。第二种模式中，人作为主动专家，即在智能体开始初始推理之前注入专家信息。主动信息可以是简洁的 human idea，也可以是完整的 human reasoning。重要的是，两种角色并不互斥：即使初始化时提供了主动人类信息，系统仍可在后续协作中选择向基于 GPT 的外部专家求助。这让我们分离人类参与的两个互补效应：初始指导（更好的起始轨迹）与按需纠正（不确定性下的针对性救援）。记法上，主动设置把原问题输入 x 扩展为

$$x' = \left(x,\, E_h^{init}(x)\right),$$

其中 $E_h^{init}(x)$ 可以是 $e_h^{idea}(x)$ 或 $e_h^{reason}(x)$。

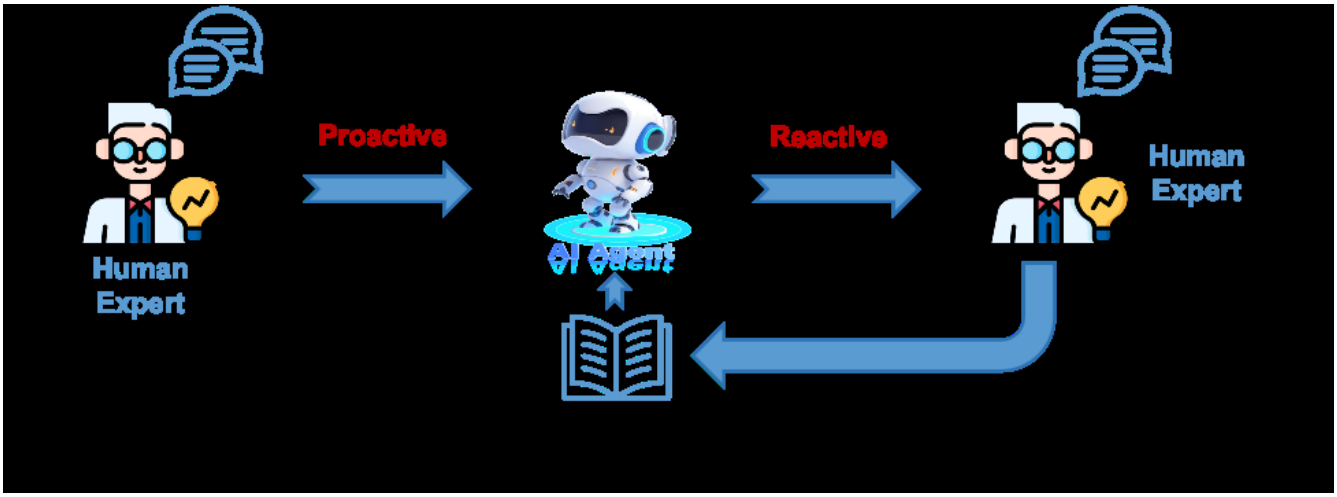


图 8：HILA 中具有双向交互的真实人在回路协作。真实人类专家可在初始化时主动注入先验知识（如高层 human idea 或完整 human reasoning），在自主协作开始前塑造智能体起始状态；也可在元策略选择 DEFER 时被动提供纠正反馈。这一统一视角表明，HILA 中的人类专长不限于事后监督，而可作为前置指导与多轮协作中的按需干预整合进来。

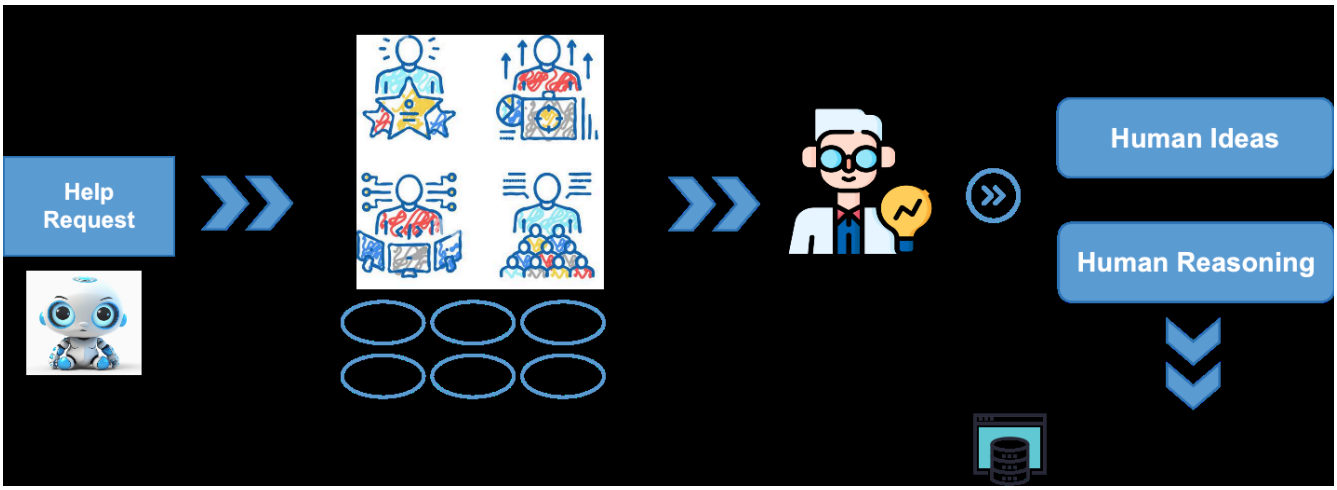


图 9：HILA 中的真实人类反馈流水线。收到求助请求（DEFER）后，系统把查询路由到人类专家池，专家提供高层 human idea 或完整 human reasoning。收集的反馈随后作为结构化监督存储，用于后续训练与持续改进。

单专家机制下的专家质量。 在评估完整 HILA 框架之前，我们首先比较候选专家的独立问题求解准确率，包括基座 LLAMA3-8B、若干 GPT 模型与真实人类专家池。这直接估计外部干预发生时系统可用的质量上限。如表 11 所示，真实人类专家在三个基准上取得最强总体表现，在 AMC 上尤其突出，大幅超过所有基于模型的专家。这一结果很重要，因为它表明人类专家通道不只是 GPT 代理的概念替代，而是在需要结构化推理与细致数学判断的领域能提供真正更强的指导。同时，MMLU 上的差距较小，说明人类专家的相对优势取决于任务类型。总体而言，该比较确立真实人类构成 HILA 高质量、有意义的外部专长来源。

表 11：候选外部专家在人类评估基准上的独立表现。 Human Experts 表示由 20 名博士参与者汇总的真实专家池。所有数值为百分比。

专家	GSM8K	AMC	MMLU
LLaMA3-8B	58.67	16.67	57.33
GPT-3.5-Turbo	66.00	17.50	58.00
GPT-4o-mini	85.67	39.17	86.67
GPT-4o	88.33	46.67	87.33
Human Experts	**95.00**	**97.50**	**88.00**

HILA 下的被动人类专家。 接下来，我们在自主骨干固定为 LLAMA3-8B 的情况下，用不同被动专家替换 HILA 中基于 GPT 的专家。表 12 显示，更强专家持续带来更好的下游表现，真实人类专家总体最佳。该趋势与此前基于代理的观察一致，但现在是真实人类参与者：一旦系统学会何时求助，最终增益仍关键取决于外部协助的质量。AMC 上的提升尤其惊人：用真实人类替换 GPT 专家带来的跃升远大于另外两个数据集。这表明，在集体可能收敛到看似合理但错误的推理路线的情境中，人类干预的价值尤其强。换言之，人类专家不仅在孤立评估时更准确；作为被动干预目标时，他们也为 HILA 的决策过程提供更有效的纠正信号。

表 12：HILA 使用不同被动专家的表现。 被动专家仅在系统选择 DEFER 时被咨询。自主骨干固定为 LLaMA3-8B。所有数值为百分比。

HILA 中的被动专家	GSM8K	AMC	MMLU
GPT-3.5-Turbo	61.67	20.83	59.67

HILA 中的被动专家	GSM8K	AMC	MMLU
GPT-4o-mini	74.33	29.17	64.33
GPT-4o	77.33	33.33	67.33
Human Experts	**78.67**	**61.67**	**75.33**

初始化时的主动人类指导。 最后，我们考察人类能否不仅作为被动专家，也在多智能体推理开始前作为主动指导来源。表 13 在相同 LLAMA3-8B 骨干下比较多种人类参与设置。当人类在初始化时仅提供高层 idea 时，收益好坏参半：MMLU 上有所提升，但数学数据集上收益有限或不一致。这说明粗略的人类提示可能改善初始搜索方向，但往往不足以可靠地把整个协作过程引向正确解。相反，当人类在初始化时提供完整推理轨迹，三个基准的表现都大幅提升，在所有比较的人类参与设置中最强。

被动 vs. 主动人类角色。 human idea 与完整 human reasoning 的对比揭示了真实人类价值在 HILA 中的关键机制。轻量主动提示主要充当弱先验：它们可能使初始推理轨迹产生偏置，但下游智能体仍须自行重建完整解题路径。相反，完整主动推理提供强得多的结构化信号，从一开始就能重塑协作搜索过程。值得注意的是，这种主动人类信息仍可与后续基于 GPT 的被动干预结合，形成混合设置：人类知识改善初始化，而自动专家代理仍可在后续提供救援。综合来看，这些结果表明真实人类能以两种不同但互补的方式改进 HILA：作为被动专家，在系统明确请求帮助时纠正失败；作为主动专家，在协作展开前改善初始推理状态的质量。这提供了更强的经验证据：HILA 不仅在原则上兼容人类参与，还能在多种操作模式下有意义地利用真实人类专长。

真实人类参与下的动作分配。 为更好理解真实人类参与如何改变 HILA 的行为（而不仅是最终任务准确率），我们进一步分析不同人类参与模式下策略动作的分布。具体而言，我们报告人类作为被动专家、主动 idea 提供者或主动完整推理提供者时，GSM8K、AMC 与 MMLU 上 EVAL、CREATE、DEFER 决定的比例。该分析很重要，因为相同的性能增益可能来自性质不同的协作状态：一个系统可能因更自给自足而改进，另一个可能因更积极地调用外部帮助而改进。通过比较动作分布，我们可以刻画人类输入的来源与形式如何重塑策略的内部决策动态。

被动人类专家鼓励直接求助。 当真实人类作为被动专家（仅在策略选择 DEFER 后咨询）时，所得动作分布在三个数据集上都把相当比例分配给求助（图 10）。GSM8K 上尤其明显，DEFER 成为最频繁的动作。该模式与此前观察到的人类专家强独立质量一致：一旦策略学会真实人类提供高度可靠的纠正信号，它在不确定情境中就更愿意调用外部干预。同时，策略在 CREATE 上仍保留不可忽略的概率，说明即使有高质量人类帮助，HILA 也不会退化为纯粹依赖专家，而是维持自主探索与专家咨询并存的混合策略。

主动人类 idea 使策略更倾向求助。 当人类仅在初始化时提供简洁 idea、而 GPT-4o 仍作为后续 DEFER 的被动专家时，出现不同模式（图 11）。相对于仅被动人类条件，三个基准上 DEFER 比例都进一步上升。这说明轻量人类 idea 虽可作为初始先验，却往往不足以完全化解下游不确定性。结果是策略似乎更依赖后续被动干预：用初始提示引导搜索，但当困难推理步骤仍未解决时仍频繁请求更强专家协助。在这个意义上，高层人类 idea 可能改善早期定向，却不一定降低模型在整个推理轨迹中对后续救援的依赖。

完整主动人类推理重新平衡协作策略。 当主动人类输入从高层 idea 升级为完整推理轨迹时，动作分布再次变化（图 12）。相较于主动 idea 条件，GSM8K 与 AMC 上 DEFER 下降，CREATE 总体更突出。该模式说明更丰富的前置人类指导能更好稳定初始推理状态，使智能体无需那么频繁调用被动帮助，就能继续改进或扩展更强的部分解。换言之，完整人类推理轨迹更像下游协作的结构化脚手架，而非弱先验。虽然 DEFER 仍不可

忽略，但相对于主动 idea 设置的下降表明，更强的主动人类输入能通过更早降低不确定性，部分替代后续干预。

人类指导改变策略状态，而不仅是准确率。 综合来看，这些分布表明不同形式的人类参与在 HILA 中诱发实质不同的策略状态。被动人类专家主要通过让外部干预在明确请求时极具价值，从而提高 DEFER 的吸引力。主动人类 idea 虽有初始提示之益，却仍留下足够残余不确定性，使系统下游求助更频繁。相反，主动完整推理提供更强的前置结构指导，在某些任务上减少后续干预需求，并把更多概率质量转向通过 CREATE 与 EVAL 的自主延续。这些观察补充了准确率结果：真实人类参与不仅影响系统表现多好，也影响它选择如何协作。

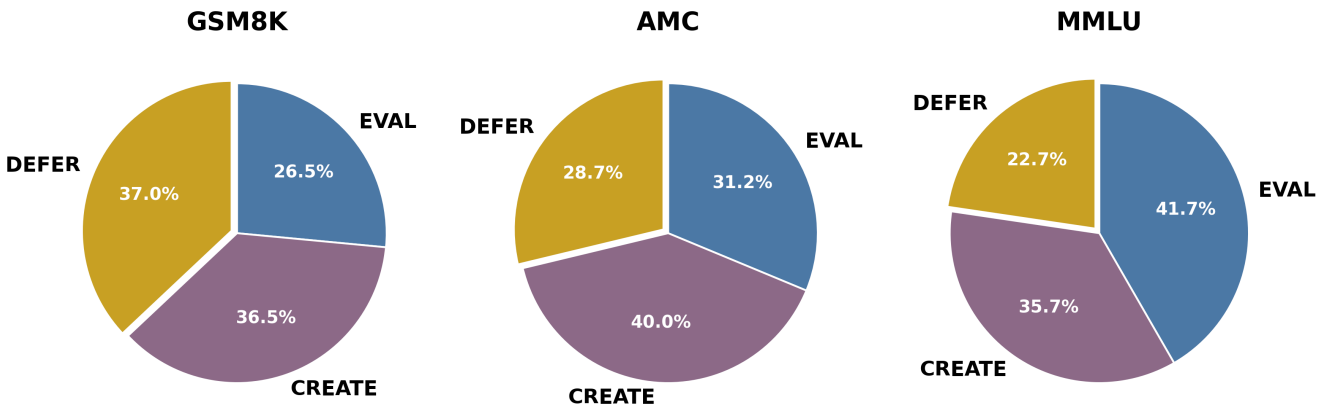


图 10：真实人类作为被动专家时 HILA 的动作分布，即仅在系统选择 DEFER 后提供反馈。跨数据集看，GSM8K 与 AMC 上 CREATE 与 DEFER 占主导，MMLU 上 EVAL 比例明显更大。

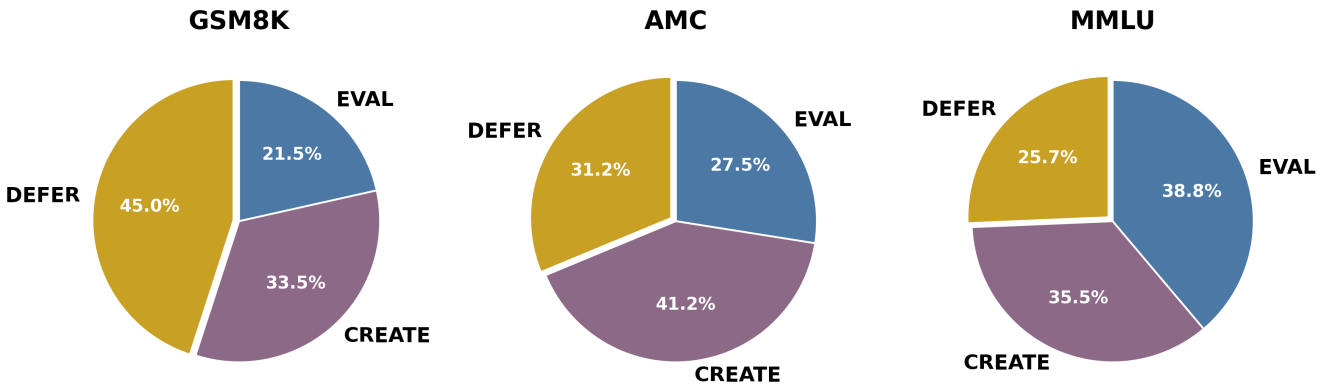


图 11：人类在初始化时提供主动 idea、GPT-4o 仍作为后续 DEFER 被动专家时 HILA 的动作分布。结果展示 GSM8K、AMC 与 MMLU。

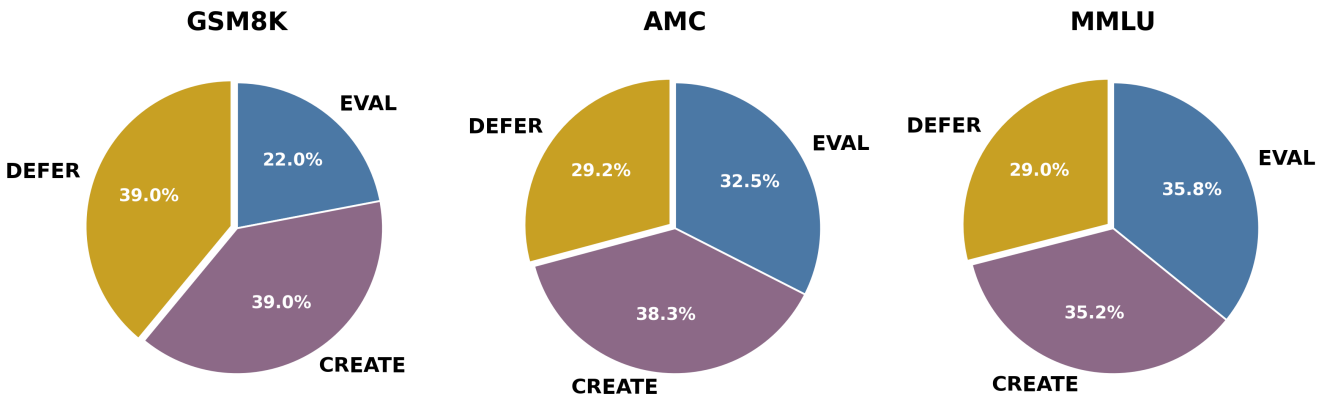


图 12：人类在初始化时提供完整主动推理、GPT-4o 仍作为后续 DEFER 被动专家时 HILA 的动作分布。结果展示 GSM8K、AMC 与 MMLU。

表 13：HILA 下不同真实人类参与模式的比较。 主动设置中，人类信息在智能体初始推理前注入，GPT-4o 仍作为后续 DEFER 的被动专家。所有数值为百分比。

人类参与设置	GSM8K	AMC	MMLU
仅 GPT-4o 作为被动专家	77.33	33.33	67.33
仅人类专家作为被动专家	78.67	61.67	75.33
人类主动 idea + GPT-4o 被动专家	78.33	34.17	79.33
人类主动完整推理 + GPT-4o 被动专家	90.67	65.83	86.67

D 关于使用大语言模型的声明

在准备本工作过程中，我们出于不同目的使用了若干大语言模型。第一，GPT-4o-mini 与 GPT-4o 被直接整合进实验框架，作为人在回路设置中人类专家的代理。这一设计选择遵循既有研究，使我们能在受控、可重复条件下评估框架，并平衡成本与效果。GPT-5 用于生成合成训练数据以优化模型，实现可扩展、受控的训练实例构造。第二，GPT-5 用于协助改善稿件的清晰度、组织与可读性。该模型帮助润色措辞与语法，但所有概念贡献、方法设计与实验分析均由作者完成。所有内容均经作者仔细审阅、编辑与验证，作者对最终发表的准确性与完整性承担全部责任。