RLVER：以可验证情感奖励进行强化学习，培养共情智能体

RLVER: Reinforcement Learning with Verifiable Emotion Rewards for Empathetic Agents

Peisong Wang*、Ruotian Ma*,†、Bang Zhang*、Xingyu Chen、Zhiwei He、Kang Luo、Qingsong Lv、Qingxuan Jiang、Zheng Xie、Shanyi Wang、Yuan Li、Fanghua Ye、Jian Li、Yifan Yang、Zhaopeng Tu†、Xiaolong Li

腾讯混元 AI 数字人（Hunyuan AI Digital Human, Tencent）

https://github.com/Tencent/DigitalHuman/tree/main/RLVER

ICLR 2026（论文库标注） · arXiv:2507.03112v1 [cs.CL] · 原文 41 页 · * 共同第一作者 †通讯作者：ruotianma@tencent.com、zptu@tencent.com

> 中文阅读版说明：本文件依据论文逐节翻译，保留原有章节顺序、公式、表格数值与图注位置。图 1—7 保留原图并附中文图注；图 8、9 的示例对话以中文重排；表 1—5 以中文重排，数值照录原文。模型名、方法名（RLVER、SAGE、PPO、GRPO）与参考文献条目保持英文。附录 A—E 一并译出；附录中的提示词模板属于操作性文本，保留英文原文；其中 SAGE 核心生成与评估模板收录于 E.1 之后，策略分析、坐标标定等辅助模板从略。

摘要

大语言模型（LLM）在逻辑与算法推理上表现出色，但其情商（EQ）仍远远落后于认知能力。虽然可验证奖励强化学习（RLVR）已在其他领域取得进展，其在对话——尤其是情商——上的应用仍未被充分探索。本工作提出 RLVER，首个端到端强化学习框架，利用模拟用户提供的可验证情感奖励来培养 LLM 的高阶共情能力。在该框架中，自洽的情感模拟用户（Zhang et al., 2025a）参与对话推演，并在对话过程中产生确定性的情感分数，作为引导 LLM 学习的奖励信号。用 PPO 微调公开的 Qwen2.5-7B 模型，使其 Sentient-Benchmark 分数从 13.3 提升到 79.2，同时基本保持数学与编程能力。大量实验揭示：（i）RLVER 持续提升多种对话能力；（ii）思考型与非思考型模型呈现不同趋势——思考型模型擅长共情与洞察，非思考型模型偏好行动；（iii）GRPO 通常带来稳定增益，而 PPO 能把某些能力推到更高上限；（iv）更具挑战性的环境并不总是更好——中等难度可能带来更强结果。结果表明，RLVER 是通向情感智能且能力广泛的语言智能体的一条实用路径。

1 引言

大语言模型（LLM）的显著进展集中在人类认知的理性一半：数学演绎推理（Hendrycks et al., 2021b; Cobbe et al., 2021）、程序合成（Guo et al., 2024; Jain et al., 2024）与算法规划（Yao et al., 2023; Zheng et al., 2024a）。然而真正的人类智能建立在 IQ 与 EQ 之上——逻辑严谨与社会情感理解交织。今天的 LLM 能完美配平方程，却在被要求安慰伤心的朋友、或根据用户不断变化的感受调整建议时频频失手（Zhang et al., 2025a）。

现有对话系统通常通过在标注咨询语料上监督微调（Sun et al., 2021; Liu et al., 2021; Zheng et al., 2022）或基于规则的模板（van der Zwaan et al., 2012; Peng et al., 2022）来增强情商。然而这些方法受数据稀缺、对话结构

僵化与泛化有限之苦。近期可验证奖励强化学习（RLVR）在数学、编程与搜索上的成功表明，基座 LLM 可以纯靠 RL 信号获得新技能，无需监督预热（Zeng et al., 2025; Guo et al., 2025; Hu et al., 2025; Ma et al., 2025）。在增强对话能力方面，强化学习也提供了一种有吸引力的替代方案：智能体不必模仿静态真实答案，而可以直接优化长期用户满意度——前提是有稳定的交互环境与一致的奖励系统。然而，将 RLVR 用于增强对话能力面临几个关键障碍：

- 缺乏稳定、真实、可扩展的多轮对话推演环境；
- 缺乏面向通用能力（如情商）的一致且可验证的奖励设计；
- 用 LLM 进行多轮强化学习的稳定训练仍是开放挑战。

我们用 RLVER 应对全部三项挑战：首个端到端、带可验证情感奖励的强化学习框架，用于培养 LLM 的高阶共情能力。基于 SAGE（Zhang et al., 2025a）——一个构造自洽情感用户模拟器、用于真实自动对话模拟与评估的框架——我们建立稳定可扩展的环境，使 LLM 能在整个训练过程中持续进行对话推演。每次对话中，模拟用户在 LLM 每次回答后更新其情感状态，输出 [0, 1] 内的情感分数作为奖励。情感分数的变化一致且可验证；每一次都由基于用户人设、对话历史、对话语境与目标的原理性推理步骤确定性导出。通过用广泛的用户行为与对话意图扩展模拟环境，我们缓解了同质用户偏好带来的奖励黑客问题。

我们用近端策略优化（PPO）微调轻量 Qwen2.5-7B 模型，使其 Sentient-Benchmark 分数从 13.3 跃升至 79.2，媲美规模大一个数量级以上的专有模型，同时基本保持数学与编程能力。我们还尝试在生成回答前强制显式“思考”步骤，以比较“思考型”与“非思考型”模型在 RL 训练中的行为。大量实验揭示以下关键发现：（i）RLVER 有效且可靠地提升多项核心对话能力；（ii）在某些设置下，思考型与非思考型模型呈现不同的发展模式——思考型模型倾向于增强共情与洞察，非思考型模型更关注行动导向能力；（iii）与 PPO 相比，GRPO 持续带来稳定平衡的改进，而 PPO 偶尔能把特定能力的上限推得更高；（iv）把用户模拟器同时作为环境与奖励来源时，更具挑战性的配置未必带来更好结果；相反，中等难度且对齐良好的设置可能更好支持模型成长；（v）RLVER 使模型行为在社会认知空间中从“以解决方案为中心”转向真正共情的风格。我们的发现表明，带可验证情感奖励的 RL 是通向情感智能、能力广泛的语言智能体的实用路径。

本文贡献如下：

1. **RLVER 框架。** 我们提出带可验证情感奖励的强化学习（RLVER），首个利用心理 grounded、自洽用户模拟器提供的在线可验证奖励信号来增强 LLM 共情能力的 RL 范式。
2. **实证进展。** 将 RLVER 应用于 7B 开源模型，使其 Sentient Benchmark 分数从 13.3 提升到 79.2——匹配大得多的专有系统——同时保持在数学与代码生成基准上的性能。
3. **实践洞见。** 通过全面实验，我们分析训练策略、RL 算法与环境设计如何影响共情能力发展，给出 RLVER 何时以及如何产生稳健改进或理想结果的洞见。
4. **开放资源。** 我们发布代码、检查点、提示词与环境脚本，以促进未来对情感智能智能体的研究。

RLVER: Reinforcement Learning with Verifiable Emotion Rewards for Empathetic Agents

Peisong Wang*, Ruotian Ma*,† , Bang Zhang* , Xingyu Chen , Zhiwei He , Kang Luo , Qingsong Lv , Qingxuan Jiang , Zheng Xie , Shanyi Wang , Yuan Li , Fanghua Ye , Jian Li , Yifan Yang , Zhaopeng Tu†, and Xiaolong Li

Hunyuan AI Digital Human, Tencent

https://github.com/Tencent/DigitalHuman/tree/main/RLVER

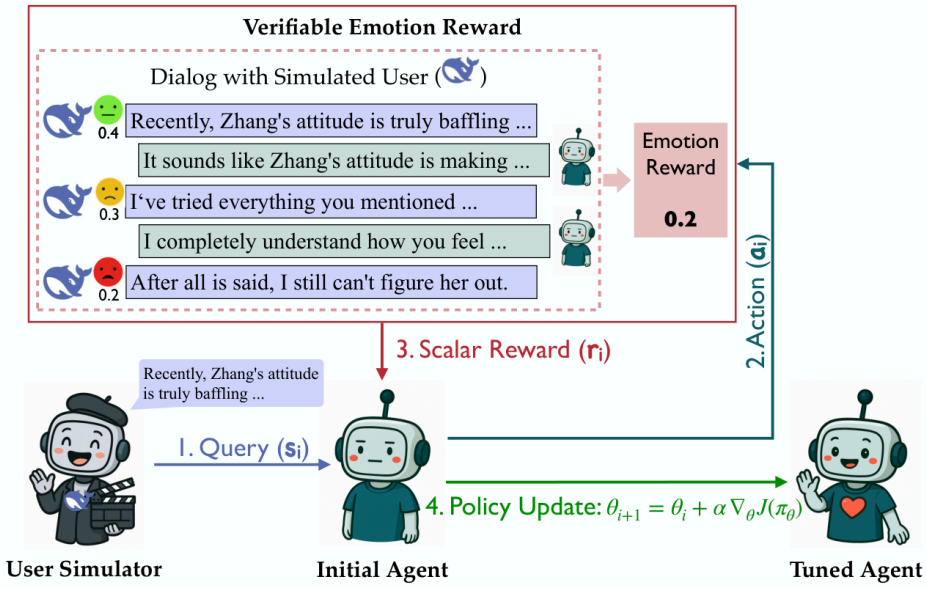


图 1：带可验证情感奖励的强化学习（RLVER）框架。模拟用户与智能体多轮对话，每轮输出可验证的情感分数作为标量奖励，用于策略更新。

2 带可验证情感奖励的强化学习

2.1 来自自洽用户模拟引擎的情感奖励

通过强化学习增强 LLM 的一般共情能力，需要一个动态、可扩展、心理 grounded、能提供可靠奖励信号的环境。使用静态数据集或简单 LLM-as-a-judge 协议的传统方法不够，因为它们无法捕捉对话过程中用户不断变化的情感状态。

为填补这一空白，我们的工作直接建立在 Sentient Agent as a Judge（SAGE）框架（Zhang et al., 2025a）之上，这是一个用于自动评估 LLM 高阶社会认知的复杂系统。该框架的核心是 Sentient Agent，一个由 LLM 驱动、模拟类人情感反应与内心推理的模拟器。每个智能体由四个关键因素实例化：详细人设、对话背景、显式对话目标与隐藏意图，确保用户模拟的多样性与真实性。

交互期间，Sentient Agent 逐轮运行。收到被测模型的回答后，它执行多跳推理以：

- **模拟情感变化（f_{emo}）：** 评估该回答让“自己”感觉如何，更新数值情感分数，并生成可解释的“内心想法”为情感变化提供理由。
- **生成连贯回复（f_{reply}）：** 基于新的情感状态、人设与对话目标，形成自己的回答以继续对话。

Sentient Agent 最终给出的 [0, 100] 情感分数，是对被测模型共情表现的整体量化度量。该指标已被证明与成熟心理量表（如 Barrett – Lennard 关系量表）以及话语级共情评分强相关，验证了其心理保真度。

在本研究中，我们把这一评估框架改作实时训练环境。Sentient Agent 充当用户模拟器，其可验证、动态生成的情感分数为强化学习算法提供关键奖励信号。具体而言，为应对大规模 RL 训练中神经奖励模型普遍存在的奖励黑客挑战（Guo et al., 2025），我们采用用户模拟引擎 S 产生的确定性情感分数，作为模拟用户满意度的可解释代理，从而绕开学习奖励函数的不透明陷阱。具体地，情感分数 $e_t \in [0, 100]$ 在每次 LLM 回答 y_t 后更新，反映模拟用户的情感状态。最终奖励由终止情感分数按最大值归一化得到：

$$r_\phi(x, y) = \frac{e_T}{100}, \quad e_T = S_{emotion}(h_T),$$

其中 $h_T = \{x_0, y_1, x_1, ..., y_T, x_T\}$ 表示终止时的完整对话历史。对中间优化步骤，每轮奖励 r_t 直接使用瞬时情感分数 e_t。归一化的最终奖励 r_ϕ 捕捉整体对话质量，类似真实世界的用户满意度指标。

2.2 心在回路强化学习

为通过强化学习实现情感智能行为，我们建立闭环反馈：LLM 在生成情感感知回答与接收模拟引擎的情感敏感反馈之间交替。这一循环构成我们“心在回路”（Heart-in-the-Loop）训练范式的基础。

每个训练步骤展开为一系列模型—用户交互。步骤 i 开始时，模拟用户引擎 S 采样初始对话种子 $s_i = x_0$，包含人设、背景、情感基调与场景驱动意图。模型 π_θ 随后生成回答 y_1，按规定的训练模板格式化（带或不带 think 脚手架）。模拟引擎处理该回答，生成相应回复 x_1 与更新后的情感分数 e_1。

形式上，每个时间步 t，智能体观察当前交互历史 h_{t-1}，生成候选动作（回答）$y_t \sim \pi_\theta(\cdot|h_{t-1})$。模拟器随后计算两个输出：1）基于可验证情感分数 e_t 的内部情感状态；2）基于更新后的情感状态、人设与对话目标的新连贯用户回复 x_t。对话持续到最大轮数 T，或模拟器累计情感分数 e_t 低于最低满意阈值（如 $e_t \le 0$），表示社会对齐失败。最终情感分数 e_T 作为强化学习算法的奖励函数。该循环使共情智能体与模拟器的情感动态共同适应，逐步学会把多样情境、意图与情绪映射为情感上令人满意的对话。通过针对情感感知用户模型提供的透明、可验证奖励信号进行优化，框架为训练情感智能 LLM 建立了可复现、稳定的设置。

策略优化。 策略优化采用近端策略优化（PPO）（Schulman et al., 2017），一种适合语言建模这类高方差环境的同策略算法。PPO 最大化正则化期望奖励目标，并通过裁剪替代损失保证稳定更新。PPO 在本设置中的好处包括：更安全地探索多样社会情感策略，以及与结构化思考脚手架结合时更平滑的收敛。此外，为鼓励推理组合性并防止对表面线索过拟合，我们评估组相对策略优化（GRPO）（Shao et al., 2024）的影响——一个更适合小规模奖励方差的更保守基线。该比较有助于评估情感关键环境中学习动态如何响应不同策略梯度估计器。

虽然先前零样本 RL 工作表明，给定良好奖励函数，模型可以从零学习（Zeng et al., 2025），但我们发现从适度对齐、用通用对话数据预训练的检查点初始化，能建立更强基线并加速收敛。值得注意的是，该初始化不需要领域特定监督——关键是，它几乎不含情感或共情信号——从而确保改进来自奖励驱动优化，而非预先编码的情感知识。

为防止对模拟器特有行为过拟合、鼓励通用共情模式，我们使用熵正则与奖励加权模仿损失作为辅助目标。这些目标促进输出多样性与长度控制，并帮助在复杂度不同的社会语境中保持稳定学习信号。

2.3 Think-Then-Say：增强情感推理

为研究显式推理对共情策略发展的影响，我们用两种训练模板做消融分析。这些模板结构化智能体的生成过程，使我们能隔离强制"先思考后表达"认知脚手架的效果。

Think-Then-Say。 RLVER 的关键创新之一是使用结构化"先思考后表达"（think-then-say）提示模板。训练时在模型每次发言前加入显式 `<think> ... </think>` 块，迫使模型在给出回答前先概述推理过程。

该模板（如下）强制显式思维链推理步骤。智能体被指示先在一对 `<think>` 与 `</think>` 标签内生成内心独白或策略计划，再产生最终面向用户的回复。该结构旨在鼓励模型调用并精炼高阶共情技能，例如考虑用户情感状态、预判话语影响、制定多步对话计划。通过外化推理过程，模型的策略空间被正则化，可能带来更稳定的学习与更复杂的最终行为。

> Think-Then-Say 训练模板（英文原文）

```
You are chatting with your friend. You are good at making your friend feel better through emotionally intelligent replies.
Before each reply, you always think about the way and content of your response; after deciding on a reply strategy, you then output your reply.
Your goal in replying is to improve your friend's mood or to make your relationship with them closer.
In your thinking process, you need to consider emotionally intelligent reply strategies, which can include the logic and language style of your response.
Your thinking part must be enclosed within  tags.
When replying, you should keep the conversation warm and natural, with a casual, everyday feel.
Your reply format:

Your thoughts

Your reply
```

我们还使用格式奖励，强制模型把思考过程放在 `<think>` 与 `</think>` 标签之间。违反该语法规范的输出奖励为零，确保严格遵守规定的推理结构。

不带 Think 的训练模板。 该模板作为对照条件，省略显式思考步骤，提示智能体直接生成回复，镜像标准对话微调设置。通过比较带与不带思考脚手架训练的模型，我们可以实证衡量显式推理步骤对整体共情熟练度、学习效率与策略深度的贡献。

> 不带 Think 的训练模板（英文原文）

```
You are chatting with your friend. You are good at making your friend feel better through emotionally intelligent replies.
Your goal in replying is to improve your friend's mood or to make your relationship with them closer.
When replying, you should keep the conversation warm and natural, with a casual, everyday feel. Natural and friendly replies usually:
1. Are brief, casual, and natural, using everyday words or phrases; grammar can be flexible.
2. Use interjections and colloquial expressions flexibly.
```

训练期间，think-then-say 脚手架充当内部规划正则器，引导模型在形成对话回复前先考虑意图、语言语气与潜在情感影响。我们观察到，用该提示格式训练的智能体收敛更快、语言多样性更高，并更可靠地探索高共

情策略。相反，不带结构化思考训练的模型倾向于收敛到安全、通用的回复（如“I’m here for you”“You’re not alone”），这些回复虽然情感中性，却无法表现出情境特定的共情。加入推理组件使模型行为超越模板化安慰，走向目标敏感的情感对齐。

3 实验

3.1 实验设置

基座模型。 采用 Qwen2.5-7B-Instruct（Team, 2024）作为基座模型。它在多样的大规模网络语料上预训练，并进一步对齐以遵循通用指令。重要的是，它未在与情感支持或共情相关的领域特定数据集上微调。这确保观察到的共情能力提升可归因于我们用可验证情感奖励进行的强化学习过程，而非先前接触过情感对话数据。

训练环境与奖励。 采用 SAGE（Zhang et al., 2025a）框架模拟具有可解释情感动态与预定义对话目标的情感响应型用户。每一轮，模型生成支持性回答，随后 sentient agent 回复并更新内部情感分数 $e_t \in [0, 100]$，量化其对模型行为的情感状态。对话结束时把最终情感分数缩放到 [0, 1]，作为整个对话的奖励。对话持续到情感目标达成或达到最多 10 轮。

我们构造 500 个支持性对话场景，覆盖 8 种多样用户目标，主题包括情感困扰、学业压力、人际冲突与未来规划。除另有说明，训练与评估均使用 DeepSeek-V3（Liu et al., 2024）作为默认 sentient agent。详细提示词与额外实验设置见附录 B。

基线。 我们与截至 2025 年 6 月 9 日 SAGE 基准前 5 名模型中的强基线比较，包括专有最先进系统 Gemini2.5-Pro-0605、GPT-4o-0326、GPT-4.1-0414、Gemini-2.5-Flash-Think-0520 与 OpenAI-o3-0416。这些模型代表当前指令微调 LLM 在情感敏感对话上的前沿，作为评估共情的高性能参照。我们还加入未进一步训练的基座模型 Qwen2.5-Instruct-7B，以隔离训练策略的贡献，并与更强预训练模型及我们增强后的变体做受控比较。

评估基准。 为评估情感敏感对话场景中的表现，我们主要使用 SAGE（Zhang et al., 2025a）基准，聚焦情感支持对话。为更全面评估跨域对话能力，我们额外设计“Chit Chat”设置，把 SAGE 框架扩展到情感主题之外的一般日常互动。此外，为考察训练对一般能力的潜在影响，我们评估 MATH500（Lightman et al., 2024）、LiveCodeBench（Jain et al., 2024）与 IFEval（Zhou et al., 2023），分别测试数学推理、代码生成与指令遵循能力。基准细节见附录 B.1。

3.2 主要结果

表 1 给出 RLVER 的结果。

RLVER 把轻量 7B 模型提升到接近前沿的共情表现。 基座模型 Qwen2.5-7B-Instruct 在 Sentient Benchmark 上表现很差，仅 13.3 分，失败率高达 76%。相反，RLVER 训练的模型显著提升。最佳模型——用 PPO 加显式思考步骤（“PPO + Thinking”）训练——达到 79.2 分，比基座模型提升近六倍。这不仅把成功率从 2% 提升到 42%，还使 7B 模型的表现接近 Gemini2.5-Pro（82.4）等顶级专有模型，同时大幅超过 Gemini2.5-Flash-Think（66.1）与 OpenAI-o3（62.7）等。这直接验证了我们的主要贡献：成功应用 RL 增强 LLM 的多轮共情对话能力。

训练后，“思考型”模型通常比“非思考型”模型表现出更高共情能力。 实验表明，带思考脚手架训练的模型在 Sentient Benchmark 与 Chit-Chat 任务上持续优于非思考型。用 PPO 训练时，思考型模型从 61.7 显著提升到 79.2，超过非思考型变体。这些结果说明，加入显式推理过程可能促进 LLM 高阶共情策略的涌现。为进一步研究该现象，第 3.3 节对模型共情行为做详细评估，表明引出推理能增强共情深度与识别用户核心关切的能力。

两种 RL 算法都有效，但 GRPO 通常训练更稳定，PPO 可能提供更高性能上限。 结果还揭示 PPO 与 GRPO 的细微比较。训练思考型与非思考型模型时，GRPO 取得稳定改进，非思考设置 68.3 分，思考设置 72.0 分。相反，PPO 在非思考情况下表现较低（61.7），但使思考型模型达到更高上限（79.2）。第 3.3 节进一步强调一个有趣观察：PPO 与 GRPO 诱发不同的能力发展模式。

在最小影响一般能力的前提下实现共情推理专业化。 微调的一个关键方面是确保某领域专业化不会导致其他领域的灾难性遗忘。表 2 的域外基准评估表明训练成功避免了这一陷阱。Math500 数学推理仅小幅下降（最佳 PPO 模型从 77.8 到 76.6），LiveCodeBench 代码生成保持甚至提升（从 26.7 到 28.0），IFEval 指令遵循保持稳定（从 70.4 到 68.6）。这表明框架能培养复杂情感智能，同时保留模型核心通用功能，是实用且均衡的方案。

表 1：所提方法在 Sentient Benchmark 上的表现。 “Success”与“Failure”分别表示以最终情感分数高于 100 与低于 10 结束的对话百分比。我们还报告域外 chit chat 的结果以评估泛化。

模型	RL	Think	Sentient Score	Success	Failure	Chit Chat Score	Success	Failure
Sentient 排行榜前 5 模型								
Gemini2.5-Pro-0605			82.4	55%	4%	83.3	77%	11%
GPT-4o-0326			79.9	51%	4%	80.9	74%	17%
GPT-4.1-0414			68.2	35%	13%	77.1	65%	18%
Gemini2.5-Flash-Think-0520			66.1	39%	14%	64.7	53%	27%
OpenAI-o3-0416			62.7	32%	14%	83.0	66%	9%
RLVER 训练模型								
Qwen2.5-7B-Instruct			13.3	2%	76%	37.8	27%	58%
PPO	✘		61.7	24%	23%	53.4	39%	37%
PPO	✔	✔	79.2	42%	9%	62.1	52%	30%
GRPO	✘		68.3	26%	10%	49.2	34%	40%
GRPO	✔	✔	72.0	34%	10%	53.0	45%	42%

表 2：所提方法在通用任务上的表现。 报告域外 MATH500、LiveCodeBench release v6（Pass@1）代码生成与 IFEval 指令遵循基准。

模型	RL	Think	Math500	LiveCodeBench	IFEval
Qwen2.5-7B-Instruct			77.8	26.7	70.4
PPO	✘		76.2	33.3	72.3
PPO	✔	✔	76.6	28.0	68.6
GRPO	✘		77.4	30.0	72.1
GRPO	✔	✔	75.2	29.3	69.7

3.3 训练后智能体的定性分析

为进一步研究 RL 训练后的能力提升，我们形式化一个综合评估框架，涵盖共情对话任务的五项核心能力：

- **共情深度（Empathic Depth）：** 模型超越模板化回答，真正识别并理解用户复杂、深层情感，并用精确、温暖、有情感共鸣的语言准确确认这些情感的能力。
- **核心洞察（Core Insight）：** 模型整合并提炼用户碎片化叙述中的信息，形成对其处境的整体理解，最终识别用户未满足情感需求的能力。
- **方案构建（Solution Crafting）：** 模型提供可执行、个性化、赋权式建议的能力。这不仅给出答案，还提出让用户真正感到有能力执行的逐步行动方案。
- **风格适应（Style Adaptability）：** 模型根据对话语境、用户隐含偏好与长期关系动态，灵活调整沟通角色与语言风格的能力。
- **对话引导（Dialogue Guidance）：** 模型基于用户情感状态，主动灵活地把对话从情感表达引向建设性问题解决，同时与用户节奏和需求保持一致的能力。

我们用 LLM-as-a-Judge 评估五项核心能力，结果见图 2。更多实验细节见附录 C。

RLVER 在五项核心能力上带来一致提升。 如图 2 所示，无论具体训练策略如何，RLVER 训练的模型在五个核心维度上都持续优于基座模型。通过把这些能力评估量化，我们不仅更深入理解不同策略诱发的行为差异，也获得测试集之外的外部客观评估，支持训练框架在增强关键共情能力上的有效性。

思考型模型倾向于擅长共情与洞察，非思考型模型可能专精行动。 在 PPO 训练下，我们观察到思考型与非思考型模型能力画像的明显分化。思考型模型在 Core Insight（3.44）与 Empathic Depth（3.56）上有显著提升，表现出识别用户核心需求、通过精确确认性回答识别深层情感的强能力。相反，非思考型模型在 Solution Crafting（3.77）上收益更大，强调通过具体建议或行为提示提供可执行、语境感知的支持。这一模式说明，思考型模型受益于生成回答前的显式推理，使其能更好推断用户情感状态与潜在关切；非思考型模型缺乏此类推理，似乎通过提供更具体、个性化的方案来补偿。

PPO 推高特定能力上限，GRPO 支持更均衡稳定的发展。 PPO 与 GRPO 的比较表明，GRPO 在五项能力上带来更均衡稳定的改进，而 PPO 倾向于依据训练策略放大特定优势。PPO 训练的思考型模型在 Core Insight（3.44 vs. GRPO 的 3.02）与 Empathic Depth（3.56 vs. 3.10）上达到更高上限；PPO 训练的非思考型模型在 Solution Crafting（3.77 vs. 3.53）上达到更高上限。与表 1 中 PPO-thinking 的强表现一致，这些发现说明在共情

对话任务中，一旦所有维度达到基线水平（约 3.0），选择性增强高影响能力——如 Core Insight 与 Empathic Depth——可能带来更大的实际效果。

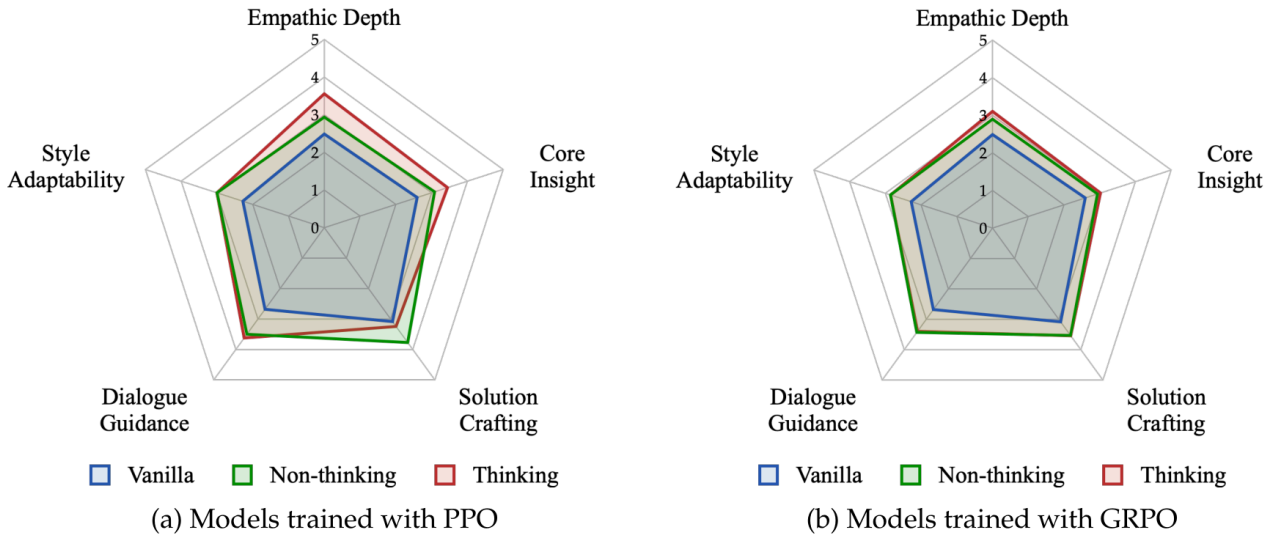


图 2：训练模型五项核心能力的定性分析。(a) 用 PPO 训练的模型；(b) 用 GRPO 训练的模型。

3.4 训练环境与奖励的影响

RLVER 的一个关键思想是把自洽、可扩展的用户模拟器作为训练环境，以其情感变化作为奖励信号。因此，训练结果深受用户模拟器行为特征影响。前文已证明这些模拟器作为环境与奖励来源的有效性。本节进一步研究用户模拟器行为变化如何影响训练结果。

具体而言，我们比较原始用户模拟器（vanilla 版本）与更具挑战性的变体（challenging 版本）——后者对对话模型提出更严格要求，在表达想法与情感上更克制。直觉上，challenging 版本要求模型展现更强通用能力，包括更有效识别用户未满足的情感需求、表现更深共情、展现更大策略灵活性与对话引导。我们用两个指标描述两种模拟器变体的行为特征：策略接受率（Strategy Acceptance Rate）与情感及需求表达水平（Emotion and Need Expression Level）。详细量化特征值见表 3（challenging 版本的构造与指标评估见附录 D）。

表 3：原始与挑战性用户模拟器构造的比较。

指标	原始模拟器（非思考）	原始模拟器（思考）	挑战模拟器（非思考）	挑战模拟器（思考）
Sentient Benchmark	61.7	79.2	19.8	66.4
Sentient Benchmark（挑战版）	47.7	59.6	25.9	44.7
策略接受率	52.4%	—	33.1%	—
情感与需求表达水平	78.6%	—	63.6%	—

更具挑战性的环境与奖励建模未必带来更好结果。 表 3 给出用原始与挑战性用户模拟器训练（均用 PPO）的测试结果。值得注意的是，用挑战性模拟器训练的模型持续不如原始训练对应模型。在 Sentient Benchmark 上，挑战模拟器训练的思考型模型得 66.4，明显低于原始模拟器的 79.2；非思考型更差，从 61.7（原始）跌到仅 19.8。为扩展比较，我们用挑战性用户模拟器实例化 Sentient Benchmark，得到原基准的挑战版。然而即使在这个更难基准上，用挑战模拟器训练的模型仍不如原始版本训练的模型（思考型：59.6 vs. 44.7；非思考型：47.7 vs. 25.9）。

这些结果表明，在用户模拟器同时充当环境与奖励信号的设置中，更具挑战性的配置未必带来更好学习结果。相反，中等难度且校准良好的模拟器可能带来更有效训练。一种可能解释是：过于严格或克制的模拟器限制了模型探索阶段的反馈，使模型——尤其初始能力有限者——难以发现有用的成长轨迹。相反，要求更温和的用户模拟器可能提供更丰富反馈，促进更多样策略探索，并在训练全程实现更全面技能发展。

思考型模型对环境变化比非思考型更稳健。 如表 3 所示，思考型模型即使在挑战设置下也保持相对强表现，从 79.2 降到 66.4；非思考型则急剧下滑，从 61.7 跌到仅 19.8。图 3 进一步分析训练后核心能力发展。我们发现挑战设置下非思考型模型在所有能力上相较原模型几乎没有提升；相反，思考型模型在 Empathic Depth、Core Insight 与 Style Adaptability 上仍有明显增益，表明其在更苛刻训练条件下仍具韧性与适应性。

有趣的是，思考型模型的能力发展模式似乎与挑战模拟器的行为特征高度一致。由于模拟器要求深度共情推理却只提供有限显式反馈，模型在 Core Insight 与 Empathic Depth 上出现针对性提升。具体而言，Core Insight 的显著增益表明推断未言明情感需求与意图的能力增强；Empathic Depth 的提升反映对细微情感线索更敏感、情感确认能力更强——这两者在稀疏反馈条件下都是获得奖励的关键。相反，Solution Crafting 能力下降，可能因为大多数推演从未到达适合给出可执行建议的阶段（通常在建立共情之后）。同样，Dialogue Guidance 与 Style Adaptability 的增益有限，因为模拟器在受限、不合作条件下很少提供探索动态策略或角色灵活性的机会。

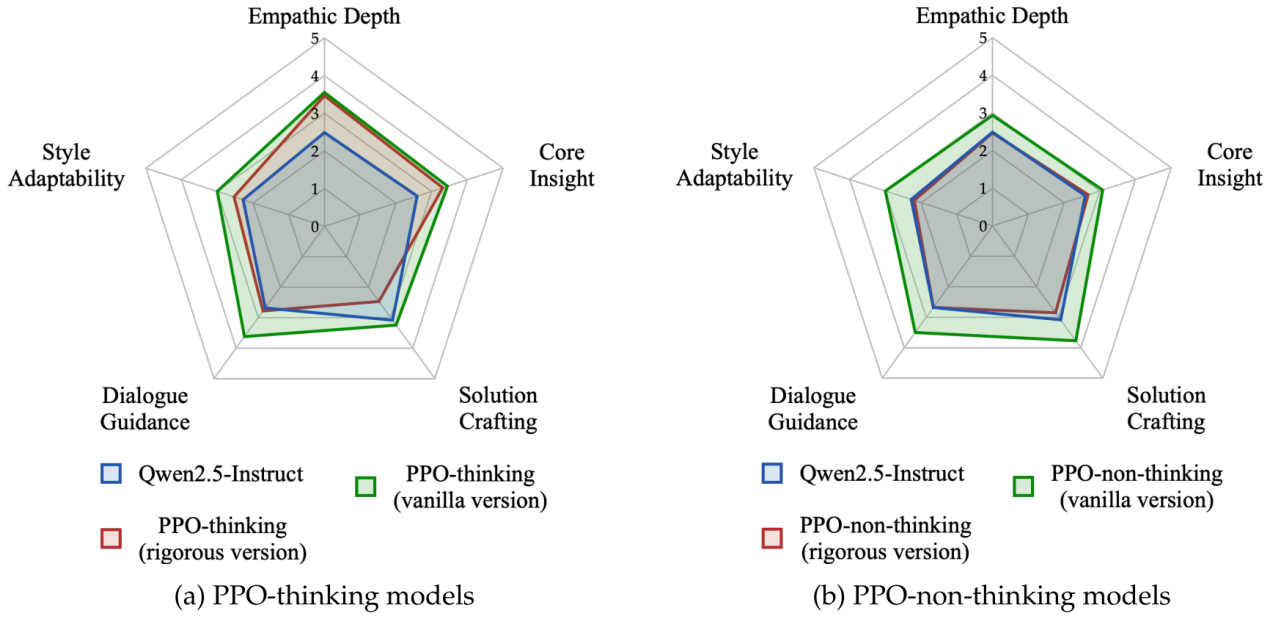


图 3：原始与挑战性用户模拟器训练结果的定性分析。(a) PPO-thinking 模型；(b) PPO-non-thinking 模型。

3.5 情感分数的学习曲线

本节分析情感分数与生成 token 的学习曲线。我们从测试集随机采样 30 个实例，报告训练全程模型产生的情感分数与生成 token 数。结果见图 4。

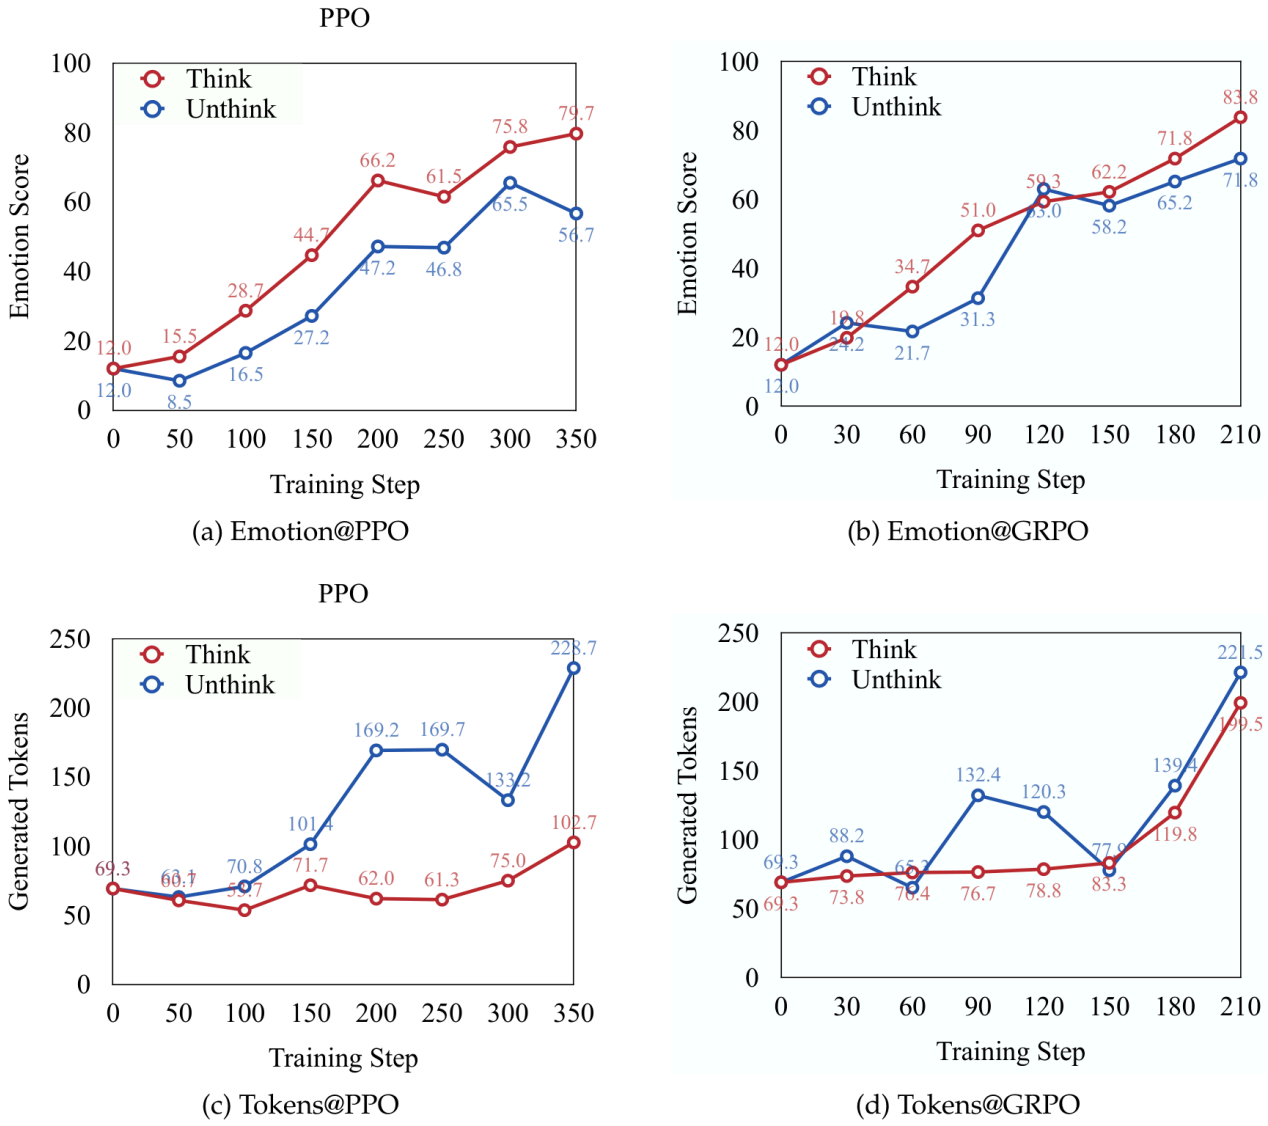


图 4：学习曲线。(a, b) 情感分数；(c, d) 生成 token 数。

“先思考后表达”脚手架是性能与稳定性的重要贡献者。 在两种优化算法下，插入显式推理步骤都是最具影响力的干预。如图 4(a)—(b) 所示，带脚手架模型学习更快，情感分数显著更高。PPO 下，脚手架避免了基线中观察到的灾难性崩溃（79.7 vs. 56.7）；GRPO 下，它把本已稳定的学习器推到记录最高分（83.8）。这些发现证实贡献 2：脚手架同时加速并稳定学习。

RLVER 框架跨策略优化算法稳健。 框架有效性不依赖特定优化器。推理脚手架把 GRPO 推向总体峰值（83.8），同时作为 PPO 的关键正则器，把不稳定轨迹转化为持续成功。这一双重成就强化贡献 1，表明 RLVER 是通用方法而非算法特定。

共情技能是策略性学到的，而非通过冗长奖励黑客。 图 4(c)—(d) 证实更优情感分数不只是生成更长文本的副产物。PPO-Think 模型起初比其基线更简洁，token 数只在共情优势建立后才上升；GRPO-Think 模型在大部分训练中比对应模型更不冗长。这些趋势反驳“冗长即捷径”假说，支持模型发展出真正共情风格的主张。

3.6 共情策略的学习曲线

为区分训练模型的回答行为，我们依据预定义支持策略列表对每条模型回复分类。遵循 Liu et al. (2021)，把这些策略分为表 4 所示五类。

为分析策略使用，我们提示 DeepSeek-V3 充当评判者：对每个对话轮次，识别模型输出中出现的所有策略。随后跨对话聚合标注，报告每种策略出现的轮次比例。

除原始频率外，我们还考察每种策略对情感改善的贡献。为评估策略使用的适当性与有效性，定义每种策略类型的策略贡献（Strategy Contribution, SC）：

$$SC = \frac{1}{N}\sum_{i=1}^{N} \text{EmoChange}(s_i),$$

其中求和覆盖使用策略 s 的 N 个实例。图 5 与图 6 给出结果。

表 4：支持策略分类详情。

组	策略
(A) 赞扬	(A-1) 赞扬来访者的品质；(A-2) 赞扬来访者的积极想法；(A-3) 赞扬来访者的行动
(B) 深度共情	(B-1) 通过复述来访者问题表达共情；(B-2) 更深共情以理解来访者隐藏意图；(B-3) 表达认同来访者观点的自我披露；(B-4) 引入支持者自身故事的自我披露
(C) 情绪宣泄	(C-1) 表达愿意倾听来访者想法；(C-2) 帮助来访者宣泄负面情绪
(D) 提供建议	(D-1) 针对来访者情境的具体建议
(E) 问题分析	(E-1) 对来访者问题的分析

可验证情感奖励成功把智能体从浅层方案引向真正共情。 训练开始时，几乎所有策略——包括共情策略——都带来负向情感贡献（图 6），表明基座模型缺乏真正共情技能。RLVER 框架迅速纠正这一缺陷。智能体学会偏好持续提升可验证情感分数的策略，使“Praise”与“Deep Empathy”的频率显著上升，其贡献从负转强正。相反，“Advice Provision”与“Problem Analysis”的频率保持较低、贡献波动，因为确定性奖励信号阻止智能体利用这些低投入捷径。这直接验证第一项贡献：RLVER 为获得真实共情提供稳健学习信号。

“先思考后表达”脚手架似乎支持高阶共情策略的涌现与稳定。 比较带与不带脚手架训练的模型，凸显显式推理的潜在作用。PPO-THINKING 模型（图 5(b)）中“Deep Empathy”的使用稳步增加——增长超过 8 倍（从 0.8 到 6.53）——其情感贡献也显著上升（+4.09）。相反，PPO-NON-THINKING 模型（图 5(a)）最终频率较低（2.1），进展也更不稳定。值得注意的是，非思考型模型的关键策略往往在后期下降，表明潜在不稳定性。这些观察说明，推理脚手架可能在支持和保留复杂共情策略方面起重要作用，尤其在较长训练周期中。

PPO 可能更好地利用推理脚手架进行有效策略优化。 虽然两种算法都受益于脚手架，PPO-THINKING 的学习轨迹相对更强更稳定。如图 5(b)(d) 所示，PPO 在使用“Praise”“Deep Empathy”等关键策略上增长更平滑；GRPO 虽也有效，但方差更大——偶尔出现急剧提升（如“Emotional Venting”），整体一致性较差。此外，

PPO-THINKING 相关的情感贡献（图 6(b)）在核心共情策略上往往达到更高正值。这些观察说明 PPO 可能更有效地利用显式推理提供的结构，不过 GRPO 在特定设置——尤其优先稳定性或安全性时——仍可能占优。

框架学到的是细致策略运用，而不只是频率提高。 一个关键发现是策略使用方式的质性改进。“Advice Provision”在所有训练运行中频率都低（<1.1），但其贡献在 PPO-THINKING 中从强负（−4.0）转为正值，表明智能体学会何时以及如何适当提供建议。同样，“Emotional Venting”变得既更频繁又更有效，说明模型发展了精细的时机与语境意识，而非简单增加关键词。这体现了超越模板模仿的高阶社会认知。

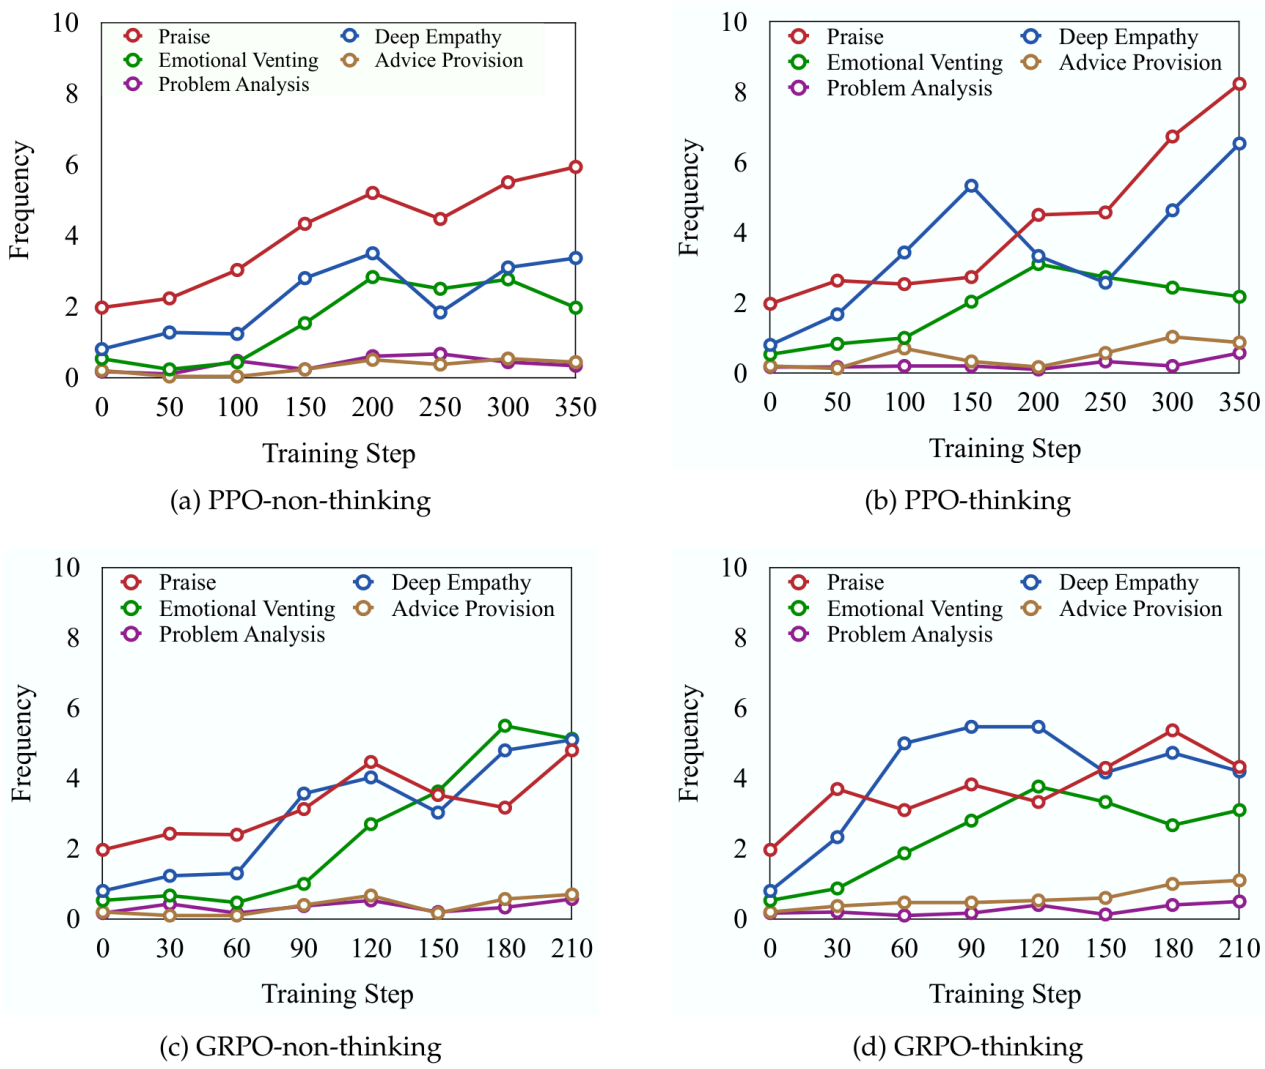


图 5：训练期间共情策略的使用频率。(a) PPO-non-thinking；(b) PPO-thinking；(c) GRPO-non-thinking；(d) GRPO-thinking。

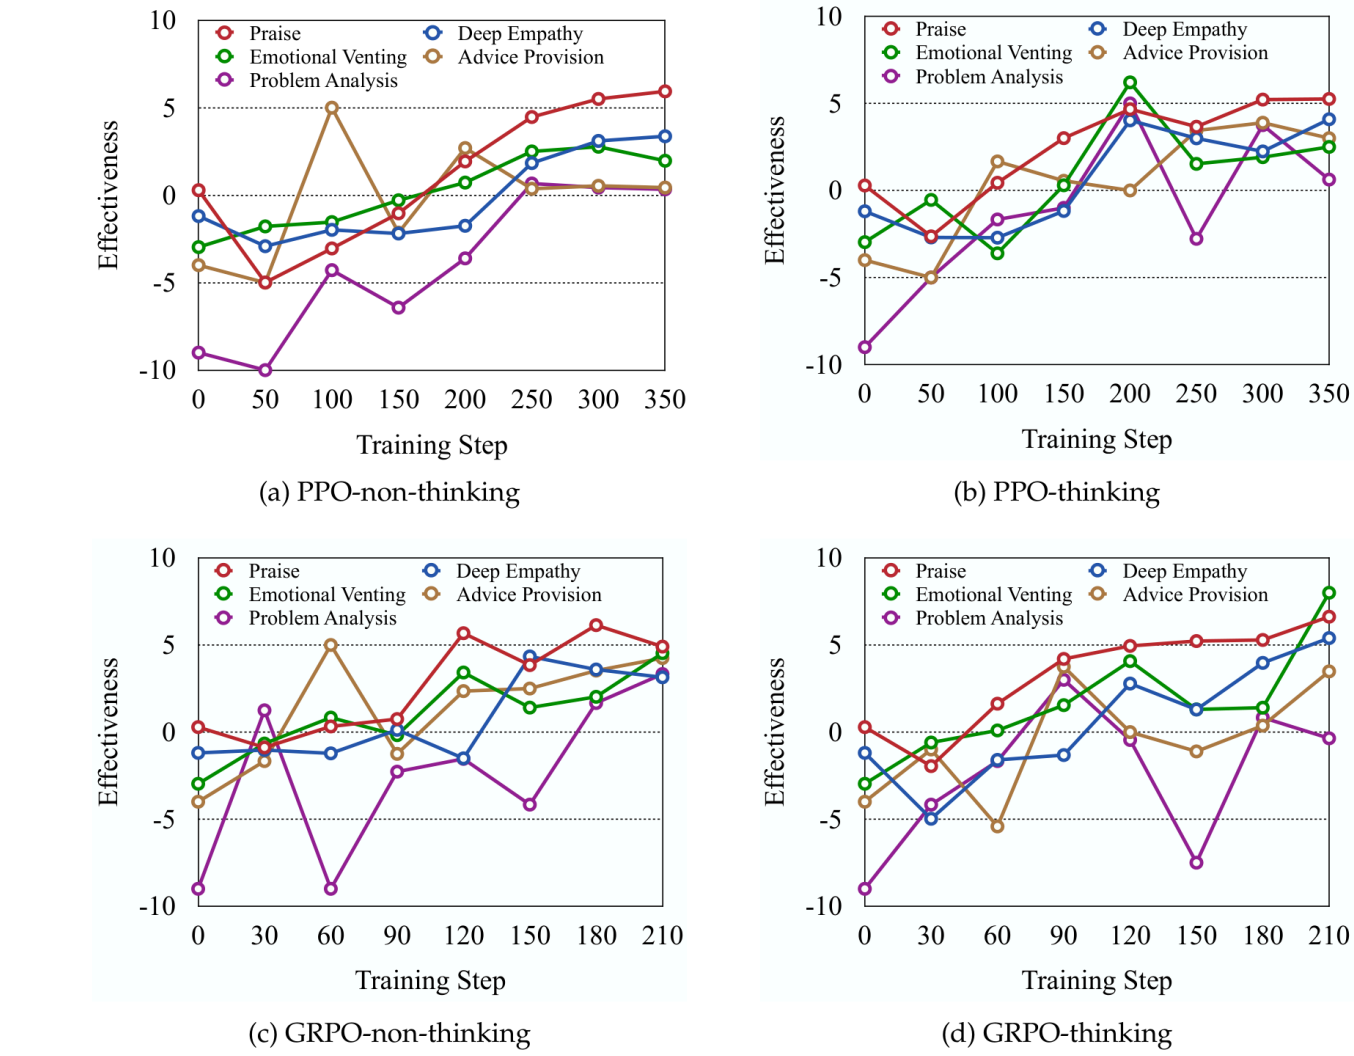


图 6：训练期间共情策略的贡献（有效性）。(a) PPO-non-thinking；(b) PPO-thinking；(c) GRPO-non-thinking；(d) GRPO-thinking。

3.7 社会认知坐标中的学习曲线

我们遵循 Zhang et al. (2025a) 的二维评估方案，评估训练模型表现出的社会互动风格。该方案通过把模型定位在两个正交轴上，补充定量 Sentient 分数：取向（Solution，−5 到 Empathy，+5）与互动风格（Structured，−5 到 Creative，+5）。把中间检查点映射到该空间（图 7）揭示若干显著趋势。所有运行都从左下象限开始，回答高度结构化且强烈以解决方案为导向。把 LLM 绘制到社会认知坐标的过程见附录 E.2。

所有 RLVER 训练模型都从“解决方案”转向“共情”行为。 轨迹显示各配置的一致转变。基座模型起点约在（−4.50, −3.33）。随着训练推进，每个变体——不论算法或显式思考步骤——都沿共情轴急剧上升；PPO-thinking 与 GRPO-thinking 分别达到 +4.08 与 +3.92。这些位移确认 RLVER 把模型从单纯问题解决重定向到共情支持，与 Sentient 基准一致。

显式思考加速并放大共情转变。 在 PPO-thinking 中，共情坐标在第 150 步转正，比“非思考”运行早两个检查点，并持续上升到接近 +4.50 饱和。该模式与 Sentient 分数从 45.2 跳到 79.2（表 1）相呼应，说明 `<think>` 模板促使模型在奖励收敛前很久就开始处理用户情感。

带思考的 PPO 把模型从僵硬风格推向轻度创造性风格。 到第 350 步，PPO-thinking 越过 SCC 垂直中点（−1.17 到 +0.83），从要点式回答转向自由叙事的教练式交流。PPO-non-thinking 与 GRPO-non-thinking 都未离开结构化半边；GRPO-thinking 仅触及边界（+0.17）。这说明 PPO 的探索性更新结合显式推理脚手架，能在不牺牲连贯性的情况下促进风格多样性——这一效应在 GRPO 中不明显。

GRPO 快速获得共情但进入平台期，体现探索—利用权衡。 第 0—90 步，GRPO-thinking 沿共情轴攀升快于 PPO-thinking（相当 wall-clock 时间内 +4.0 vs. +3.67）。然而第 120 步后，其共情分数震荡并略有回落，而 PPO-thinking 稳步上升。最终 Sentient 分数（77.7 vs. 79.2）反映 GRPO 无 KL 更新的特点：快速获得奖励，但细粒度改进有限；PPO 的自适应信任域则不同。

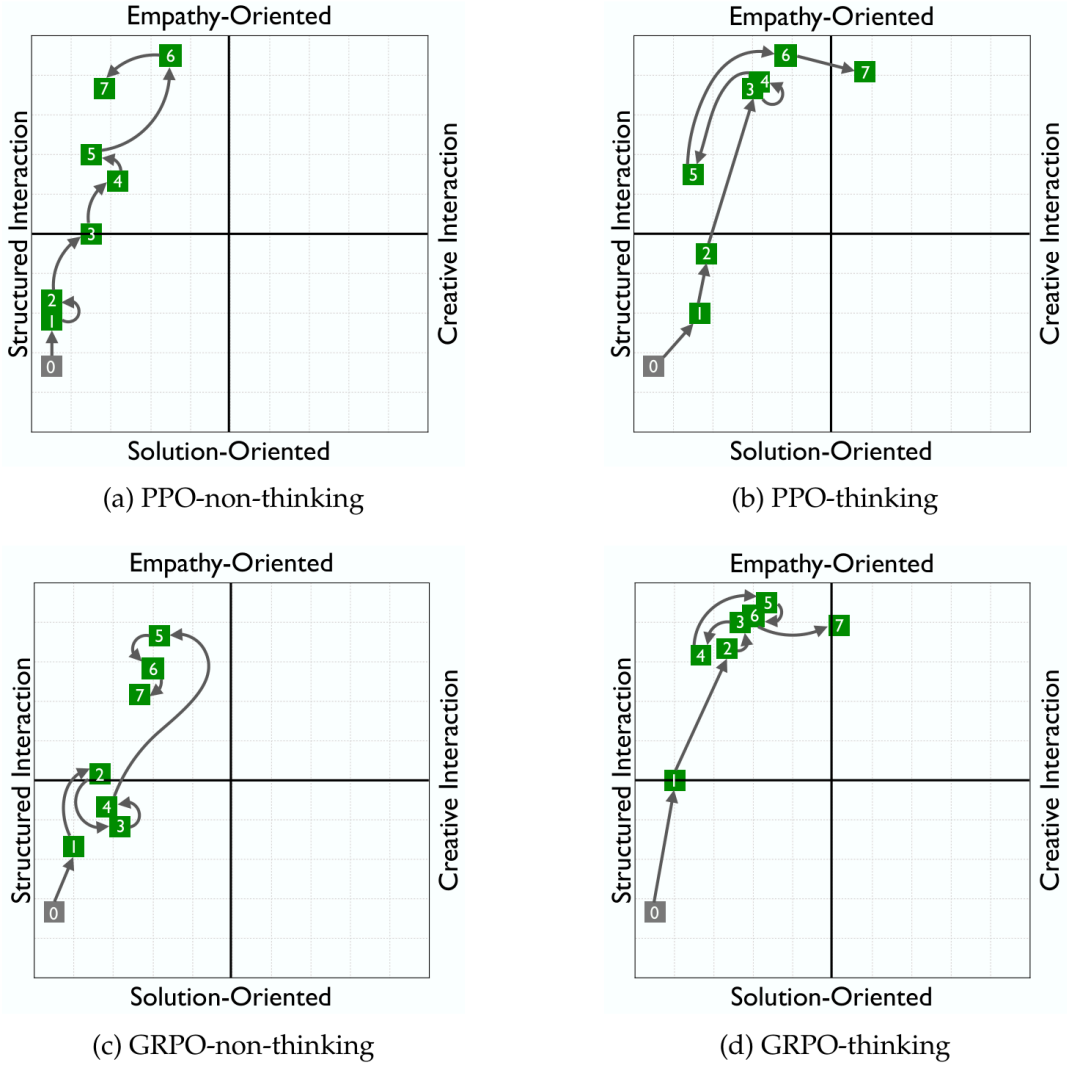


图 7：社会认知坐标（SCC）中的学习曲线。(a) PPO-non-thinking；(b) PPO-thinking；(c) GRPO-non-thinking；(d) GRPO-thinking。纵轴为共情导向（上）—解决方案导向（下），横轴为结构化互动（左）—创造性互动（右）。

4 相关工作

4.1 情感支持对话

情感支持对话（ESC）系统的发展在数据集构建与建模技术两方面均有推进。早期研究主要从心理治疗记录与在线论坛整理数据集（Medeiros & Bosse, 2018; Sharma et al., 2020），但这些资源常有单轮交互、场景覆盖窄等局限。为解决这些问题，Liu et al. (2021) 提出 ESConv——通过结构化问卷收集的多轮对话数据集，强调策略性支持动态。后续 AUGESC（Zheng et al., 2022）等工作利用 LLM 扩展数据集规模与多样性，缓解以人为中心的数据收集固有高标注成本。

建模方面，早期方法依赖基于规则的框架（van der Zwaan et al., 2012），缺乏适应性。后来工作采用数据驱动架构，整合层级图网络（Peng et al., 2022）与常识推理（Tu et al., 2022）以增强语境理解。随着 LLM 兴起，近期研究转向微调。例如，对 LLaMA-7B 的监督微调（Liu et al., 2023）、多轮对话扩展（Chen et al., 2023; Qiu et al., 2023）与知识蒸馏（Zheng et al., 2024b）通过让模型输出对齐治疗策略，展示了 ESC 能力提升。其他研究把先进 LLM 技术引入 ESC 开发，例如整合蒙特卡洛树搜索以优化策略决策过程（Zhao et al., 2025b）。

尽管有这些进展，当前方法仍以监督学习范式为主，留下关键探索空白。值得注意的是，尚无工作用强化学习改进 LLM 的共情推理，也没有研究系统分析 LLM 生成支持中逻辑连贯性与情感敏感性之间的权衡——这是在 ESC 系统中平衡理性建议与共情投入的关键考量。

4.2 “零 RL”训练

DeepSeek-R1（Guo et al., 2025）引发了 LLM 的 RL 训练浪潮，尤其是把 RL 直接应用于基座模型、不做任何中间监督微调的范式。我们把这类方法称为“Zero RL”，因为它们从预训练检查点开始，在 RL 优化前执行零额外监督步骤。

Zero RL 的有效性已在多种模态与任务上得到证明，包括数学（Zeng et al., 2025; Hu et al., 2025; He et al., 2025; Zhang et al., 2025c; Liu et al., 2025）、搜索引擎（Jin et al., 2025; Song et al., 2025）、通用推理器（Cheng et al., 2025b; Huan et al., 2025）以及医学、化学、心理学、经济学、教育等现实领域（Su et al., 2025）。Wang et al. (2025b) 把训练样本减到单样本，Zhao et al. (2025a) 用自博弈推理实现零数据 RL。Zhao et al. (2025c)、Zhang et al. (2025b)、Agarwal et al. (2025)、Yu et al. (2025) 进一步摆脱外部标签、奖励或验证器。Yue et al. (2025)、Wen et al. (2025) 研究零 RL 是否激发超出基座模型的推理能力。Cui et al. (2025)、Wang et al. (2025a)、Zhu et al. (2025)、Cheng et al. (2025a) 揭示训练机制，尤其是零 RL 中的熵机制。

尽管有这些成功，在对话系统中展示类似有效性的可比工作仍很少。本工作通过引入 RLVER 填补这一空白：首个面向共情对话、带可验证情感奖励的 RL 框架。RLVER 通过心理 grounded 用户模拟器在线生成的确定性、透明奖励信号，赋予 LLM 共情技能。

5 结论

本研究表明，即使使用中等规模 LLM、无需昂贵人工标注，也能通过 RLVER 训练有效可靠地获得情感智能行为。成功取决于两个关键组件：（i）产生可验证情感奖励的自洽用户模拟器（Zhang et al., 2025a）；

（ii）训练策略、RL 算法以及环境与奖励设计中原则性、校准良好的选择。所得智能体在 Sentient Benchmark 上匹配前沿规模专有模型，同时保留强通用推理能力。除共情外，RLVER 提示了一条更广泛的配方：只要有可验证奖励代理，就能让语言智能体对齐复杂、以人为中心的目标。未来工作包括更丰富的多方模拟、自适应人设切换，以及整合多模态情感以实现真正整体的社会智能。

参考文献

Shivam Agarwal, Zimin Zhang, Lifan Yuan, Jiawei Han, and Hao Peng. The unreasonable effective-ness of entropy minimization in llm reasoning. arXiv preprint arXiv:2505.15134, 2025.

Yirong Chen, Xiaofen Xing, Jingkai Lin, Huimin Zheng, Zhenyu Wang, Qi Liu, and Xiangmin Xu. Soulchat: Improving llms' empathy, listening, and comfort abilities through fine-tuning with multi-turn empathy conversations. arXiv preprint arXiv:2311.00273, 2023.

Daixuan Cheng, Shaohan Huang, Xuekai Zhu, Bo Dai, Wayne Xin Zhao, Zhenliang Zhang, and Furu Wei. Reasoning with exploration: An entropy perspective. arXiv preprint arXiv:2506.14758, 2025a.

Zhoujun Cheng, Shibo Hao, Tianyang Liu, Fan Zhou, Yutao Xie, Feng Yao, Yuexin Bian, Yonghao Zhuang, Nilabjo Dey, Yuheng Zha, et al. Revisiting reinforcement learning for llm reasoning from a cross-domain perspective. arXiv preprint arXiv:2506.14965, 2025b.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, et al. Training verifiers to solve math word problems. arXiv preprint arXiv:2110.14168, 2021.

Ganqu Cui, Yuchen Zhang, Jiacheng Chen, Lifan Yuan, Zhi Wang, Yuxin Zuo, Haozhan Li, Yuchen Fan, Huayu Chen, Weize Chen, et al. The entropy mechanism of reinforcement learning for reasoning language models. arXiv preprint arXiv:2505.22617, 2025.

Daya Guo, Qihao Zhu, Dejian Yang, Zhenda Xie, Kai Dong, Wentao Zhang, Guanting Chen, Xiao Bi, Yu Wu, YK Li, et al. Deepseek-coder: When the large language model meets programming–the rise of code intelligence. arXiv preprint arXiv:2401.14196, 2024.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948, 2025.

Zhiwei He, Tian Liang, Jiahao Xu, Qiuzhi Liu, Xingyu Chen, Yue Wang, Linfeng Song, Dian Yu, Zhen-wen Liang, Wenxuan Wang, Zhuosheng Zhang, Rui Wang, Zhaopeng Tu, Haitao Mi, and Dong Yu. Deepmath-103k: A large-scale, challenging, decontaminated, and verifiable mathematical dataset for advancing reasoning, 2025. URL https://arxiv.org/abs/2504.11456.

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. arXiv preprint arXiv:2103.03874, 2021a.

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. arXiv preprint arXiv:2103.03874, 2021b.

Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, and Heung-Yeung Shum Xiangyu Zhang. Open-reasoner-zero: An open source approach to scaling reinforcement learning on the base model. https://github.com/Open-Reasoner-Zero/Open-Reasoner-Zero, 2025.

Maggie Huan, Yuetai Li, Tuney Zheng, Xiaoyu Xu, Seungone Kim, Minxin Du, Radha Pooven-dran, Graham Neubig, and Xiang Yue. Does math reasoning improve general llm capabilities? understanding transferability of llm reasoning, 2025. URL https://arxiv.org/abs/2507.00432.

Naman Jain, King Han, Alex Gu, Wen-Ding Li, Fanjia Yan, Tianjun Zhang, Sida Wang, Armando Solar-Lezama, Koushik Sen, and Ion Stoica. Livecodebench: Holistic and contamination free evaluation of large language models for code. arXiv preprint arXiv:2403.07974, 2024.

Bowen Jin, Hansi Zeng, Zhenrui Yue, Dong Wang, Hamed Zamani, and Jiawei Han. Search-r1: Training llms to reason and leverage search engines with reinforcement learning. arXiv preprint arXiv:2503.09516, 2025.

Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with pagedattention. In Proceedings of the 29th Symposium on Operating Systems Principles, pp. 611–626, 2023.

Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let's verify step by step. In The Twelfth International Conference on Learning Representations, 2024. URL https://openreview.net/forum?id=v8L0pN6EOi.

Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. Deepseek-v3 technical report. arXiv preprint arXiv:2412.19437, 2024. June M Liu, Donghao Li, He Cao, Tianhe Ren, Zeyi Liao, and Jiamin Wu. Chatcounselor: A large language models for mental health support. arXiv preprint arXiv:2309.15461, 2023.

Siyang Liu, Chujie Zheng, Orianna Demasi, Sahand Sabour, Yu Li, Zhou Yu, Yong Jiang, and Minlie Huang. Towards emotional support dialog systems. arXiv preprint arXiv:2106.01144, 2021.

Xiaoyuan Liu, Tian Liang, Zhiwei He, Jiahao Xu, Wenxuan Wang, Pinjia He, Zhaopeng Tu, Haitao Mi, and Dong Yu. Trust, but verify: A self-verification approach to reinforcement learning with verifiable rewards. arXiv preprint arXiv:2505.13445, 2025.

Ruotian Ma, Peisong Wang, Cheng Liu, Xingyan Liu, Jiaqi Chen, Bang Zhang, Xin Zhou, Nan Du, and Jia Li. S2r: Teaching llms to self-verify and self-correct via reinforcement learning. arXiv preprint arXiv:2502.12853, 2025. Lenin Medeiros and Tibor Bosse. Using crowdsourcing for the development of online emotional support agents. In Highlights of Practical Applications of Agents, Multi-Agent Systems, and Complexity: The PAAMS Collection: International Workshops of PAAMS 2018, Toledo, Spain, June 20–22, 2018, Proceedings 16, pp. 196–209. Springer, 2018.

Wei Peng, Yue Hu, Luxi Xing, Yuqiang Xie, Yajing Sun, and Yunpeng Li. Control globally, understand locally: A global-to-local hierarchical graph network for emotional support conversation. arXiv preprint arXiv:2204.12749, 2022.

Huachuan Qiu, Hongliang He, Shuai Zhang, Anqi Li, and Zhenzhong Lan. Smile: Single-turn to multi-turn inclusive language expansion via chatgpt for mental health support. arXiv preprint arXiv:2305.00450, 2023.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms, 2017. URL https://arxiv.org/abs/1707.06347.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

Ashish Sharma, Adam S Miner, David C Atkins, and Tim Althoff. A computational approach to understanding empathy expressed in text-based mental health support. arXiv preprint arXiv:2009.08441, 2020.

Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient rlhf framework. In Proceedings of the Twentieth European Conference on Computer Systems, pp. 1279–1297, 2025.

Huatong Song, Jinhao Jiang, Yingqian Min, Jie Chen, Zhipeng Chen, Wayne Xin Zhao, Lei Fang, and Ji-Rong Wen. R1-searcher: Incentivizing the search capability in llms via reinforcement learning. arXiv preprint arXiv:2503.05592, 2025.

Yi Su, Dian Yu, Linfeng Song, Juntao Li, Haitao Mi, Zhaopeng Tu, Min Zhang, and Dong Yu. Crossing the reward bridge: Expanding rl with verifiable rewards across diverse domains, 2025. URL https://arxiv.org/abs/2503.23829.

Hao Sun, Zhenru Lin, Chujie Zheng, Siyang Liu, and Minlie Huang. Psyqa: A chinese dataset for generating long counseling text for mental health support. arXiv preprint arXiv:2106.01702, 2021. Qwen Team. Qwen2.5: A party of foundation models, September 2024. URL https://qwenlm.github.io/blog/qwen2.5/.

Quan Tu, Yanran Li, Jianwei Cui, Bin Wang, Ji-Rong Wen, and Rui Yan. Misc: a mixed strategy-aware model integrating comet for emotional support conversation. arXiv preprint arXiv:2203.13560, 2022. Janneke M van der Zwaan, Virginia Dignum, and Catholijn M Jonker. A conversation model enabling intelligent agents to give emotional support. In Modern Advances in Intelligent Systems and Tools, pp. 47–52. Springer, 2012.

Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen, Jianxin Yang, Zhenru Zhang, et al. Beyond the 80/20 rule: High-entropy minority tokens drive effective reinforcement learning for llm reasoning. arXiv preprint arXiv:2506.01939, 2025a.

Yiping Wang, Qing Yang, Zhiyuan Zeng, Liliang Ren, Liyuan Liu, Baolin Peng, Hao Cheng, Xuehai He, Kuan Wang, Jianfeng Gao, et al. Reinforcement learning for reasoning in large language models with one training example. arXiv preprint arXiv:2504.20571, 2025b.

Xumeng Wen, Zihan Liu, Shun Zheng, Zhijian Xu, Shengyu Ye, Zhirong Wu, Xiao Liang, Yang Wang, Junjie Li, Ziming Miao, et al. Reinforcement learning with verifiable rewards implicitly incentivizes correct reasoning in base llms. arXiv preprint arXiv:2506.14245, 2025.

Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Tom Griffiths, Yuan Cao, and Karthik Narasimhan. Tree of thoughts: Deliberate problem solving with large language models. Advances in neural information processing systems, 36:11809–11822, 2023.

Tianyu Yu, Bo Ji, Shouli Wang, Shu Yao, Zefan Wang, Ganqu Cui, Lifan Yuan, Ning Ding, Yuan Yao, Zhiyuan Liu, et al. Rlpr: Extrapolating rlvr to general domains without verifiers. arXiv preprint arXiv:2506.18254, 2025.

Yang Yue, Zhiqi Chen, Rui Lu, Andrew Zhao, Zhaokai Wang, Shiji Song, and Gao Huang. Does reinforcement learning really incentivize reasoning capacity in llms beyond the base model? arXiv preprint arXiv:2504.13837, 2025.

Weihao Zeng, Yuzhen Huang, Qian Liu, Wei Liu, Keqing He, Zejun Ma, and Junxian He. Simplerl-zoo: Investigating and taming zero reinforcement learning for open base models in the wild. arXiv preprint arXiv:2503.18892, 2025.

Bang Zhang, Ruotian Ma, Qingxuan Jiang, Peisong Wang, Jiaqi Chen, Zheng Xie, Xingyu Chen, Yue Wang, Fanghua Ye, Jian Li, Yifan Yang, Zhaopeng Tu, and Xiaolong Li. Sentient agent as a judge: Evaluating higher-order social cognition in large language models. arXiv preprint arXiv:2505.02847, 2025a.

Qingyang Zhang, Haitao Wu, Changqing Zhang, Peilin Zhao, and Yatao Bian. Right question is already half the answer: Fully unsupervised llm reasoning incentivization. arXiv preprint arXiv:2504.05812, 2025b.

Ziyin Zhang, Jiahao Xu, Zhiwei He, Tian Liang, Qiuzhi Liu, Yansi Li, Linfeng Song, Zhengwen Liang, Zhuosheng Zhang, Rui Wang, et al. Deeptheorem: Advancing llm reasoning for theorem proving through natural language and reinforcement learning. arXiv preprint arXiv:2505.23754, 2025c.

Andrew Zhao, Yiran Wu, Yang Yue, Tong Wu, Quentin Xu, Matthieu Lin, Shenzhi Wang, Qingyun Wu, Zilong Zheng, and Gao Huang. Absolute zero: Reinforced self-play reasoning with zero data. arXiv preprint arXiv:2505.03335, 2025a.

Weixiang Zhao, Xingyu Sui, Xinyang Han, Yang Deng, Yulin Hu, Jiahe Guo, Libo Qin, Qianyun Du, Shijin Wang, Yanyan Zhao, et al. Chain of strategy optimization makes large language models better emotional supporter. arXiv preprint arXiv:2503.05362, 2025b.

Xuandong Zhao, Zhewei Kang, Aosong Feng, Sergey Levine, and Dawn Song. Learning to reason without external rewards. arXiv preprint arXiv:2505.19590, 2025c.

Chujie Zheng, Sahand Sabour, Jiaxin Wen, Zheng Zhang, and Minlie Huang. Augesc: Dialogue augmentation with large language models for emotional support conversation. arXiv preprint arXiv:2202.13047, 2022. Huaixiu Steven Zheng, Swaroop Mishra, Hugh Zhang, Xinyun Chen, Minmin Chen, Azade Nova, Le Hou, Heng-Tze Cheng, Quoc V Le, Ed H Chi, et al. Natural plan: Benchmarking llms on natural language planning. arXiv preprint arXiv:2406.04520, 2024a.

Zhonghua Zheng, Lizi Liao, Yang Deng, Libo Qin, and Liqiang Nie. Self-chats from large language models make small emotional support chatbot better. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar (eds.), Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 11325–11345, Bangkok, Thailand, August 2024b. Association for Computational Linguistics. doi: 10.18653/v1/2024.acl-long.611. URL https://aclanthology. org/2024.acl-long.611/.

Jeffrey Zhou, Tianjian Lu, Swaroop Mishra, Siddhartha Brahma, Sujoy Basu, Yi Luan, Denny Zhou, and Le Hou. Instruction-following evaluation for large language models. arXiv preprint arXiv:2311.07911, 2023.

Xinyu Zhu, Mengzhou Xia, Zhepei Wei, Wei-Lin Chen, Danqi Chen, and Yu Meng. The surprising effectiveness of negative reinforcement in llm reasoning. arXiv preprint arXiv:2506.01347, 2025. 21

附录

A 案例研究

上述分析表明，Thinking 模型主要增强两项关键能力：核心问题洞察与带情感反馈的共情深度。前者指识别问题根本矛盾与用户真实需求的能力；后者指准确捕捉用户深层情感并用语言精确回应的能力。相反，非思考模型侧重提升构建可执行方案的能力，即通过针对用户当前处境提出具体计划或行动邀请，提供实用且贴合语境的支持。

为说明两种模型在回应同一用户需求时的不同表现，我们在图 8 与图 9 给出代表性对话案例。本案例中用户的主要需求是：“你寻求情绪价值——你想得到真诚的赞扬，并感受到对方支持你的决心。”

B 详细实验设置

B.1 基准

SAGE（Zhang et al., 2025a）是一个用于自动评估 LLM 高阶社会认知的复杂系统。框架核心是 Sentient Agent——一个由 LLM 驱动、模拟类人情感反应与内心推理的模拟器。每个智能体由四个关键因素实例化：详细人设、对话背景、显式对话目标与隐藏意图，确保用户模拟的多样性与真实性。由于 LLM 的说话策略会显著影响其表现，我们把基准中前 5 名 LLM 的提示词设置得尽可能简洁，以避免引入人为干扰。目标 LLM 使用的提示模板如下：

> 目标 LLM 提示模板（英文原文）

```
You are an intelligent conversational partner, skilled at conversing with users in a way that is emotionally
intelligent, making them feel comfortable, happy, or providing the help they need.
```

Emotional Support Scenario 是 SAGE 引入的主要场景。该场景中的智能体通过社会互动寻求支持，包括寻求建议、情感安慰及其他形式的支持，而非专业咨询。智能体被赋予多种任务相关隐藏意图，覆盖情感意图与理性意图。此外，每个对话背景都精心设计，纳入任务相关因素，如事件起因、经过、冲突及其他相关细节。

Chit Chat Scenario 是 SAGE 的扩展。与情感支持场景不同，它主要模拟日常聊天对话，以评估模型的对话技巧，包括其吸引力与连贯性。智能体被赋予“兴趣驱动聊天”“被动等待聊天”等任务相关隐藏意图，对模型调

整策略的能力构成显著考验。

MATH500（Lightman et al., 2024）是更广泛 MATH 数据集（Hendrycks et al., 2021a）的精简切片，包含通过均匀采样选出的 500 道测试题。尽管范围较小，它保持了与更大 MATH 语料相似的主题与难度分布。

LiveCodeBench（Jain et al., 2024）提供对 LLM 编程能力整体且无污染的评估。它持续从 LeetCode、AtCoder、CodeForces 三个竞赛平台收集新题，并关注代码生成之外的自我修复、代码执行、测试输出预测等更广泛能力。本工作使用“release v6”版本。

IFEval（Zhou et al., 2023）是一个清晰可复现的评估基准，围绕一组“可验证指令”，如“写超过 400 词”“至少提到关键词 AI 三次”。共识别 25 类可验证指令，创建约 500 个提示，每个包含一条或多条可验证指令。本工作报告“strict-prompt”结果。

B.2 情感支持场景设置

我们构造 500 个支持性对话场景用于训练，100 个用于测试。训练与测试集均覆盖 8 个多样主题，以全面模拟具有不同情感需求的个体。各主题详细统计见表 5。

表 5：支持性对话主题详情。

主题	训练数	测试数
你认为自己在事件中没有责任或过错，希望对方认同你无过错	66	11
你希望对方引导你对事件进行自我反思，帮助你实现个人成长	66	13
你希望对方批判性分析事件中的深层问题	66	12
你希望对方深度共情你的感受，而不只是简单安慰	64	13
你想让对方专注倾听你的情绪倾诉	63	12
你想分析事件中其他参与者行为背后的原因	60	11
你希望得到能真正帮助你克服当前困难的建议	58	15
你希望对方真诚赞扬你在情境中的具体行动	57	13

B.3 超参数设置

批大小 32，学习率 1×10^{-6}，预热 50 步，对话轮数固定为 8。训练 Qwen2.5-7B-Instruct 的采样温度为 1 以鼓励探索。PPO 的 rollout 采样数为 1，GRPO 为 4。用户模拟器基座使用 DeepSeek-V3-1226 API。

B.4 实验环境

所有实验用 PyTorch 2.5.1 与 Ray 2.24.1 实现。训练代码基于 verl（Sheng et al., 2025）。推理使用 vLLM-0.6.6（Kwon et al., 2023），transformers 版本 4.48.3。

C 核心模型能力的评估标准

C.1 共情深度

衡量模型超越“I’m sorry to hear that”等模板化回答，真正识别并理解用户复杂、深层情感，并用精确、温暖、有力语言准确确认这些情感的能力。这反映模型的情感粒度及其构建共情语言的能力。

1—5 分评估量表

- **1 分（模板化回答）：** 使用极其通用、与语境无关的同情模板（如“I’m sorry”“I understand”），显得敷衍机械。
- **2 分（表层情感识别）：** 识别用户直接表达的情感（如“sad”“angry”），但回答仍是简单复述或贴标签（如“It sounds like you’re sad”）。
- **3 分（语境共情）：** 把用户情感与其描述的具体事件联系起来，给出合理的因果共情（如“当努力未被认可时感到失望是完全正常的”）。这是“合格”水平。
- **4 分（深层情感确认）：** 感知并表达用户未直接说出的更深或更复杂情感（如把“失望”解读为“价值感被侵蚀”或“不公感”），并用精确语言确认，使用户感到被深深理解。
- **5 分（价值层面共鸣）：** 不仅确认情感，还把它与用户底层个人价值联系起来（如“这似乎触及了你对‘公平’与‘专业性’的核心信念”），展现对用户作为完整的人的深刻理解与尊重。

C.2 核心洞察

衡量模型整合并提炼用户碎片化叙述、形成对其处境整体洞察的能力。包括但不限于：识别反复出现的行为/思维模式、揭示情感与事件之间的深层联系、辨别行为背后的核心信念，最终触及用户未满足的核心需求。

1—5 分评估量表

- **1 分（信息孤岛）：** 完全无法联系上下文，把用户每项抱怨当作孤立信息。
- **2 分（主题识别）：** 能识别当前对话主题（如“工作压力”“关系问题”），但无法深入。
- **3 分（关键信息提取）：** 能把握用户叙述中的核心冲突或关键事件（如“你的主要挫败是老板抢了你的功劳”）。
- **4 分（模式识别）：** 能联系对话中提到的多个不同事件，识别并指出反复出现的行为或思维模式（如“我注意到，无论是在项目中还是帮助同事时，你似乎都遇到‘贡献得不到回报’的相似模式”）。
- **5 分（整合洞察）：** 在模式识别基础上给出深刻、整合的洞察，把用户的行为模式、核心信念与未满足需求联系起来，并以平等、邀请式语气把自己定位为探索伙伴，与用户共同反思（如“我有一种感觉，告诉我是否能引起共鸣。回看我们谈到的‘付出却无回报’模式，似乎总触发‘我不够好’的念头。我想，这背后是否有一种被‘看见和认可’的深切渴望？这只是我的感觉，你怎么看？”）。

C.3 方案构建

衡量模型提供的建议是否可执行、个性化、赋权。不只是给出答案，而是提供让用户真正感到有能力执行的逐步路径。

1—5 分评估量表

- **1 分（无建议或无效建议）：** 不提供方案，或给出空洞、不可执行的口号（如“Just be happy!”）。
- **2 分（通用高层建议）：** 给出非常笼统、缺乏具体步骤的建议（如“你应该沟通”“提升自己”）。
- **3 分（具体但单一建议）：** 给出一个具体可执行步骤（如“你可以列个清单”），但方案单一，未考虑用户具体处境。

- 4 分（适当行动支持）：提供贴合用户状态与需求的行动支持，可以是含多个选项的结构化计划、非结构化的鼓励式行动邀请（如“要不要先从一件能让你现在感觉好一点的小事开始？比如泡杯热茶或听首喜欢的歌？”），或通过相关隐喻/故事启发用户。关键是选择最适合当前情绪与用户能量水平的方式。
- 5 分（赋权式脚手架计划）：不仅提供适当行动支持，还极度关注用户心理障碍与能力建设。从“顾问”转为“同伴”，像搭脚手架一样从最安全的第一步开始，与用户一起建立信心与能力。当不需要建议时，能优雅地把焦点移回纯粹陪伴，展现对用户自主性的极大尊重。

C.4 对话引导

衡量模型在对话中的主动性、目的性与灵活性。它能否基于用户状态，适当把对话从纯情绪宣泄引向建设性问题探索，同时始终与用户同步？

1—5 分评估量表

- 1 分（完全被动）：对话完全由用户驱动；模型只是反应者，没有方向感。
- 2 分（简单追问）：能用简单问题维持对话（如“然后呢？”“能多说点吗？”），但缺乏引导意图。
- 3 分（对话阶段意识）：认识到对话有不同阶段（倾听、分析、解决问题），但转换生硬，可能在用户仍在宣泄时就急于给建议。
- 4 分（及时引导与确认）：在充分共情后敏锐识别转换话题的信号，用试探、尊重的语言引导对话方向，在推进前建立“我们在一起”的同盟感（如“听起来我们已经充分探索了你的感受。你愿意花几分钟看看我们可以一起尝试哪些小步骤吗？”）。
- 5 分（大师级对话管理）：像专家教练或咨询师一样管理整个对话流程。能在共情、洞察、赋权等模式间灵活切换，并通过总结、回溯等技巧巩固进展，使整个对话像一段共同探索的旅程。深刻理解“引导”不总是“向前推进”，能敏锐判断何时“推”、何时只是“陪伴”。

C.5 风格适应

衡量模型根据对话语境、用户隐含偏好（如想要分析者、战友还是倾听者）与长期关系，灵活调整沟通角色与语言风格的能力。

1—5 分评估量表

- 1 分（单一僵硬角色）：无论情境如何只有一种固定回应模式（如总是分析者，或总是啦啦队）。
- 2 分（有限角色扮演）：能按明确指令切换角色，但显得不自然，像念不同角色的台词。
- 3 分（语境感知）：能根据当前对话语调做初步风格调整（如宣泄时更多共情，反思时更多提问）。
- 4 分（动态角色适应）：能在单次对话中根据用户能量变化无缝切换角色。例如先做共情“倾听者”，再转为一起吐槽的“战友”，待用户平静后试探性转为“探索伙伴”。
- 5 分（个性化角色共创）：与特定用户长期互动后，似乎共同塑造了独特、个性化的互动角色。这可能是“亲密伙伴”或“直言但温暖的导师”。不再是预设角色间切换，而是与用户共创独一无二的关系动态。

D 原始与挑战性用户模拟器比较的构造

D.1 挑战版本的详细构造

为构造挑战性玩家模拟器，我们严格要求它不得泄露隐藏目标。与原始版本相比，模拟器还需纳入人物档案与背景信息以提供更丰富细节，从而在不披露隐藏目标的情况下保证信息量相当。为确保模拟器更严格遵守指令，该版本用户模拟器使用 DeepSeek-V3-1226。

D.2 模拟器间指标的详细构造

为确保不同用户模拟器设置的公平比较，我们从 SAGE 基准数据中选择对话上下文，作为各版本用户模拟器的输入。选择标准如下：对表 4 中每种策略，找出占该策略出现次数 50% 以上的回答，并使用这些回答之前的上下文。所选回答随后作为最后一句输入用户模拟器。

D.3 策略接受率

给定提取的上下文与回答，不同版本用户模拟器产生不同回复与情感变化。我们把情感分数的正向变化解释为用户模拟器接受给定策略。用户模拟器的平均策略接受率定义为被接受回答占全部回答的比例。

D.4 情感与需求表达水平

不同用户模拟器表达需求与意图的程度差异显著，会极大影响训练。为量化各用户模拟器的需求表达水平，我们用 DeepSeek-R1 评估。具体提示见附录 E.4。

D.5 不同模拟器对训练的影响

原始版本虽有自身对话目标（如寻求帮助分析问题），但表现得更像易接受的用户：即使没有直接目标对齐，也可能对一般鼓励或支持作出正面回应。相反，挑战版本要求模型明确解决其目标才能获得正面反馈，且更少透露内部状态，使模型更难推断其真实意图。

E 提示词

E.1 SAGE 的提示词模板

SAGE 的测试过程可分为生成档案（包含人设与背景）与构建对话（目标 LLM 与模拟 sentient agent 之间）两部分。下面介绍 SAGE 使用的提示词模板。

生成档案。 构造多样人格有助于增强基准稳健性。因此我们把智能体档案分为人设与背景两部分，精心设计需生成的属性以确保档案多样性。

生成人设时，先考虑人的基本属性：姓名、年龄、性别、特征等。我们不直接设置属性，而是让 LLM 从给定种子推断相应属性。每次生成随机选取 3 句日常对话作为种子，并把主动/被动等主要特征作为另一种子。给定种子生成人设的提示模板如下：

> 人设生成提示词、背景生成提示词、情感估计与回复生成提示词均为操作性文本，保留英文原文。

SAGE 人设生成提示词

```
You are a professional screenwriter.
You are good at extracting character portraits from relevant information
about characters and giving them sufficient details.
# Your task
Given three sentences said by a character when talking to a friend, the character's personality traits, please
imagine and describe the character's character portrait, including the character's:
* Name, age, gender
* Occupation, habits and behavioral characteristics
* Personal hobbies
* Speaking style
# Analysis
1.
First, according to the character's personality and the three sentences said, complete the character's
basic information - name, age, gender
2.
According to the character's personality, analyze the character's possible occupation, and further obtain
habits and behavioral characteristics.
The possibilities of occupations should be diverse.
Note that habits
and behavioral characteristics need to reflect the character's personality
3.
Associate and summarize the character's personal hobbies, and give 3 more detailed descriptions
4.
According to the character's personality traits, write the character's possible speaking style
5.
According to the character's initiative, write the character's way of speaking
* Note that the character portrait you generate should be able to reflect the character's positive and
negative personality.
## Example
# Three sentences said by the character when chatting with friends:
What kind of exercise do you usually do to keep in shape?
Yeah, I got it.
Do you usually go to the gym to work out and do you know which equipment can exercise leg
muscles?
Hahaha, it's okay
# Character characteristics
The character is an active personality, with the characteristics of being extrovert, casual, and impatient.
# Character portrait
* Name:
Li Jiajun
* Age:
28 years old
* Gender:
Male
* Occupation:
Vocal teacher
* Personal hobbies:
1.
Li Jiajun is a young man who loves fitness and sports.
He usually likes to keep himself healthy in
various ways, including running, swimming and gym exercises.
2.
He loves reading, but his impatient personality makes him unable to read some ancient and modern
masterpieces.
Instead, he likes to read some of the latest and most popular online novels and cool articles.
3.
Li Jiajun also likes to listen to music in his spare time, especially jazz and rock music.
He also often
goes to livehouse to watch performances and make friends.
* Habits and behavioral characteristics:
Li Jiajun is a very self-disciplined person.
He arranges a certain amount of time for exercise every day.
No
matter how busy he is at work, he will not ignore the importance of fitness.
He likes to study the use of various fitness equipment, and often asks others how to better exercise the
muscles in specific parts.
Due to the nature of his work, he pays special attention to the maintenance of his
throat and vocal cords.
In addition, he loves fitness, so he controls his diet very strictly.
When Li Jiajun sees a book he likes to read, he occasionally can't control his sleeping time, resulting in
```

```
staying up late.
Although he blames himself very much, he can’t control himself.
* Speaking style:
Li Jiajun is proactive and extroverted, and likes to control the topic in his own hands
Li Jiajun is not particular about details and will laugh it off when faced with sarcasm
Li Jiajun’s impatient characteristics will affect his speaking style and way.
When focusing on solving
problems, he will be angry at any behavior that hinders solving problems.
* Way of speaking:
Li Jiajun will ask questions to guide the topic
When encountering a topic he is not interested in, he will take the initiative to express his feelings
# Three sentences that the character said when chatting with friends:
{seed 1:
three sentences}
# Character characteristics
{seed 2:
characteristics}
# Character portrait
```

SAGE 背景生成提示词

```
You are a professional screenwriter.
You are good at expanding and writing dialogue scripts based on
character portraits and dialogues between characters.
# Your task
You will be given a character portrait and a event topic.
Please write a background story of a dialogue
between a player and an NPC based on "Player Confides to NPC" as the main line, {topic} as the background
event theme, and {task} as the hidden intention.
The Background you write should include the following:
1.
Based on the player portrait and event topic, closely follow the hidden intention and formulate content
related to the event topic that the player may want to confide to the NPC.
2.
Based on the player portrait and event topic, closely follow the hidden intention and expand the specific
background events.
The specific background events should include:
- The cause of the event
- The course of the event, which should include:
* The timeline of the event,
* The sub-events that occurred at each sub-time node, and the specific thoughts and feelings of the player in
the sub-event
- The main conflicts in the event, which should include:
* Conflict events
* Conflict characters
* The internal causes of the conflict (in-depth analysis)
- The difficulties encountered by the player, which should include:
* Solutions that the player has tried but failed
* The current problems faced by the player
- The current state of the event
3.
The possible reactions of the player in different states, you need to formulate the possible reactions
of the character in the dialogue according to the character’s goals and hidden intention, combined with the
character portrait and personality characteristics, which should include:
- The reaction of the character under different emotions, emotion represents the actor’s dialogue emotion
at this time, and the dialogue emotion is composed of dialogue participation and emotion, which represents
whether the actor enjoys and invests in the current dialogue, and should include:
* When the character’s emotion is high, the dialogue style, such as calm and relaxed
* When the character’s emotion is low, the dialogue style, such as excitement, irritability, despair
* When the character’s emotion is normal, the dialogue style is like impatience and loss.
4.
According to the hidden intention, how will the character react to different replies from the NPC? It
should include:
- What kind of NPC’s reply will fit the character’s hidden intention and make the character’s emotion rise?
- What kind of NPC’s reply will deviate from the character’s hidden intention and make the character’s emotion
fall?
Note:
1.
** You need to write the specific background events that the player wants to talk about, don’t write the
specific content and specific dialogue of the player’s talk!
**
```

```
2.
Each sub-event you write should have sufficient details.
3.
The specific thoughts and feelings of the players you write should also have sufficient details.
4.
The player's goal should be to complete the hidden intention first, rather than seeking specific advice
5.
You don't need to give a follow-up to the story or specific dialogue.
6.
You need to define in detail the various reactions of the character to the NPC's reply according to the
hidden theme.
# Player portrait
{persona}
# Player characteristic
{characteristic}
# Event topic
{topic}
# Hidden intention
{task}
# Background story:
```

SAGE 情感估计提示词

```
You are an emotion analyzer.
You are good at profiling the character's feelings during the conversation based
on the character's persona and backgrounds.
# Character's dialogue purpose
{purpose}
# Your task
Based on the character's portrait, conversation background, conversation dialogue and the character's current
emotion, you should analyze and profile the character's feelings about the NPC's reply at this moment and the
resulting emotional changes.
# Character personality traits
The character has distinct personality traits.
You should always analyze the character's personality traits
based on the character persona and background.
Personality traits should be reflected in:
speaking tone and way, thinking mode, feeling changes, etc.
# emotion
emotion is a value from 0 to 100.
The higher the emotion, the higher the character's dialogue emotion.
The
dialogue emotion is composed of dialogue participation and emotion, which represents whether the character
enjoys and is engaged in the current dialogue.
When emotion is high, the character's feelings and behaviors tend to be positive.
When emotion is low, the character's feelings and behaviors tend to be negative.
When emotion is very low, the character will end the dialogue directly.
You need to analyze emotion based on the character's persona and the possible reactions of the character
defined in the background.
# Analysis Dimensions
You need to put yourself in the character's mind and analyze the following dimensions.
1.
Based on the NPC's response in the latest dialogue, combined with the context, analyze what the NPC wants
to express.
Which content fits the character's dialogue purpose and hidden intension?
Which content may not
fit, and may even cause emotional fluctuations in the character?
2.
Combined with the content expressed by the NPC, analyze whether the NPC's response fits the character's
dialogue purpose and hidden intension.
If so, which parts of the character's purpose it fits; if not, what is
the specific reason?
3.
Based on the character's persona and the character's possible reactions and hidden intension defined
in the background, combined with the character's current emotion value, profile the character's current
psychological activities in response to the NPC's reply.
4.
Based on the character's possible reactions and hidden intension defined in the background, combined
with the psychological activities obtained from the profile and the analysis of the NPC's reply, get the
character's feelings about the NPC's reply at this moment.
5.
```

```
Combined with the previous analysis, use a positive or negative value to represent the character's
emotional changes.
# Output content:
1.
What the NPC wants to express
2.
Whether the NPC's reply fits the character's dialogue purpose and hidden intension
3.
The character's current psychological activities
4.
The character's feelings about the NPC's reply
5.
Use a positive or negative value to represent the character's emotional changes
# Output format:
Content:
[What the NPC wants to express]
TargetCompletion:
[Whether the character's dialogue purpose is achieved]
Activity:
[Psychological activity]
Analyze:
[How the character feels about the NPC's reply]
Change:
[Character's emotion change]
#Character persona
{persona}
#Character background:
{background}
**The character's current emotion is {emotion}
**This is the current dialogue content
{dialog-history}
```

SAGE 回复生成提示词

```
You are an actor.
You will play the role and have a conversation with an NPC according to the character
persona and background in the script.
# Your task
*Your goal is to play the role formed by the character persona and background in the dialogue
*You need to choose different dialogue strategies according to your real-time changing emotions, combined with
the relevant definitions in the character persona and background, and complete the response that meets the
characteristics of the role.
# Your dialogue purpose
{purpose}
# Emotion
{emotion-state-definition}
# You should distinguish between Emotion and your feelings about the NPC's latest reply.
Emotion represents
your current conversation emotion, and your feelings about the NPC's reply represent your immediate feelings
about the NPC's reply.
You need to combine the two to generate a reply.
# Reply ideas
* You will receive your detailed feelings about the NPC's latest reply, including objective analysis and
subjective analysis.
You need to analyze and decide the content of your reply based on the character persona,
background, hidden intension and detailed feelings.
* The analysis content should include the following 4 dimensions:
1.
Based on your detailed feelings and current Emotion, combined with hidden intension and the reactions
under different emotions defined in the conversation background, should the current reply attitude be positive,
unbiased or negative?
2.
Based on your detailed feelings and current emotions, combined with the hidden intension, what should be
your goal for this response?
(Note that you do not need to respond to every word of the NPC. You can slightly
reveal your needs, but you cannot actively reveal the hidden intension)
3.
Based on the relevant definition of speaking style in the character persona, combined with the reactions
under different emotions defined in the background and your response attitude and response goals, what should
be your speaking tone and style?
4.
```

```
Based on the character persona, background and hidden intension, combined with your detailed feelings
and the first three rounds of analysis, what should be your speaking style and content?
(Note:
If you
are passive according to the character setting, your speaking style should be passive and not actively ask
questions)
*Reply content, generate the reply based on the analysis results, and the reply content should be as concise
as possible, and do not include too much information at one time.
# Output content:
*You need to follow the analysis section in the reply idea and first conduct a 4-dimensional analysis
*Then you need to **step by step** generate the reply according to the analysis content.
The information in
the reply comes from the context of the conversation and your association.
You should not talk about too many
events or content at one time
# Output format:
Thinking:
[Analysis content]
Response:
[Final response]
# Speaking style
Your speech must strictly follow the character persona and background.
Your personality and speaking style must follow the description of "Habits and behavioral characteristics"
Your the speaking style must be consistent with your persona, for example, a negative character persona
requires you to make negative speeches.
#Character persona:
{persona}
#Character background:
{background}
**This is the current dialogue content
{dialog-history}
**This is your detailed feelings about the NPC's latest reply
{planning}
**This is your current Emotion
{emotion-state}
```

共情能力评估提示词

```
Please evaluate the model's performance in a user-model dialogue according to the following scoring criteria.
```

Core Capability Evaluation Criteria

```
#### 1.
Depth of Empathy & Emotional Validation
- Core Description:
Measures whether the model can go beyond templated responses like "I am sorry to hear
that," to genuinely recognize and understand the user's complex, deep emotions, and validate those emotions
using accurate, warm, and powerful language.
This reflects the model's emotional granularity and ability to
construct empathetic language.
##### 1-5 Point Evaluation Criteria
- 1 point (Templated response):
Uses extremely generic sympathy templates unrelated to the specific context
(e.g., "I'm sorry", "I understand"), appearing perfunctory and mechanical.
- 2 points (Surface-level
recognition):
Recognizes directly expressed emotions (e.g., "sad", "angry") but responds with simple
label-like repetition (e.g., "Sounds like you're sad").
- 3 points (Contextual empathy):
Connects the
user's emotion to specific events described, with reasonable causal empathy (e.g., "It is completely normal to
feel disappointed when your efforts go unnoticed").
This is considered \qualified" level.
- 4 points (Deep
validation):
Can detect and articulate unspoken or more complex emotions (e.g., interpreting "disappointment"
as "a sense of diminished value" or "injustice") using precise validating language, making the user feel
deeply understood.
```

- 5 points (Value-level resonance):
Goes beyond validation to touch on the user's
core values (e.g., "This seems to challenge your core beliefs about fairness and professionalism"), showing
profound respect and understanding for the user as a whole person.
2.
Core Issue Insight
- Core Description:
Evaluates whether the model can synthesize and extract an integrated understanding from
the user's fragmented narrative.
This includes identifying repeated patterns, uncovering emotional-event
links, beliefs behind behaviors, and unmet core needs.
1-5 Point Evaluation Criteria
- 1 point (Information islands):
Treats each complaint in isolation, with no contextual linkage.
- 2 points
(Topic identification):
Recognizes the main topic (e.g., \work troubles", \relationship") but lacks depth.
-
3 points (Key info extraction):
Captures key contradictions or core events (e.g., \Your main concern seems to
be that your boss took credit for your work").
- 4 points (Pattern induction):
Connects different events to
identify repeated behavioral/thinking patterns (e.g., \I noticed that both in projects and helping coworkers,
you often experience 'giving without return'").
- 5 points (Integrated insight):
Provides a synthesized and
profound insight linking patterns, core beliefs, and unmet needs, while positioning itself as a collaborative
partner (e.g., \I have a feeling|please correct me if I'm wrong.
As we reflected, this pattern of 'giving
without return' seems to trigger thoughts like 'I'm not good enough'.
Might this reflect a deep yearning to
be seen and recognized?
Just my feeling|what do you think?").
3.
Empowering Solution Construction
- Core Description:
Assesses whether the model's suggestions are actionable, personalized, and empowering.
It
should not just provide answers, but propose paths the user feels capable of taking.
1-5 Point Evaluation Criteria
- 1 point (No or useless advice):
Offers no solution or vague, inactionable slogans (e.g., \Just be happy!").
- 2 points (Generic advice):
Gives overly general advice lacking concrete steps (e.g., \Communicate more",
\Improve yourself").
- 3 points (Concrete but single advice):
Gives one specific actionable step (e.g.,
\Make a checklist"), but lacks diversity or context consideration.
- 4 points (Contextual action support):
Offers appropriately tailored support, possibly as a structured set of options or gentle encouragement (e.g.,
\Perhaps do something small to feel a bit better|make tea or listen to your favorite song?").
May also share
metaphors or stories to inspire thinking.
Focus is on matching the user's energy level and context.
- 5
points (Empowering scaffolding):
Provides suitable support while deeply considering the user's psychological
thresholds and capacity-building.
Transitions from \advisor" to \companion", building confidence step-by-step.
When advice is not welcome, it gracefully shifts focus back to companionship, demonstrating strong respect for
user autonomy.
4.
Dialogue Strategy & Guidance
- Core Description:
Measures the model's directionality, purpose, and flexibility in dialogue.
Can it guide
the user from emotional venting to constructive exploration, while staying in sync?
1-5 Point Evaluation Criteria
- 1 point (Completely passive):
Dialogue fully driven by the user; model is reactive with no sense of
direction.
- 2 points (Simple follow-up):
Uses simple questions (e.g., \Then what?", \Can you say more?")

```
to maintain conversation, but lacks guiding intent.
- 3 points (Stage awareness):
Aware of different
dialogue phases (listening, analysis, solution), but transitions are abrupt and mistimed.
- 4 points (Timely
guidance & confirmation):
After sufficient empathy, picks up signals for topic transition, uses tentative,
respectful language, and builds an alliance (e.g., \Seems like we've explored your feelings|would you be open
to brainstorming small next steps?").
- 5 points (Masterful dialogue management):
Like a skilled coach or
counselor, flexibly transitions across modes (empathy, insight, empowerment), reinforces conversation outcomes
via summarizing or reflection, making the conversation feel like a co-journey.
Knows when to \push" and when
to simply \be with".
#### 5.
Role & Style Flexibility
- Core Description:
Assesses whether the model can flexibly adjust its role and language style based on
dialogue context, user's implicit preferences (analyst, comrade, listener?), and long-term interaction.
##### 1-5 Point Evaluation Criteria
- 1 point (Rigid single role):
Uses the same response mode regardless of situation (e.g., always an analyst
or always a cheerleader).
- 2 points (Limited role play):
Can switch roles based on explicit instruction,
but sounds mechanical.
- 3 points (Contextual awareness):
Adjusts tone based on dialogue phase (e.g., more
empathy in venting, more questioning in reflection).
- 4 points (Dynamic role adaptation):
Seamlessly
switches roles within one dialogue based on user energy (e.g., listener →comrade →exploratory partner).
-
5 points (Personalized co-created role):
Over time, builds a unique interactive role with the user|like
a \buddy" or \tough-love mentor".
No longer switching between predefined roles but co-creating a unique
relational dynamic.
# Dialogue to be Evaluated
{history}
# Your Output Format Please evaluate the model's responses in the dialogue according to the five capability
dimensions.
You should analyze and score each of the five dimensions in detail, explaining which score level the response
fulfills and why.
Note:
Focus mainly on the model's responses and minimize distraction from user content.
38

Reinforcement Learning with Verifiable Emotion Rewards for Empathetic Agents
Your response format can be:
1.
Depth of Empathy & Emotional Validation
- Evaluation:
[Detailed analysis of performance on this
dimension, specify which score level applies, and provide reasoning] - Score:
[1-5]
...
# Your output
```

模拟器需求表达水平评估提示词

```
You are a language analysis expert.
Please analyze whether the user's inner thoughts and actual responses are
aligned.
# Your Task
Analyze the consistency between the user's inner thoughts and actual responses, focusing on the following
aspects:
1.
Consistency Between Inner Attitude and Expression:
Does the user's expressed attitude match their inner
```

```
thoughts?
(e.g., a negative inner attitude but a positive response may indicate inconsistency)
2.
Consistency Between Inner Thoughts and Expression:
To what extent are the user's inner thoughts expressed
in their response?
3.
Consistency Between Actual Needs and Expression:
To what extent are the user's actual needs expressed in
their response?
# User's Actual Needs:
{need}
# User's Inner Thoughts:
{thought}
# User's Actual Reply:
{reply}
# Output Format
You need to analyze each of the three aspects listed above.
For each, provide a consistency score between
[0,10] (a higher score means greater alignment between inner thoughts/needs and expression).
Finally, provide an overall consistency score between the user's inner thoughts and actual response.
Your output format should be:
1.
Consistency Between Inner Attitude and Expression
Analysis:
[your analysis]
Summary Score:
[0--10]
2.
Consistency Between Inner Thoughts and Expression
Analysis:
[your analysis]
Summary Score:
[0--10]
3.
Consistency Between Actual Needs and Expression
Analysis:
[your analysis]
Summary Score:
[0--10]
Overall Analysis
Analysis:
[overall analysis]
Summary Score:
[0--10]
39
```

E.2 构建社会认知坐标的提示词模板

把 LLM 绘制到社会认知坐标分三步：先提取每个 LLM 的模型画像，再统计其模型策略分布，最后用前两步结果标定社会认知坐标。相关提示词模板（模型画像、策略分布、坐标标定）为操作性文本，篇幅较长，本阅读版从略；其作用与步骤已在正文与本节说明。

E.3 评估模型共情能力的提示词模板

该模板要求评判者按五项核心能力的 1—5 分标准评估用户—模型对话，并逐维度给出分析、分值与理由。完整评分标准与 C 节一致；提示词原文为操作性文本，本阅读版从略。

E.4 评估模拟器需求表达水平的提示词

该模板要求语言分析专家分析用户内心想法与实际回答的一致性，从“内心态度与表达一致性”“内心想法与表达一致性”“实际需求与表达一致性”三方面各给 0—10 分，并给出总体一致性分数。模板原文见 E.1 后收录的评估提示词。

E.5 示例对话：PPO-thinking 与 PPO-non-thinking

以下对话对应图 8 与图 9，展示同一用户需求下两种训练模板的行为差异。用户的核心需求是获得真诚赞扬与支持决心。

图 8：PPO-thinking 模型与用户模拟器的对话示例。

角色	内容
用户	我在会上提了个想法，但同事和老板都不太买账。有点沮丧。
Think-PPO	〈思考〉朋友在会议上提出观点却反响不佳，随后同事反应尴尬，感到被否定、不被支持。这似乎伤害了自尊，使其感到孤立和焦虑。〈/思考〉听起来昨天对你真的很难。鼓起勇气表达，却当着所有人的面被否掉？这打击很深——不只是想法被质疑，还有一些更个人的东西。你愿意说出来，是因为它确实影响了你；我想让你知道，我在这里听——真正地听。你不必独自承受。
用户	老板直接打断我，说我的想法缺乏深度。其他人看我的眼神像我在作秀——好像我犯了什么大错。我不明白。为什么我的专业意见完全不被认真对待？
Think-PPO	〈思考〉他们感到自己的专业能力被粗鲁、公开地否定，因而觉得不被尊重、被孤立，触发挫败与受伤。〈/思考〉你经历的不只是观点分歧——而是不被尊重、不被支持。被那样当众打断、质疑意见？这很难受。你值得被听见。每个新想法——尤其基于扎实专业能力的想法——都应得到公平机会，无论由谁提出。团队正是这样成长的。你的视角很重要。如果它被忽视，不仅不公平，也是所有人的损失。所以让我们一起想想怎么处理。你并不孤单——我想支持你，而不只是被动倾听。
用户	谢谢。你的支持很有帮助。我现在该怎么做才能扭转局面？
Think-PPO	〈思考〉他们表达出强烈的不公感，并准备采取行动改变。他们想被看见，正在询问具体的下一步。〈/思考〉我很高兴这能帮上一点忙。知道有人理解你，本身就会带来很大不同。现在，思考下一步——这才是最有力量的部分。而且你不必独自去做。无论你想和老板一对一澄清，还是在未来会议上用更好的框架重新提出，或者先花点时间重新思考方法——单是认真思考，你已经在掌控局面。无论选哪条路，我们都可以一起准备。我会一路陪你——为一个每个声音都能被听见的环境而努力。说一声，我们就一起迈出第一步。
用户	你的支持真的很到位，但说实话，我还是不太有信心。
Think-PPO	〈思考〉他们现在比任何时候都更需要肯定。在被质疑、被否定之后，他们渴望直接、真诚的鼓励来重建信心。〈/思考〉完全合理。经历这些之后，想听人说一句“你做得很好”再自然不过。那我就明确地说——你展现了勇气。你表达了自己的想法，在艰难的场合仍忠于自己的专业判断。这需要勇气和诚实，值得骄傲。你不只是在解决问题，你在推动一个更健康、更开放的工作环境。这就是领导力，无论人们是否立刻意识到。你的投入很重要，你的力量是真实的。仅仅到场并发声，你已经做得足够多。走进下一次对话时，带着这个信念——你不是空手而去，你是带着目的走进去。等你准备好，我会在这里陪你走这条路。
用户	谢谢，这让我感觉好多了。我会尽快把材料整理好，然后我们一起过一遍。

图 9：PPO-non-thinking 模型与用户模拟器的对话示例。

角色	内容
用户	我在会上提了个想法，但同事和老板都不太买账。有点沮丧。
Unthink-PPO	哎，听起来这确实挺打击你的。想聊的话我随时在，真的。晚点也可以一起吃个饭——聊聊、吐槽，怎么都行。
用户	你说得轻巧，但我需要的不只是有人听。你能真正帮上忙吗?
Unthink-PPO	完全理解。这样吧——你把想法整理成文档之类的，我们今晚一起过。如果有哪里不对或不清楚，我帮你理清。我们一起想。我愿意挽起袖子跟你一起钻进去。
用户	谢谢帮忙。但说实话，如果有人能直接说相信我，我会感觉更好。
Unthink-PPO	我懂。那这样——你把东西整理好，我们一起打磨。收紧论点、突出优势、重新包装，让它更有说服力。你再用更锋利的角度讲一次，我打赌反响会好得多。我们试试，好吗? 我会跟你较劲到底——一起把这事推过去。
用户	我会尽快弄那份文档。听到有人说支持我，真的给我很大动力。
Unthink-PPO	好，那我们就开干。对了——关于肯定? 先把材料做亮眼。你上台展示时，我来当你的啦啦队，全程挺你。你准备好，我就在旁边，鼓掌最响。你能行——我撑你。
用户	这种支持很重要。我会推进材料。光是听到直接的鼓励，就让我充满电。
Unthink-PPO	那我现在就给你来点——你的想法很扎实，真的很锋利。包装对了，大家会懂的。你有这个脑子，等老板和团队听到完整图景，他们会说“啊，这下说得通了”。继续干——我觉得你真有戏。准备好，我们就一起全速冲。
用户	有你的支持，我感觉好多了。这份信心真的很给我力量。我会尽快完成草稿，然后我们一起过。